

Tehnologije znanja pri predmetu informatika:  
vodnik za izpeljavo sklopa tehnologije znanja

Alenka Krapež  
Vladislav Rajkovič

# Vsebina

<b>PREDGOVOR</b>	<b>3</b>
<b>1. MODEL POUČEVANJA</b>	<b>6</b>
1.1. Vsebine poučevanja in pristopi k poučevanju	6
1.1.1. Ravni uporabe IKT	6
1.1.2. Procesiranje informacije pri človeku	7
1.1.3. Pregled različnih tehnologij znanja	9
1.1.4. Proces odločanja in različni prijemi pri odločanju	12
1.1.5. Uporaba različnih pripomočkov pri odločanju	17
1.1.6. Gradnja odločitvenih modelov	28
<b>2. UČNI NAČRT IN PREDLOG ČASOVNE RAZPOREDITVE UR</b>	<b>33</b>
<b>3. GRADIVA KOT PRIPOMOČKI PRI POUKU</b>	<b>37</b>
3.1. Program za večparametersko odločanje DEXi – priporočila za uporabo	37
3.2. Učni primer: Poročilo za izbiro maturitetnega predmeta	38
3.3. Priporočila za izbor odločitvenega problema in kriteriji za odločitveni model	44
3.4. Navodilo za pripravo poročila o odločitvenem procesu	45
3.5. Priporočila za ocenjevanje in preverjanje znanja	47
3.6. Primeri dreves kriterijev	48
<b>4. POROČILA UČITELJEV</b>	<b>50</b>
<b>5. IZBRANA POGLAVJA PODROČIJ UMETNE INTELIGENCE</b>	<b>59</b>
5.1. O razvoju umetne inteligence	60
5.2. Predstavitve znanja	62
5.3. Odkrivanje znanja v podatkih in podatkovno rudarjenje	66
5.4. Strojno učenje	66
5.4.1. Simbolično induktivno učenje	67
5.4.2. Statistične metode	69
5.5. Nevronske mreže	70
5.6. Mehki sistemi	72
5.7. Evolucijsko računanje in genetski algoritmi	72
5.8. Računalniško zaznavanje	73
5.9. Robotika	75
<b>LITERATURA IN OSTALI VIRI</b>	<b>77</b>

## Predgovor

Pričujoči vodnik je napisan za učitelje srednješolskega predmeta informatika. Predstavlja vsebine in možne oblike poučevanja tehnologij znanja s posebnim poudarkom na organizacijsko–informacijski podpori odločitvenim procesom. Vodnik je namenjen tudi vsem tistim, ki želijo obogatiti vzgojno–izobraževalni proces s sodobnimi informacijskimi tehnologijami. Znani rek, da niti človek niti računalnik sama ne zmoreta tistega, kar zmoreta skupaj, je dovoljšen izziv, da uporabo računalnika pri reševanju problemov vključimo tudi v druge predmete in vsebine.

Tehnologije znanja pomenijo izziv prenovi pedagoškega procesa, saj neposredno omogočajo premik od faktografskih znanj k ustvarjalnemu reševanju problemov z informacijsko komunikacijsko tehnologijo na različnih področjih. Uporaba znanja se poveča na osnovi računalniških predstavitev in postopkov. Posredno in neposredno tako lahko pomagamo mlademu človeku, da se lažje znajde v današnjem vse kompleksnejšem svetu.

Odločanje predstavlja srčiko vsakega upravljanja in vodenja od posameznika preko poslovnih sistemov in države do globalne družbe. Pa vendar zasledimo v naših kurikulumih bore malo o procesu odločanja, njegovi organizaciji in pripomočkih. Morda tudi zato, ker je bilo težko ponuditi vsebinsko in pedagoško primerne elemente. Prav tehnologije znanja, ki jim je posvečen ta vodnik, pa pri pomoči za boljše odločanje ponujajo konkretne rešitve in pripomočke.

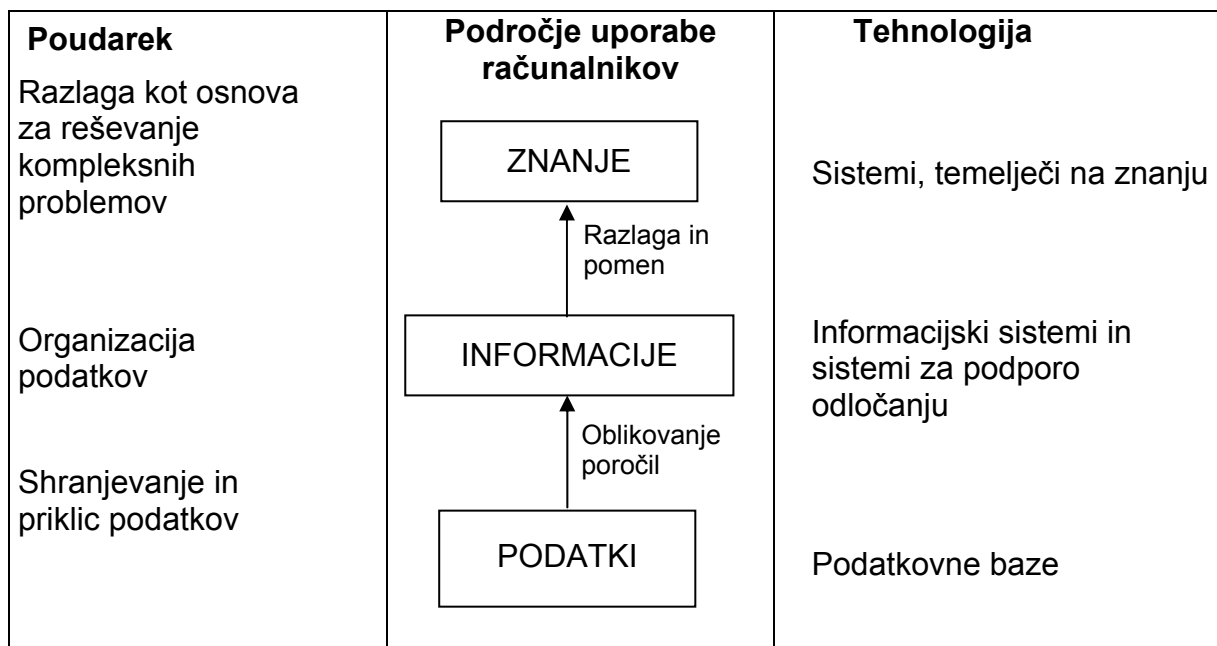
Vodnik je lahko nastal zaradi trdega večletnega dela ljudi, od katerih jih je le nekaj omenjenih v tem besedilu. Lahko rečemo, da se je delo na tehnologijah znanja za šolsko rabo pričelo s programom Računalniško opismenjevanje. Ta je med drugim omogočil tudi izvajanje strateškega projekta Ekspertni sistemi v izobraževanju in posledično razvoj programa DEXi, ki je zato tudi prosto dosegljiv. Za prenos dosežkov v pedagoško prakso pa je odigral odločilno vlogo projekt Uvajanje tehnologij znanja v predmet informatika, zaradi katerega je ta vsebina tudi »zaživela« v razredih.

Alenka Krapež

Vladislav Rajkovič

# Uvod

S *tehnologijami znanja* mislimo katerokoli tehnologijo, s katero si lahko pomagamo pri delu z znanjem: od najpreprostejše, kjer kot sredstvo uporabljamo papir in svinčnik, do sodobnih računalniških tehnologij. Naša pozornost je v skladu z namenom tega vodnika usmerjena k računalniškim tehnologijam. Področje njihove uporabe se je širilo iz obdelave števil na obdelavo konceptov v sedemdesetih letih, v osemdesetih letih pa še na *upravljanje z znanjem*.



## Slika 1: Od podatkov do znanja

Besedna zveza »*upravljanje z znanjem*« označuje proces vzajemnega povezovanja med metodami in tehnikami obdelovanja podatkov z informacijsko in komunikacijsko tehnologijo na eni in ustvarjalnimi in inovativnimi sposobnostmi človeka na drugi strani (GartnerGroup, 1999). Tako kot človek z uporabo različnih mehanskih, optičnih in drugih pripomočkov presega svoje fizične omejitve, lahko na umetni inteligenci temelječi sistemi človeku pomagajo odpravljati slabosti oziroma omejitve pri naših miselnih procesih.

O umetni inteligenci dijaki marsikaj slišijo in preberejo iz sredstev javnega obveščanja. Pogosti so tudi filmi, ki skupaj s preveč poljudnimi članki pravo naravo, predvsem pa možnosti uporabe zamegljujejo, marsikdaj celo mistificirajo. Pravega poduka na tem področju so deležni le študenti, ki imajo v študijske programe vključene predmete z vsebinami s področja razvoja ali uporabe metod tehnologij znanja. Za osnovno razumevanje tehnologij znanja in možnosti uporabe pa ni treba niti poglobljeno znanje računalništva niti poglobljeno znanje matematike, ki ga pridobijo študenti na študijih usmerjenih k informatiki, računalništvu in matematiki. To razumevanje lahko pridobijo že dijaki.

Osnovni cilj srednješolskega splošno-izobraževalnega predmeta informatika je, da dijaki zapustijo srednjo šolo informacijsko pismeni. Informacijska pismenost pa pomeni tudi uporabo informacijsko komunikacijske tehnologije kot podporo

človekovim miselnim procesom. Računalnik nam lahko z uporabo metod umetne inteligence služi na področjih, kjer zaradi narave problemov zgolj procesorska moč sama ne zadošča.

Širše gledano nudi uporaba informacijsko komunikacijske tehnologije (IKT) usposobljenemu učitelju možnost, da lažje sledi dognanjem sodobne psihologije, metodike in didaktike, pa tudi lastne stroke, in spremeni klasično, za današnji čas večinoma že neustrezno učno okolje. Nova vloga, ki jo pri tem dobi učenec, je aktivno sodelovanje v učnem procesu. Tako se tudi poudarek pouka prenese od sedanjega najlažje preverljivega in taksonomsko gledano najnižje vrednotenega znanja na višje taksonomske ravni: od tega, da znajo učenci reševati le probleme, ki so se jih *naučili* reševati, do tega, da se znajo *lotiti* reševanja *novih* problemov. V večini primerov pa je uporaba IKT pri pouku običajno vendarle omejena na didaktično programsko opremo različnih predmetnih področij ali predstavlja samo medij za komunikacijo oziroma vir podatkov.

Namen poučevanja tehnologij znanja, ki so po učnem načrtu predmeta informatika predvidena v izbirnem delu, pa je dijakom predstaviti različne možnosti, ki jih nudijo tehnologije znanja s poudarkom na IKT, in kaj lahko od njih pričakujejo. Namen tega pouka je tudi, da bi dijaki prišli do prave predstave o »mislečih strojih« in s tem povezano popravili precej pogosto napačno prepričanje, da znanje v človeških glavah sčasoma ne bo več potrebno, ali celo, da je učenje ob današnji dostopnosti podatkov praktično nesmiselno.

Vodnik je razdeljen na pet delov. V prvem delu je natančno opisan model poučevanja tehnologij znanja s cilji, predlaganimi oblikami poučevanja in vsebino. V drugem delu je podrobni učni načrt za ta del snovi z možno časovno razporeditvijo ur. V tretjem delu so zbrana gradiva, ki jih lahko uporabimo kot pripomoček pri pouku. V četrtem delu svoje izkušnje predstavljajo učitelji, ki so model poskusno izpeljali v razredih. Peti del pa je dodatek, v katerem smo predstavili nekaj področij umetne inteligence.

# 1. Model poučevanja

Model poučevanja je pripravljen za 25 ur pouka. Sestavljen je iz treh delov. Prvi del je namenjen teoretičnemu spoznavanju različnih vrst tehnologij znanja, drugi del obravnava odločitvene probleme in različne metode za pomoč pri odločanju, v tretjem delu pa dijaki sami izdelajo svoj odločitveni model, pripravijo poročilo in model predstavijo v razredu.

Poudarek pouka je na praktični uporabi tehnologij znanja za reševanje odločitvenih problemov.

## **Operativni cilji pouka o tehnologijah znanja:**

- Dijaki znajo razložiti, kako lahko sodobna IKT prispeva k povečanju človekovih miselnih sposobnosti.
- Razlikujejo med različnimi ravnmi uporabe IKT.
- Poznajo različne vrste tehnologij znanja.
- Spoznajo mesto in vlogo ter osnovne prijeme pri upravljanju znanja.
- Znajo naštet in razložiti faze odločitvenega procesa.
- Znajo uporabljati in spreminjati že izdelan odločitveni model.
- Znajo primerjati različne metode odločanja (ročna preglednica, elektronska preglednica, lupina ekspertnega sistema (ES)).
- Znajo zgraditi večparametrski odločitveni model za preprost odločitveni problem, vrednotiti variante in razložiti rezultat vrednotenja z uporabo računalniškega programa DEXi.

## **1.1. Vsebine poučevanja in pristopi k poučevanju**

Vsebine teoretičnega dela pouka tehnologije znanja pri predmetu informatika so:

1. ravni uporabe IKT,
2. procesiranje informacije pri človeku,
3. pregled različnih tehnologij znanja,
4. proces odločanja in različni prijemi pri odločanju,
5. uporaba računalniških programov kot pomoč pri odločanju,
6. gradnja odločitvenih modelov z razlago primerov odločitev.

V nadaljevanju so predstavljene izbrane vsebine. Pri vsaki vsebini so na začetku zapisani cilji, ki jih želimo doseči, sledijo didaktično metodična navodila za to vsebino, zatem vsebina sama. Vsebine in načini dela so prirejani za starost učencev med 16 in 18 leti. Izjema je formalna predstavitev odločanja, ki je namenjena samo učitelju oziroma dijakom, ki želijo ta del znanja tudi teoretično poglobiti.

### **1.1.1. Ravni uporabe IKT**

*Cilj prvega dela vsebin je, da dijaki spoznajo, da je učinek uporabe IKT večji, čim večje je zanje o možnostih uporabe IKT in bolj ko je uporaba IKT zavestna.*

### Didaktično metodična navodila

Ravni uporabe IKT je smiselno izpeljati ob razgovoru o najrazličnejših konkretnih uporabah IKT, ki jih navedejo dijaki. Z iskanjem skupnih lastnosti posameznih uporab pripelje učitelj do razvrstitev v opisane štiri ravni in jih poimenuje.

#### Vsebina:

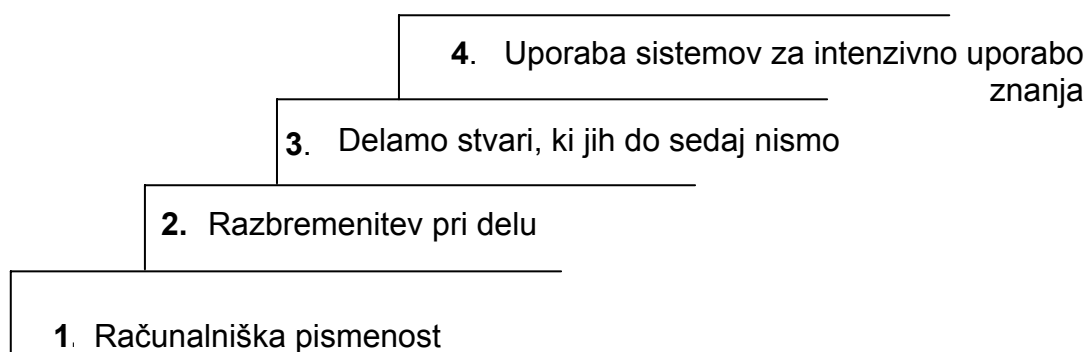
Ravni uporabe IKT:

**Računalniška pismenost.** Kdor je računalniško pismen, zna rokovati z IKT tako, da samostojno uporablja osnovne uporabniške računalniške programe, tudi nove. Pri tem obvlada delo z datotekami: od iskanja do stiskanja in prenašanja.

**Razbremenitev pri delu** je raven, ki jo dosežemo, ko osnovno rokovanje z IKT tako dobro obvladamo, da nam samo po sebi ne predstavlja napora. Potem predstavlja vsaka smiselna uporaba računalnika razbremenitev pri delu.

**Delamo stvari, ki jih do sedaj nismo.** Računalnik nam zaradi svoje hitrosti in drugih lastnosti omogoča, da delamo stvari, ki jih do sedaj nismo zmogli. Kot primer navedimo: preverjanje črkovanja, preverjanje pravilnosti (električnih) shem, preoblikovanje slik, pregledovanje množice podatkov po svetu, analiza podatkov, analiza kaj-če, reinženiring proizvodnje ipd.

**Uporaba sistemov za intenzivno uporabo znanja** predstavlja najvišjo raven uporabe IKT. Za uporabo teh sistemov potrebujemo poleg računalniške pismenosti tudi ustvarjalnost. Primeri uporabe teh sistemov so: ekspertni sistemi, inteligentna analiza podatkov, pomoč pri odločanju ipd.



**Slika 2: Ravni uporabe IKT**

### **1.1.2. Procesiranje informacije pri človeku**

*Za razumevanje prednosti in pomanjkljivosti človekovih miselnih sposobnosti in kako z ustrezno podporo prednosti povečati, pomanjkljivosti pa omiliti, je smiselno razmišljati, kako človek procesira informacije.*

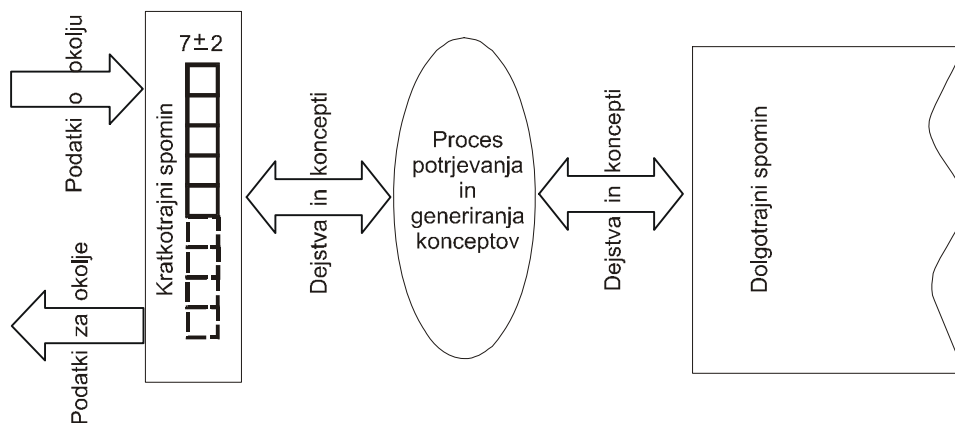
#### Didaktično metodična navodila

Pomembno je, da dijaki sami povedo, kar že vedo o tem, kako človek sprejema podatke iz okolice, jih procesira, pomni in kaj je pravzaprav tisto, čemur pravimo

znanje. Med razgovorom z dijaki učitelj gradi sliko (na tabli ali s prosojnicami) po širše sprejetem modelu človekovega procesiranja informacije. V pomoč je lahko slika 3. Smiselno je povedati dijakom, da obstajajo tudi drugi modeli. Učitelj poudari možnosti, ki jih nudijo informacijske rešitve za zmanjševanje slabosti in povečevanje dobrih strani človekovih miselnih procesov.

### Vsebina

Preko čutil (senzorjev) sprejemamo zunanje dražljaje – podatke o okolju. Človek ima po trajanju »zapisa« in načinu doseganja podatkov v spominu dve vrsti spomina, ki ju poimenujemo kratkotrajni spomin in dolgotrajni spomin.



**Slika 3: Model človekovega procesiranja podatkov**

V skladu s spoznanji psiholoških raziskav se večina strinja, da gredo podatki iz senzornega sistema najprej v **kratkotrajni spomin**. Ta ima majhno kapaciteto (obseg neposrednega pomnjenja):  $7 \pm 2$  enoti (enota je tu mišljena lahko kot beseda, številka, simbol, slika, skratka »košček«, ki si ga je treba zapomniti). Vanj tudi prikličemo podatke iz dolgotrajnega spomina, ko rešujemo kako nalogo. Prednost kratkotrajnega spomina je v tem, da lahko človek shranjene enote zelo hitro sočasno obdeluje. Podatki v kratkotrajnem spominu pa hitro zbledijo. Čas pomnjenja v kratkotrajnem spominu je od nekaj trenutkov do nekaj deset sekund, če jih ne obnavljamo.

**Dolgotrajni spomin** ima zelo veliko kapaciteto, zasledimo številko  $10^{10} - 10^{15}$  bitov. Po nekaterih prepričanjih (Russel, 1990) si človek zapomni vse, kar je kadarkoli doživel. Težje pa to ponovno prikliče v zavest. Človeški dolgotrajni spomin je organiziran asociativno, po vsebini. Vsebino določajo **vodilni koncepti**, lahko bi jim rekli **ključi**. Če smo npr. pri konceptu varstva okolja, nas skupaj s podatki iz neposrednega okolja (npr. o sajah na balkonu) usmeri na varstvo zraka. Koncept varstva zraka pa naprej do informacij v zvezi s toplarno. Podatki se med seboj povezujejo v **asociacijske mreže**, priklic podatka pa je odvisen od tega, ali bomo našli ustrezno asociacijo na ta podatek. Človek si torej zapomni podatek, ko ga poveže z že zapomnjenimi, in več ko si zapomnimo, lažje si bomo zapomnili nove reči.

Kognitivne raziskave kažejo, da imamo v dolgotrajnem spominu več različnih sestavin oz. struktur. S stališča učenja je zanimiva razlika med tako imenovanim *epizodičnim spominom* in *semantičnim spominom* ter *obstoj spominskih shem*.



**Epizodični spomin** je spomin na razne dogodke v življenju v zaporedju, kot so se dogajali. **Semantični spomin** vsebuje besedno simbolno znanje, najverjetneje v obliki pojmovnih mrež. Za uspešno zapomnitev in priklic je treba podatke organizirati v hierarhičen ali kak drug sistem. Čim jasnejše in stabilnejše so spominske strukture, tem lažja sta zapomnitev in njihov priklic. Zapomnitev in priklic se izboljšata, če povezujemo epizodični in semantični spomin. **Spominske sheme** so zbirke splošnega prejšnjega znanja: kakšno je zaporedje dogodkov, kakšni so odnosi med njimi, kaj lahko v kaki situaciji pričakujemo. Sheme so splošnejše od pojmov in so nekakšni paketi znanja ali scenariji, ki nam pomagajo osmisliti dogodke in pojave ter usmerjati akcije (Rumelhart, cit. po Baretič Požarnik, 2000). Obstaja še več drugih teorij o načinu pomnjenja in priklica, kot npr. scenariji in mentalni modeli ali hologrfska teorija spomina.

Med obema vrstama spominov potekajo različni **proces**i. Tak proces je na primer **ponavljanje**, s katerim utrjujemo povezave med pojmi. Elaboracija je **dodajanje pomena** oziroma konstruiranje razumevanja novih dejstev in zakonitosti s pomočjo obstoječega znanja. V procesu **organizacije** nove pojme in zakonitosti umeščamo v že obstoječe spominske strukture in s tem potrjujemo stare koncepte in predstave. Lahko pa že obstoječe spominske strukture reorganiziramo in tako generiramo nove. Gre za to, da nekatere stvari dodatno premislimo, jih drugače uredimo in tako ustvarjamo novo znanje. Več o tem lahko preberete v knjigi Anite Voolfolk Pedagoška psihologija.

S kratkotrajnim spominom, miselnimi procesi in delom dolgotrajnega spomina lahko človek zavestno upravlja. Med spanjem, pa tudi sicer, potekajo tudi nezavedni miselni procesi.

S pomočjo IKT lahko zmanjšamo pomanjkljivosti in povečamo prednosti človeških možganov. Zavedati se moramo, da je človeški kratkotrajni spomin omejen. Zato morajo biti vhodni podatki pregledno organizirani. Podporo dolgotrajnemu spominu pa lahko nudimo s sistemi, ki temeljijo na bazah znanja in sistematičnem pregledovanju.

### **1.1.3. Pregled različnih tehnologij znanja**

*Dijaki spoznajo v tem delu osnovne pojme, razvoj, vrste, namen in smeri razvoja umetne inteligence.*

#### **Didaktično metodična navodila**

Za motivacijo, predvsem pa zaradi večje nazornosti predstavitve pomena, ciljev, vrst in različnih namenov umetne inteligence, so ure, namenjene tej tematiki, sestavljene iz kratkih video posnetkov, ki jih dijaki skupaj z učiteljem sproti komentirajo. Posebej je pomembno, da učitelj poudari različnost pristopov in rešitev.

Smiselno je, da po uvodni uri predstavitve umetne inteligence in po kratkem pregledu glavnih področij, dijaki za domačo nalogo poiščejo primere uporabe umetne inteligence oziroma tehnologij znanja. Pri naslednji uri o tem poročajo v razredu.

## Vsebina

*Kot znanstvena disciplina se umetna inteligenca (UI) ukvarja z razvojem tehnik, metod in arhitektur za reševanje logično zapletenih problemov, ki bi jih bilo težko ali celo nemogoče rešiti s klasičnimi metodami (Luger, 2002).*

Področje umetne inteligence je zelo razvejano. Razvijati se je začelo v sredini dvajsetega stoletja z namenom zgraditi inteligen ten umeten sistem, ki bi lahko z učenjem presegel človekove intelektualne zmožnosti. V realnosti pa se je pokazalo, da je celo danes tak sistem praktično nemogoče zgraditi, čeprav še vedno obstajajo zagovorniki prvotne ideje umetne inteligence. Omejitve običajno izvirajo iz *nepoznavanja* lastnih, to je človekovih miselnih procesov. Poleg tega se razhajajo mnenja tudi o tem, kaj inteligenca pravzaprav sploh je.

**Lastnosti**, ki jih v splošnem pripisujemo **intelligentnim sistemom**, so:

- sposobnost znati se v novih situacijah,
- sposobnost sklepanja,
- sposobnost pridobivanja in uporabe novega znanja,
- sposobnost zaznavanja in delovanja v fizičnem svetu
- sposobnost generiranja novih konceptov
- ...

Ena od možnih definicij inteligence, ki pa ni splošno veljavna, je

*Intelligenca pomeni sposobnost prilagajanja okolju in reševanja problemov.*

Pojmi **učenje**, ki v sami definiciji nastopa kot prilagajanje, **znanje** in **intelligenca** so močno povezani. Za reševanje problemov je nujno znanje in njegova uporaba (Kononenko, 1997).

Znanje mora biti ustrezno predstavljeno tako s stališča stroja kot tudi človeka, saj morata oba v procesu obvladovanja znanja sodelovati (Rajkovič, 2001). Kako opisati (vse potrebno) splošno znanje, zaenkrat še niso ugotovili (Nilsson, 1998).

V začetnem obdobju UI (v 60-ih letih 20.stoletja) je bil poudarek na pisanju programov za reševanje splošnih problemov. Programi so igrali šah, damo, dokazovali matematične teoreme. Žal se je izkazalo, da so bila pričakovanja prevelika. To področje UI pa je vseeno 1997 doživelo velik uspeh. Program Deep blue je premagal takratnega svetovnega šahovskega prvaka Garija Kasparova.

V 70-ih letih 20. stoletja so prišli snovalci UI do spoznanja, da človeku pri reševanju splošnih problemov bolj kot uporaba algoritmov, služi velika količina splošnega in specialističnega znanja. Na osnovi tega so nastali **ekspertni sistemi**. To so sistemi, ki temeljijo na ozko specializiranem znanju. Namenjeni so reševanju specifičnih problemov iz realnega sveta. Kot pomoč človeku pa so postali tudi ekonomsko zanimivi.

Ekspertni sistemi znajo pojasniti razloge oziroma način sklepanja za določen zaključek (rezultat oz. odločitev) korak za korakom. Tak način komuniciranja omogoča uporabniku, da uvidi napačen korak v računalnikovem sklepanju ali pa uvidi lastno napako.

Razvili so tudi programske jezike, namenjene pisanju sistemov umetne inteligence. Primer sta LISP in prolog (Bratko, 1982).

Nabor področij UI se je širil. Razumevanje napisanega besedila so raziskovali kot **razumevanja naravnega jezika**, podpodročje tega pa je **prepoznavanje in sinteza govora**. Podobno se **računalniški vid** ukvarja s prepoznavanjem in generiranjem slik. **Robotika** se je razvila iz prizadevanj zgraditi stroj, ki bi se gibal podobno kot človek. Do razvoja **strojnega učenja** je prišlo zaradi prizadevanj, da bi se baze znanja avtomatsko dopolnjevale in tako prilagajale okolju. Velike količine shranjenih podatkov so pospešile razvoj tehnik **iskanja znanja v podatkih**.

Veliko število podpodročij UI je naravni odgovor na kompleksnost in obseg naloge ustvariti umetno inteligenco. Med njimi so močne povezave in medsebojni vplivi, nova podpodročja pa še nastajajo.

Danes s pridom uporabljamo marsikatera odkritja na področju umetne inteligence v praksi.

*Področja, s katerimi se danes ukvarja UI, so predvsem:*

- *predstavitev znanja,*
- *razvoj ekspertnih (na znanju temelječih) sistemov,*
- *strojno učenje,*
- *računalniško zaznavanje,*
- *razumevanje naravnega jezika,*
- *igranje iger (šah, dama ...),*
- *robotika,*
- *avtomatsko sklepanje in dokazovanje izrekov,*
- *logično programiranje,*
- *kvalitativno modeliranje,*
- *hevristično reševanje problemov,*
- *kognitivno modeliranje*
- ...

Nekaj več lahko o pojmu inteligenca, o razvoju UI in kratka pojasnila o nekaterih področjih UI preberete v zadnjem poglavju vodnika. Več o ekspertnih sistemih pa je zapisano v poglavju o odločanju.

Prav področje odločanja je eden od primerov uspešne uporabe metod umetne inteligence.

#### 1.1.4. Proces odločanja in različni prijemi k odločanju

*Cilj tega in naslednjih dveh sklopov je, da dijaki spoznajo osnove dobrega odločanja z uporabo ustrezne tehnologije, svoje znanje pa utrdijo ob gradnji in vrednotenju lastnega večparametrskega odločitvenega modela ter analizi variant.*

##### Didaktično metodična navodila

Poglavje o odločanju je tema, ki se dotika vsakdanjega življenja. Učitelj naj dijake povpraša, o čem vse so se tisti dan/teden odločali in zakaj so se odločili za prav tisto varianto in ne za kakšno drugo. Na kakšne probleme in težave so pri tem naleteli. Katera njihova odločitev je najbolj zaznamovala njihovo življenje, kaj vse in kdo vse je vplival na njihovo odločitev, ali bi se ponovno enako odločili, če ne, kaj je razlog za drugačno odločitev. Kaj menijo, da je pomembno za dobro odločitev.

Ob takem razgovoru lahko učitelj naveže izkušnje dijakov na vsebino poglavja.

##### Vsebina

Odločanju se v življenju praktično ne moremo izogniti. Odločitveni problemi so zelo različni in posegajo v vsakdanje zasebno in poslovno življenje. Posledice odločitev so prav tako zelo različne. Nekaterih skorajda ne čutimo ali pa se v kratkem času izgubijo, druge pa vplivajo na nas celo življenje. *Cilj vsakega odločanja je »prava odločitev«, odločitev, ki bo imela za odločevalca najugodnejše posledice* (Hammond et al. 2000).

Problem odločanja je tako pomemben, da se z njim ukvarja vrsta znanstvenih področij in disciplin, tako družboslovnih kot naravoslovnih. Prva znana pisna navodila, kako se odločati, segajo v četrto stoletje pred našim štetjem.

Odločanje je proces, pri katerem izbiramo med več možnostmi - variantami. Izbrana varianta naj čimbolj ustreza danim ciljem. Vrstni red zaželenosti variant določa tako imenovana preferenčna relacija »imam raje«. Ta je odvisna od preferenčnega znanja odločevalca oz. odločevalcev, ki ni pogojeno le z njegovim strokovnim znanjem, ampak tudi z njegovimi vrednotami. Tak primer je lahko izbor počitnic. Variante so v tem primeru: počitnice v gorah, ob morju, zdravilišču, popotovanje itd.

##### **Odločamo se lahko na različne načine:**

- *Intuitivno* (to je odločanje, pri katerem ne znamo razložiti, kako to počnemo) ali *sistematično* (organiziranje podatkov in znanja).
- *Individualno* ali *skupinsko*.
- O *racionalnem* odločanju govorimo takrat, ko izmed vseh možnih variant izberemo tisto, ki je najbolj zaželena, o *iracionalnem* odločanju pa takrat, ko je odločitev zaradi raznih omejitev na videz brezmiselna (na primer v trenutku odločanja ne upoštevamo vseh razpoložljivih parametrov, ki vplivajo na kakovost odločitve).

Vzrokov za težave pri odločanju o določenem odločitvenem problemu je več:

- pri odločanju navadno ne poznamo vseh dejavnikov, ki vplivajo na odločitev,
- variante, med katerimi se odločamo, niso natančno določene,

- za natančno študijo odločitvenega problema in variant bi zmanjkalo časa,
- vsi podatki niso vedno dosegljivi,
- cilji različnih odločevalcev so lahko različni.

Poleg tega pa obstaja vrsta možnih dejavnikov, ki odločanje ovirajo. Med **pasti pri odločanju** štejemo (Rajkovič, 1991):

**Spreminjanje odločitvene situacije**, ko se med odločanjem, npr. pri nakupovanju nekega predmeta po celodnevnem iskanju, raje odločimo za dražjo varianto, kot da bi se vrnili na drugi konec mesta in kupili optimalno. Na odločitev je vplival nov kriterij – utrujenost.

**Majhne razlike, ki se seštevajo v velike**, ko se npr. cena za avto s posameznimi dodatki postopno malo spreminja, razlika med končno in začetno ceno pa je občutna.

**Dve varianti nista nikoli popolnoma enaki**; četudi sta varianti na prvi pogled enaki, lahko že neznaten dodatek, ki nima povezave z odločitveno situacijo, neracionalno vpliva na odločitev. Zato se je treba potruditi poiskati parametre, ki so povezani z vsebino.

Primer za to se skriva v naslednji zgodbi. Predpostavimo, da smo na žrebanju dobili nagradno potovanje v eno izmed svetovnih prestolnic Tokio ali New York. Odločiti se moramo, kam bomo šli. Vzemimo, da nam je popolnoma vseeno, kje preživimo ta teden. Za odločitev bi najraje metali kovanec. Torej je za nas varianta A enaka varianti B.

Nato nam nekdo ponudi še bonboniero v dar. Dobimo jo le, če potujemo v Tokio. Bonboniera ima brez dvoma neko pozitivno vrednost. S tem je odločitev jasna. Gremo v Tokio. Vendar se s takim razlogom le težko strinjamo, saj bonboniera nima prave povezave s samo odločitvijo.

Problem ni v tem, da bonboniera ne bi imela svoje vrednosti. Večina izmed nas bi raje imela bonboniero kot ne. Stvar je v tem, kako vrednost zavisi od konteksta, v katerem se pojavi. V tej situaciji je bonboniera nepomembno povezana z odločitveno situacijo, v drugih odločitvenih situacijah pa je lahko pomembna.

**Subjektivna verjetnost** povzroči, da pogosto precenimo pojav dogodka, ki ima majhno verjetnost in podcenimo pojav dogodka, ki ima veliko verjetnost.

Kot primer navedimo pošteno igro z enakimi kockami. V igralnici v zadnjih 100 metih ni padla vsota pik 7 na kockah. Zato igralec stavi, da bo padla v prihodnjem metu. Vendar je verjetnost, da bodo kocke padle na katerokoli vrednost vedno enaka ne glede na to, kako so padale prej.

Često predvidevamo dogodke, ki se že dolgo niso zgodili in bi se prav zato morali. Radi precenimo verjetnost zelenih in podcenimo verjetnost nezaželenih dogodkov.

Marsikdaj se odločamo v negotovih situacijah, ki izvirajo iz opisa variant, preferenčnega znanja odločevalca, predvidevanja bodočih dogodkov.

## SISTEMI ZA PODPORO ODLOČANJU

Pri racionalnem in sistematičnem odločanju si lahko pomagamo s **sistemi za podporo odločanju** (angl.: Decision Support Systems, s kratico: DSS). Ko govorimo o DSS, imamo v mislih sisteme, ki uporabljajo informacijsko tehnologijo. Praviloma gre za sisteme za intenzivno uporabo znanja, seveda pa si lahko pomagamo tudi z enostavnejšimi orodji. DSS uporabljamo, da nam olajšajo trud v odločitvenem procesu. DSS pomagajo preseči človekove omejitve pri procesiranju informacij, omogočajo sistematizirano odločanje in tako precej pripomorejo, da se izognemo pastem pri odločanju.

Nekateri uvrščajo med tehnologije, ki jih uporabljajo sistemi za pomoč pri odločanju, prav vse od ročnih metod, elektronskih preglednic, preko baz podatkov, do ekspertnih sistemov.

Kot primer uporabe navajamo dva DSS:

DSS za izbiro primernih cestnih povezav lahko uporablja bazo geografskega informacijskega sistema, upošteva naše želje in omejitve, ki nastanejo kot posledica vremena in drugih prometnih težav, ter nam postreže s predlogi možnih poti, ki so ovrednoteni po kilometrih, predvidenem času in še čem.

DSS za pomoč pri odločitvah v tekstilni industriji pri barvanju tkanin za določeno vrsto tkanine in predvideno temperaturno obstojnost predlaga različne kombinacije dosegljivih barvil in drugih kemikalij.

Sam proces odločanja lahko opišemo tudi formalno.

### FORMALNA DEFINICIJA ODLOČANJA:

Pri odločanju nastopa:

*množica variant*  $A = \{ a_1, a_2, a_3, \dots, a_n, \dots \}$

*preferenčna relacija* (»imam raje«)  $P$

Preferenčna relacija uredi množico  $A$  po zaželenosti, ustreznosti ali koristnosti.

Če imamo izmed dveh elementov množice  $A$ ,  $a$  in  $b$ , prvega rajši kot drugega, to zapišemo:

$a P b$ .

V odločitveni praksi skušamo vpeljati *funkcijo koristnosti* oz. *zaželenosti*. Funkcija  $v(a)$  izmeri stopnjo zaželenosti variante tako, da za vsak par  $a, b$  iz  $A$  velja:

$a P b \leftrightarrow v(a) > v(b)$


Varianti, ki jo imamo raje kot drugo, pripišemo večjo stopnjo (vrednost) zaželenosti.

Racionalna odločitev (slika 4) je izbira variante  $a_k$ , tako da je

$V(a_k) = \max (v(a): a \in A)$

Pri običajnih odločitvenih modelih ocenjujemo variante po več lastnostih ali parametrih. V takih primerih govorimo o **večparametrskem** odločanju. V realnosti srečamo odločitvene primere z nekaj (na primer nakup računalnika) do nekaj deset in

več parametrov, kadar gre za kompleksne odločitvene situacije. To so take odločitvene situacije, ki imajo veliko med seboj zapleteno povezanih elementov (na primer izbira lokacije za odlagališče jedrskih odpadkov).



**Slika 4: Varianta  $a_4$  predstavlja racionalno odločitev, saj ima največjo stopnjo zaželenosti.**

#### **Formalna definicija večparametrskega odločanja:**

*V splošnem večparametrskem odločanju nastopa:*

*Množica variant  $A = \{a_1, a_2, a_3, \dots, a_n, \dots\}$*

*Preferenčna relacija  $P$*

*Množica parametrov  $X = \{x_1, x_2, x_3, \dots, x_m\}$*

$$x_i : A \rightarrow D_i,$$

*$D_i$  so zaloge vrednosti posameznih parametrov.*

*Vsako varianto  $a$  iz množice  $A$  opišemo z vektorjem vrednosti parametrov:*

$$a = x_1(a), x_2(a), x_3(a), \dots, x_n(a).$$

Pri tem ne smemo pozabiti, da gre le za opis, s katerim lahko varianto bolj ali manj dobro predstavimo. Vektorski opis variante po izbranih kriterijih je le model variante, ki je namenjen lažjemu ocenjevanju.

*Preferenčno relacijo  $P$ , ki uredi množico  $A$  po zaželenosti oziroma koristnosti, nadomestimo s funkcijo koristnosti.*

*Funkcijo koristnosti  $v: A \rightarrow D$  nadomestimo s funkcijo,*

$$v_x: D_1 \times D_2 \times D_3 \times \dots \times D_n \rightarrow D$$

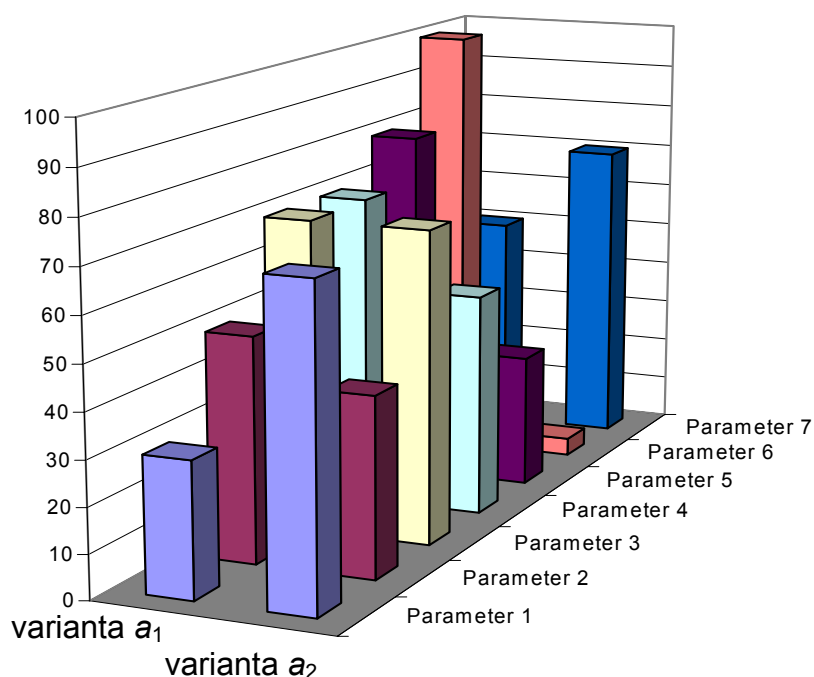
*kjer je  $v_x$  definirana nad domeno, ki jo predstavlja kartezični produkt domen posameznih parametrov in je  $D$  njena zaloga vrednosti.*

*Pri tem predpostavljamo, da je*

$$v(a) = v_x(x_1(a), x_2(a), x_3(a), \dots, x_n(a))$$

*Funkcija koristnosti predstavlja »združeno« meritev koristnosti po vseh parametrih. Je kriterijska funkcija, s katero določamo koristnost variant na osnovi posameznih parametrov in njihove povezave (Rajkovič, 1987).*

*Preprosteje povedano je **funkcija koristnosti** tista funkcija, ki iz vrednosti parametrov (rečemo jim tudi atributi ali kriteriji) izpelje oceno variante (njeno koristnost).*



**Slika 5: Večparametrsko odločanje (dve varianti, ki ju ocenjujemo po sedmih parametrih)**

Pri večparametrskem odločanju predpostavljamo opisljivost variant z vrednostmi parametrov in obstoj funkcije koristnosti.

	varianta $a_1$	Variant $a_2$
Parameter 1	30	70
Parameter 2	50	40
Parameter 3	70	70
Parameter 4	70	50
Parameter 5	80	30
Parameter 6	100	4
Parameter 7	50	70
Ocena variant	450	334

**Tabela 1: V najpreprostejšem primeru vrednosti parametrov posamezne variante kar seštejemo. Če tako postopamo v našem primeru, je boljša odločitev variant  $a_1$ .**



### **1.1.5. Uporaba različnih pripomočkov pri odločanju**

*Cilj tega dela učnega procesa je, da dijaki spoznajo osnovne pristope in pripomočke za upravljanje z odločitvenim znanjem. Spoznajo zgradbo ekspertnega sistema, ki jo razlikujejo od lupine ekspertnega sistema. Razložiti znajo, kaj je baza znanja in kako jo zgraditi.*

#### **Didaktično metodična navodila**

Dijaki spoznajo tri različne odločitvene metode. Smiselno je, da učitelj najprej predstavi odločitveno metodo, potem pa z njo skupaj z dijaki zgradi na tablo (prosojnico) odločitveni model, najbolje za isti odločitveni problem. Odločitveni problem mora biti ustrezno didaktično izbran, tako da se jasno vidi kakovostna rast podpore odločanju: od »ročne metode« Abacon, preko elektronske preglednice do lupine ekspertnega sistema.

Za vsako od metod dijaki s pomočjo učitelja poiščejo in zapišejo dobre in slabe lastnosti. Pri tem mora učitelj paziti, da poišče in omeni tudi primere, ki se jih zaradi različnih vzrokov lažje vrednoti s preprostejšo odločitveno metodo.

#### **Vsebina**

Sistematično reševanje odločitvenega problema praviloma bistveno pripomore k boljši odločitvi. Pogoji za dobro odločanje sta temeljito poznavanje problema in natančno določen cilj, ki ga želimo z odločitvijo doseči.

Z uporabo različnih pripomočkov pri odločanju si proces odločanja lahko močno olajšamo. Z njihovo pomočjo o problemu sistematično razmišljamo.

Kot primer navedimo tri metode:

- Abacon sodi med najpreprostejše metode. Edina potrebna »tehnologija« sta papir in svinčnik.
- Uporaba elektronske preglednice (na primer Excel) in
- uporaba lupine ekspertnega sistema za gradnjo odločitvenega modela (na primer DEX (Bohanec, Rajkovič 1995)).

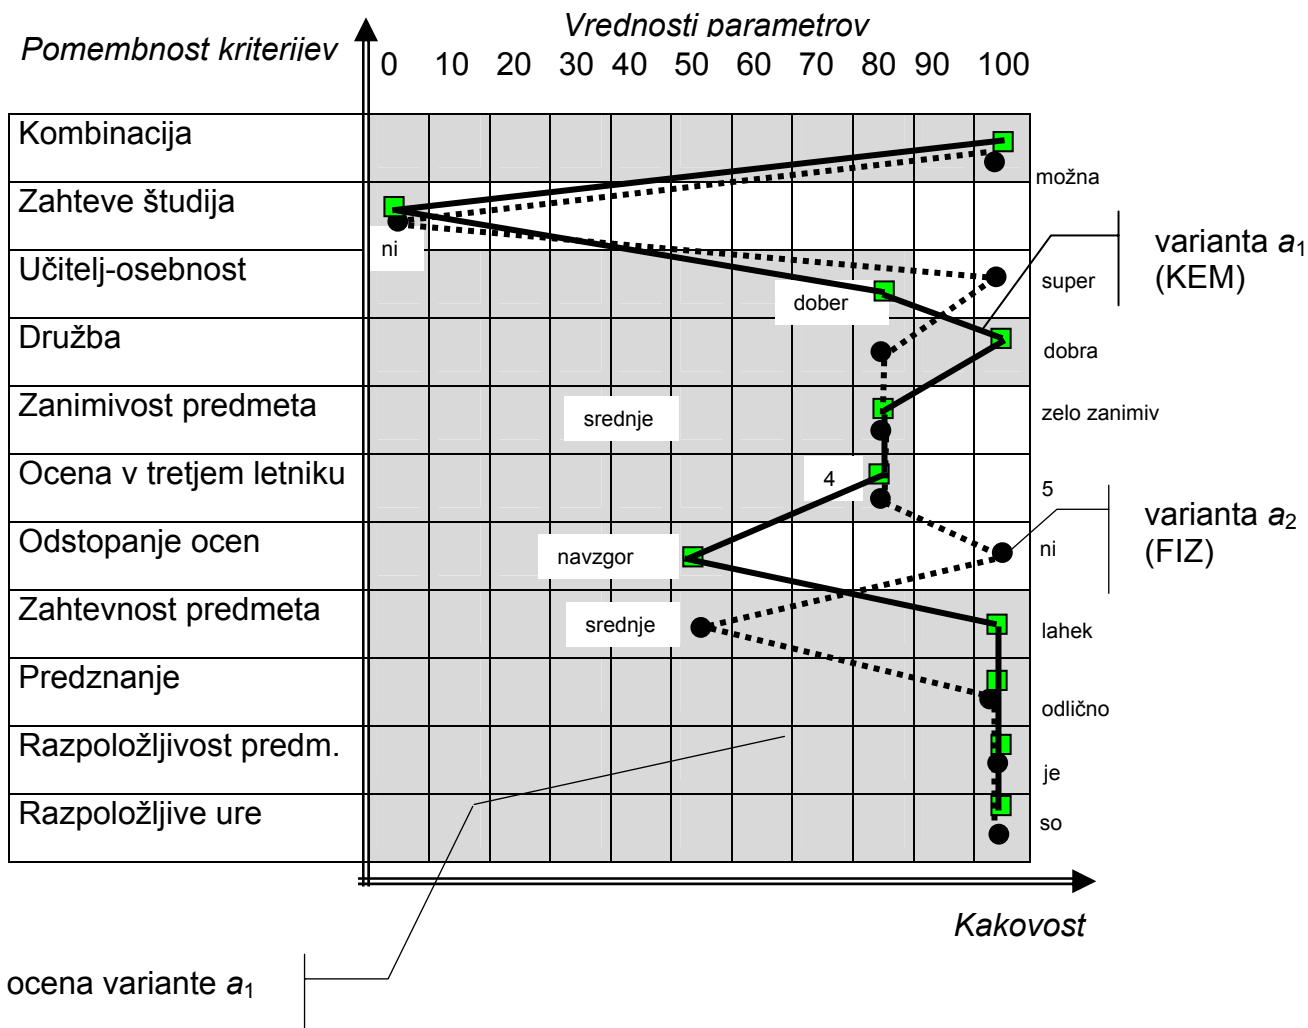
Računalniška tehnologija nudi učinkovito podporo pri odločanju in tudi iskanju ustreznih podatkov, ki koristijo dobremu odločanju.

## OPIS METODE ROČNE PREGLEDNICE

Pri metodi Abacon uporabljamo obrazec z dvema stolpcema. V levi stolpec obrazca vpisujemo parametre, ki vplivajo na odločitev, v desni pa vrednosti parametrov. Osnovne merske lestvice so v naravnih enotah za posamezni parameter. (npr. moč v vatih, površina v m<sup>2</sup>, kakovost ocenjujemo opisno: dobro, srednje ... ali odlično, sprejemljivo, nesprejemljivo ...)


Vrednosti parametrov morajo biti urejene od najslabših do najboljših, od leve proti desni. Merske lestvice pa lahko poenotimo tako, da pripišemo parametrom vrednost od 0 do 100, pri čemer je 0 najslabša ocena za parameter, 100 pa najboljša. Pomagamo si s pripravljeno mrežo v desnem stolpcu obrazca.

Pri odločanju si pomagamo pri tej metodi tako, da v levi stolpec vpišemo parametre po pomembnosti, kakor vplivajo na odločitev. Najpomembnejši parameter je na vrhu. Variante opišemo z označevanjem vrednosti parametrov v desni stolpec. Nato povežemo točke, ki predstavljajo vrednosti parametrov posamezne variante. S tem dobimo za vsako varianto po eno krivuljo. Ocena variante je sorazmerna s površino levo od krivulje. Varianta z največjo površino je najugodnejša.



**Slika 6: Primer odločitvene metode za izbiro maturitetnega predmeta z ročno preglednico**





**Slika 7: Strukturni krožni diagram uteži kriterijev**

Pogosto nas zanima, kako sprememba vrednosti enega ali več parametrov kake variante vpliva na spremembo njene končne ocene. Tako lahko v procesu odločanja eksperimentiramo z različnimi vrednostmi variant pa tudi z različnimi vrednostmi uteži. Pogledamo, kakšne posledice imajo morebitne spremembe na končno odločitev. Ob tem razmišljamo o spremenjenih scenarijih, ki nas lahko vodijo do boljših in zanesljivejših rešitev. V našem primeru ima dijak možnost, da oceno predmeta v tretjem letniku še popravi. Samo ta sprememba pomeni, da je končna ocena variante fizika boljša kot končna ocena variante kemija. Premislek je seveda stvar odločevalca, kako pa sprememba vpliva na končni rezultat, se avtomatsko izračuna v modelu narejenem z elektronsko preglednico. Takemu postopku pravimo **analiza kaj-če**.

Št.	Utež	Kriterij	varianta $a_1$ (KEM)		varianta $a_2$ (FIZ)	
			$v$	$v * w$	$v$	$v * w$
1.	20	Kombinacije	100	2000	100	2000
2.	15	Zahteve študija	0	0	0	0
3.	12	Učitelj-osebnost	80	960	100	1200
4.	10	Družba	100	1000	80	800
5.	10	Zanimivost predmeta	80	800	80	800
6.	10	Ocena v tretjem letniku	100	1000	80	800
7.	8	Odstopanje ocen	50	400	100	800
8.	5	Zahtevnost predmeta	100	500	50	250
9.	5	Predznanje	100	500	100	500
10.	4	Razpoložljivost predmeta	100	400	100	400
11.	1	Razpoložljive ure	100	100	100	100
$\Sigma$	100	<b>Ocena variante</b>	910	<b>7660</b>	890	<b>7650</b>

**Tabela 3: Izračun ocene variant v primeru, če dijak izboljša oceno predmeta kemija**

## **OPIS METODE ODLOČANJA S POMOČJO METOD UMETNE INTELIGENCE**

V učnem procesu smo za gradnjo odločitvenega modela uporabili računalniški program DEXi (Rajkovič, Bohanec, 1999), ki je v marsičem podoben lupinam ekspertnega sistema.

DEXi je računalniški program za večparametrsko odločanje. Razvit je bil na osnovi posebne lupine ekspertnega sistema za večparametrsko odločanje DEX, ki deluje v okolju DOS, medtem ko DEXi teče v okolju Windows. Podpira kvalitativne merske lestvice, funkcije koristnosti so predstavljene s pravili tipa če-potem v obliki tabel. Baza znanja je odločitveni model.

Odločanje s pomočjo programa DEXi poteka tako, da najprej zgradimo model. Ta je sestavljen iz drevesa kriterijev (atributov, parametrov) in odločitvenih pravil. Liste drevesa kriterijev predstavljajo osnovni parametri, ki vplivajo na odločitev. Z odločitvenimi pravili pa določamo vrednosti parametrov v vozliščih drevesa vse do korena, ki predstavlja končno oceno predmeta odločanja. Z odločitvenimi pravili lahko upoštevamo, da je vpliv nekega parametra na končno oceno variante odvisen od njegove vrednosti, kar pomeni, da uteži niso konstante.

Zalogo vrednosti parametrov običajno sestavljajo naravne vrednosti parametrov. Smiselno jo je tako zmanjšati, da ostaja odločitveni model dovolj občutljiv in razlikuje bistvene razlike med variantami. Opis variant v realni odločitveni situaciji pogosto ni popoln. Dogodi se, da vseh podatkov ne dobimo, so nenatančni ali verjetnostnega značaja. Ne glede na to računalniški program DEXi variante ovrednoti. Rezultat pa je lahko podan tudi na intervalu. To je odvisno od vpliva nedoločenega parametra na končno oceno variante.

Interpretacija rezultatov, ki jo mora narediti človek, poteka od korena preko vozlov do listov odločitvenega drevesa. Za bolj nazorno predstavo pa lahko z DEXi-jem naredimo različne grafične predstavitve: od primerjav variant po posameznih parametrih, do radarskih diagramov, kjer lahko grafično primerjamo med seboj variante po več parametrih.

Uporaba te metode je prikazana v poglavju Gradiva: Učni primer.

## **PRIMERJAVA POSAMEZNIH METOD**

Glede na vrsto odločitvenega primera je bolj primerna ena ali druga metoda.

Za enostavne odločitvene probleme je ročna metoda Abacon zaradi preprostosti uporabe bolj primerna kot metodi podprti z računalniško tehnologijo.

Pri zahtevnejših odločitvenih problemih pa sta slednji metodi primernejši.

Pri odločanju s pomočjo elektronske preglednice lahko upoštevamo pomembnost kriterijev z uporabo uteži, ki jo pripišemo vsakemu kriteriju. Oceno posamezne variante preprosto odčitamo. Metoda nam omogoča enostavno izračunavanje končne ocene variant, če bi se ob ustreznem možnem posegu izboljšale vrednosti posameznih parametrov, ali če bi se spremenile uteži, in tako izbrati res optimalno rešitev. Gre za že omenjeno analiza kaj-če. Delo z elektronsko preglednico omogoča tudi grafičen prikaz variant po parametrih ali končnih ocenah. Težava pri uporabi elektronske preglednice nastane takrat, ko niso podatki točno določeni, so pomanjkljivi ali negotovi, in metoda ne da ustrezne ocene variante. Gradnja modela se pri odločitvenih problemih, kjer je vpliv posameznega parametra odvisen od

njegove vrednosti, zaplete. V tem primeru bi bilo treba sprogramirati funkcije, po katerih se posamezne uteži spreminjajo v odvisnosti od vrednosti parametrov. Pri tem moramo upoštevati tudi normalizacijo uteži. Pri odločitvenih problemih, kjer naravne vrednosti parametrov niso številske, je treba te vrednosti pretvoriti v številke, s tem pa izgubimo preglednost nad razumevanjem odločitvenega problema in razlago odločitve. Prav tako se preglednost izgubi z naraščajočim številom parametrov.

Odločitveni model, zgrajen s pomočjo računalniškega programa DEXi, omogoča poleg uporabe mehkih<sup>1</sup> podatkov tudi pregledno razlago rezultatov. Omogoča upoštevanje uteži, ki so odvisne od vrednosti parametra. Študij odločitvenega drevesa in funkcij koristnosti omogoča razumevanje odločitvenega problema, s tem pa tudi končne ocene variante tudi tistim, ki model samo uporabljajo (ga niso gradili). Analiza kaj-če je preprosta. Variante in rezultate lahko na različne načine tudi grafično predstavimo.

Neugodno je, da DEXi ni tako razširjen računalniški program, kot je elektronska preglednica. Za uporabo kot program ni zahteven, treba pa je poznati metodologijo večparametrskega odločanja in osnovna pravila za delo z njim. Slabost pri vrednotenju s pomočjo DEXi-ja je, da ne zna razvrščati znotraj razreda, to je posamezne opisne vrednosti, na primer *odlično*. Če nas zanima razvrstitev variant, ki so ocenjene z isto opisno oceno, lahko kot dopolnilo uporabimo program Vredana (<http://lopes1.fov.uni-mb.si/vredana>).

Primerjavo obravnavanih odločitvenih metod prikazuje tabela 4:

<b>METODA</b>	<b>PREDNOSTI</b>	<b>SLABOSTI</b>
<b>ABACON</b>	<ul style="list-style-type: none"> <li>- Enostavnost</li> <li>- Priročnost</li> </ul>	<ul style="list-style-type: none"> <li>- Ni enovite končne ocene</li> <li>- Ni uteži</li> <li>- Omejena "kaj če" analiza</li> </ul>
<b>PREGLEDNICA</b>	<ul style="list-style-type: none"> <li>- Ocena, uteži, urejanje</li> <li>- Kaj če analiza</li> <li>- Grafika</li> </ul>	<ul style="list-style-type: none"> <li>- Samo številčna ocena</li> <li>- Izgubimo interpretacijo (od kod izvirajo številke)</li> <li>- Pri večjem številu kriterijev izgubljam preglednost</li> <li>- Ni razlage (ni pojasnil številčnih ocen kriterijev)</li> <li>- Uteži so običajno konstantne</li> </ul>
<b>DEXi</b>	<ul style="list-style-type: none"> <li>- Kvalitativno izražanje</li> <li>- Podatki so lahko nenatančni – nepopolni</li> <li>- Upoštevanje odvisnosti uteži od vrednosti kriterija</li> <li>- Razumljiva razlaga ocen variant</li> <li>- Kaj če analiza, grafika</li> </ul>	<ul style="list-style-type: none"> <li>- Nekoliko bolj zahtevno za uporabo</li> <li>- ne zna razvrščati znotraj opisne ocene</li> <li>- omejitev na opisne ocene</li> <li>- zahtevnejše določanje funkcij koristnosti (odločitvena pravila)</li> </ul>

**Tabela 4: Prednosti in slabosti obravnavanih metod**

<sup>1</sup> O mehkih podatkih govorimo, ko podatki niso točno določeni, so pomanjkljivi ali so negotovi.

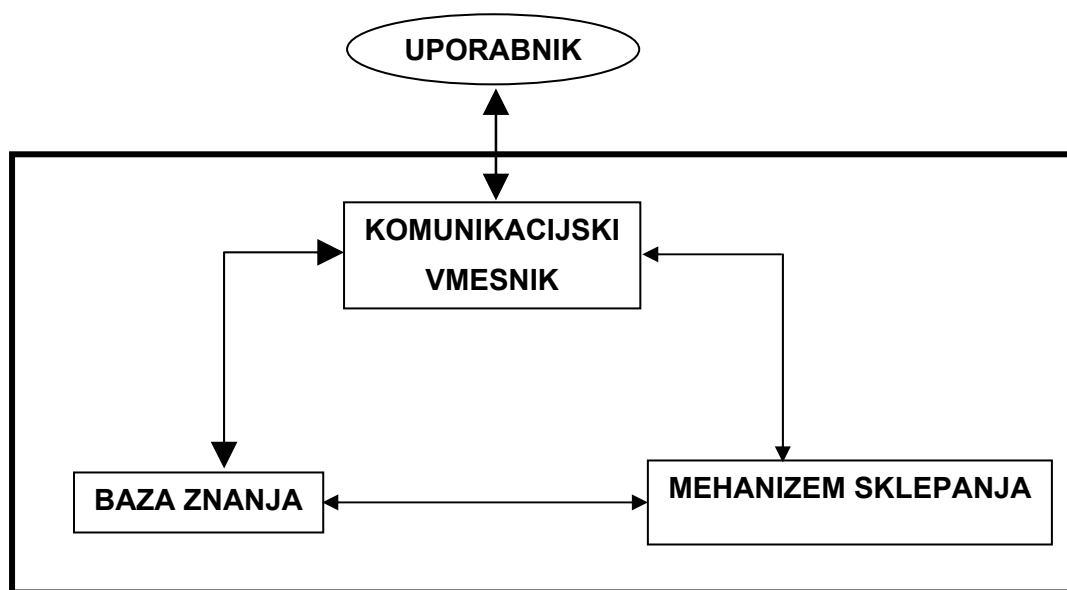
## ZGRADBA EKSPERTNIH SISTEMOV

Ekspertne sisteme smo omenili v poglavju o UI. Ko smo govorili o metodi odločanja s pomočjo metod umetne inteligence, smo se sklicevali nanje, omenili pa smo tudi lupine ekspertnih sistemov. Smiselno je, da jih nekoliko bolje spoznamo.

Ekspertni sistemi delujejo podobno kot človek - ekspert. Ekspert ne le da zna poiskati rešitve zahtevnih problemov, te rešitve zna tudi pojasniti.

Ime "ekspertni sistem" izhaja iz tega, da sistem deluje kot strokovnjak na določenem področju – ekspert. Ekspertni sistemi modelirajo sklepanje, presojo, odločanje ob nezanesljivih ali nepopolnih podatkih in imajo sposobnost pojasnjevanja svojega poteka reševanja problema (več o tem v Jackson, 1999).

Zgradbo ekspertnega sistema prikazuje slika 8.



Slika 8: Zgradba ekspertnega sistema

**Baza znanja** vsebuje znanje, ki je potrebno za reševanje določenega razreda problemov. Predstavljamo si jo lahko kot **podatkovno bazo**, ki je organizirana tako, da jo je možno uporabiti za transparentno reševanje problemov, kar pomeni, da imamo vpogled v potek tega reševanja od podatkov do rezultata.

Baza znanja vsebuje znanje določenega področja (domene), ne vsebuje pa znanja, kako ga uporabiti za reševanje določenih problemov. Za to skrbi mehanizem sklepanja.

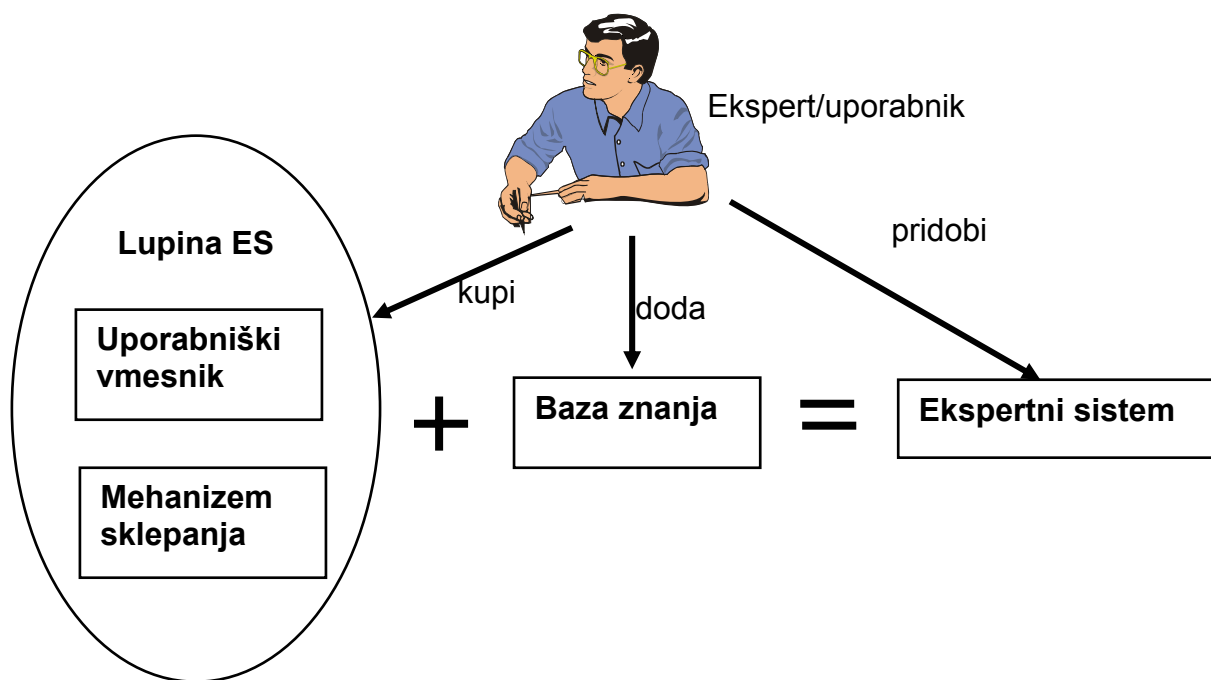
**Mehanizem sklepanja** nadzira in usmerja uporabo znanja pri reševanju konkretnega problema. Izbira dele znanja iz baze znanja, ki ga uporabi za reševanje problema, in vrstni red, kako jih kombinirati, da pride sistem v končni fazi do rešitve problema. Mehanizem sklepanja v veliki meri ni odvisen od domene znanja, zato ga praviloma uporabljamo pri bazah znanja različnih področij. Zelo pomembna naloga mehanizma sklepanja je razlaga poti do končnega rezultata.

**Uporabniški vmesnik** skrbi za komunikacijo med uporabnikom in sistemom: z bazo znanja in z mehanizmom sklepanja. Uporabniku omogoča, da lahko posega v bazo znanja. Tako kot velja za vse uporabniške vmesnike, je tudi za uporabniški vmesnik za ekspertne sisteme pomembno, da vsebuje kakovostno grafiko in omogoča učinkovito komunikacijo z uporabnikom.

Za gradnjo ekspertnih sistemov obstaja več računalniških programov – **lupin ekspertnih sistemov**, ki vsebujejo uporabniški vmesnik in mehanizem sklepanja, a imajo prazno bazo znanja.

Uporabnik mora dodati bazo znanja z določenega področja. Primeri komercialnih lupin ekspertnih sistemov so: Leonardo (Creative Logic), Spiral (Crol), X-SYS (Cybernetix), ESS (Olivetti) (Dutta, 1993), obstajajo pa še mnogi drugi. Pri gradnji sistema sodeluje tehnolog znanja, ki gradi bazo znanja s pomočjo intervjujev z eksperti določenega področja in iz drugih virov podatkov. Bazo znanja je mogoče zgraditi tudi s pomočjo strojnega učenja, kar je predstavljeno na koncu tega poglavja.

Tehnolog znanja bazo znanja vgradi v lupino sistema in pomaga pri vrednotenju in dopolnjevanju sistema. Končni uporabnik takega sistema običajno ni ekspert s tega področja, ampak manj izkušen uporabnik, ki lahko s pomočjo sistema izboljša svoje delo.



**Slika 9: Gradnja sistema s pomočjo lupine ekspertnega sistema**



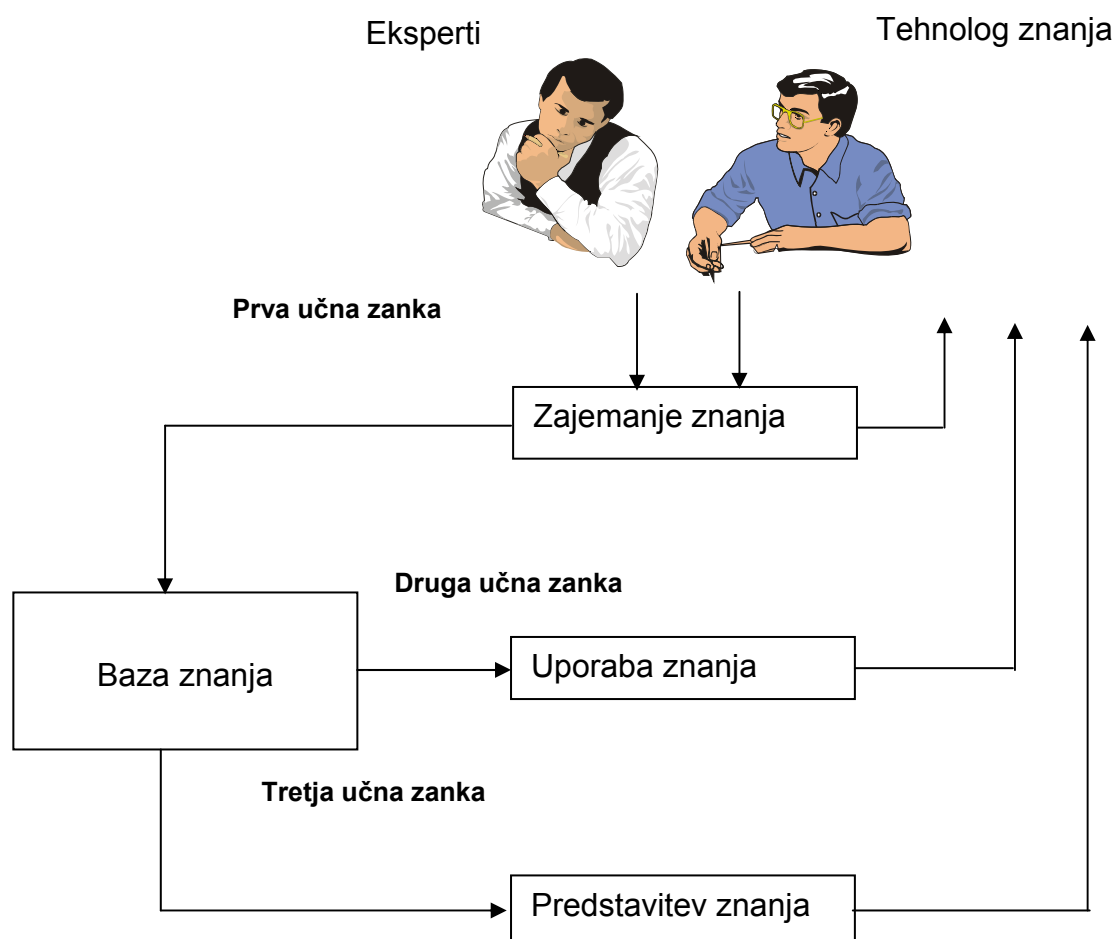
## TRI UČNE ZANKE

Pri gradnji in uporabi baze znanja govorimo o *treh učnih zankah* (Rajkovič, 2001). V vsaki od njih človek pridobiva znanje – se uči.

**Prvo učno zanko** predstavlja proces gradnje baze znanja. V tem procesu sodeluje poleg tehnologa znanja tudi ekspert z izbranega področja znanja. Gradnja baze znanja zahteva sistematizacijo in ustrezno oblikovanje znanja za predstavitev v računalniku. To zahteva tudi od eksperta dodatno proučevanje izbrane domene znanja. Tako na primer pri izgradnji odločitvenega modela zajemamo znanje o kriterijih, strukturah in preferencah ter s tem gradimo bazo odločitvenega znanja.

**Drugo učno zanko** predstavlja uporaba ekspertnega sistema. V tej učni zanki sodeluje uporabnik, ki se ob reševanju določenega problema z ekspertnim sistemom tudi uči. Odločitveno znanje uporabljamo za vrednotenje variant.

**Tretja učna zanka** pa je uporaba baze znanja kot vira znanja – predstavitev znanja – za učenje oziroma preverjanje znanja nekega področja. V procesu odločanja to pomeni, da dobimo pregled nad odločitvenim modelom.



Slika 10: Tri učne zanke

## GRADNJA BAZE ZNANJA

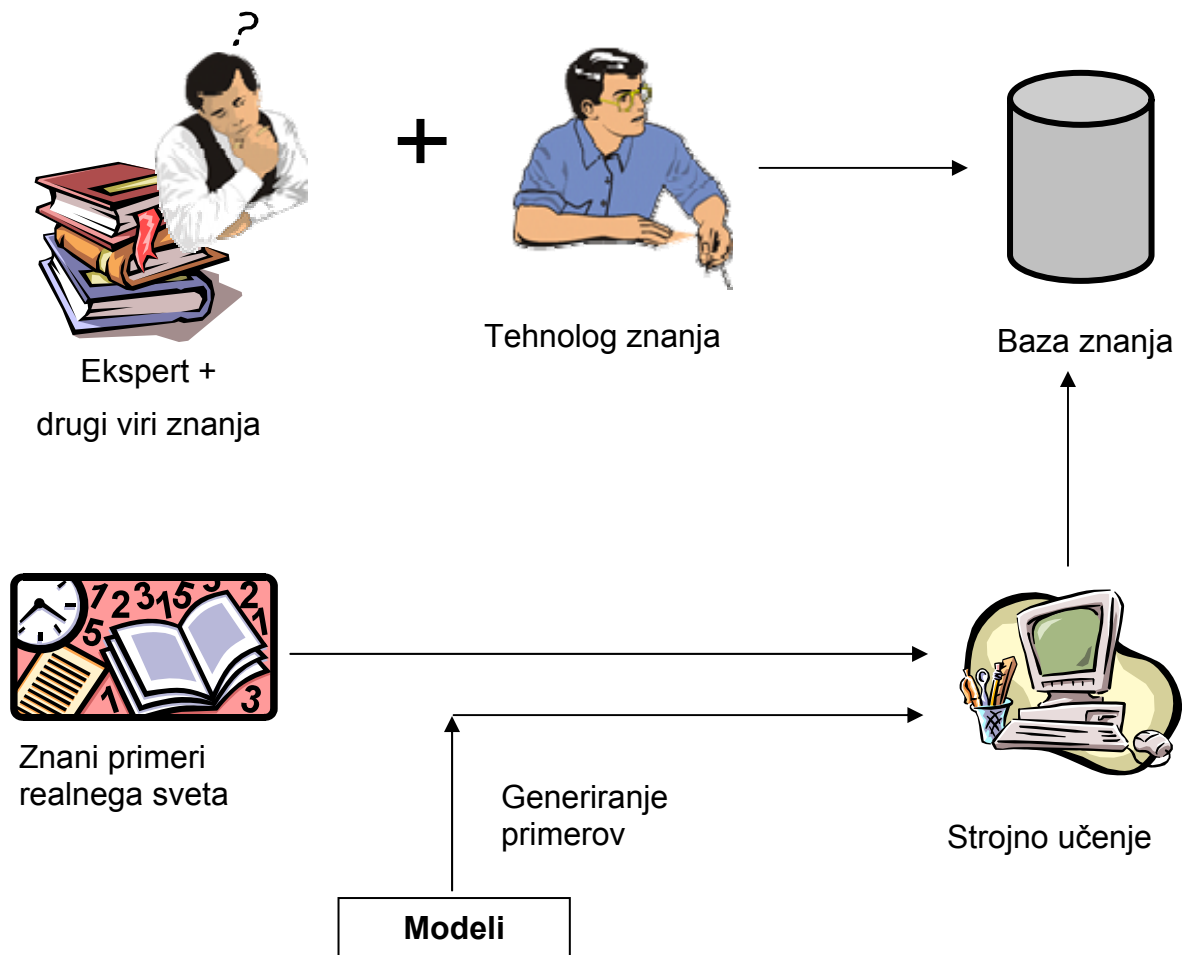
Znanje delimo na več vrst. V bazo znanja lahko shranimo tako eksplicitno kot implicitno znanje. Razmerje med proceduralnim in deklarativnim znanjem je odvisno od izbranega področja znanja.

Gradnja baze znanja je ozko grlo (Feigenbaumovo ozko grlo) pri razvoju ekspertnega sistema (Feigenbaum, 1979).

Viri znanja so različni:

- knjige, priročniki in različni drugi pisni dokumenti, ki jih najdemo tudi na internetu,
- strokovnjaki,
- drugi ljudje, ki lahko prispevajo k znanju, ki ga želimo zajeti v bazi.

Znanje, pridobljeno iz knjig, je eksplicitno znanje, ki ga je najlažje pridobiti in preoblikovati, a za uspešen ekspertni sistem je nujno tudi implicitno znanje, ki ga tehnolog znanja pridobi v razgovorih z ljudmi s tem znanjem.



**Slika 11: Gradnja baze znanja**

Zajemanje znanja, ki ga imajo ljudje – eksperti, je težavno. Razlog je v tem, ker je znanje, ki so si ga nabirali ob študiju in izkušnjah pri reševanju problemov, preraslo v

intuitivni občutek, kako se lotiti problema. Nekateri podatki, ki jih računalniško podprt sistem nujno potrebuje, se zdijo ekspertu nepotrebni, ker so za človeka očitni (na primer spol pacienta). Obstajajo pa še drugi – psihično–sociološki problemi, ki otežujejo delo tehnologov znanja: pomisleki o zmožnostih računalniškega programa, bojazen pred »konkurenco«, celo strah pred računalnikom. Zato je ta faza gradnje ekspertnih sistemov zelo občutljiva.

Bazo znanja lahko **gradimo** z uporabo ustreznih programov tudi **strojno**.

Programi za strojno učenje iz množice podatkov, ki jih podjetje ali zavod hrani o svojem delovanju, izluščijo znanje, potrebno za reševanje problemov s tega področja. Tako se čas gradnje sistema močno skrajša, vloga ekspertov pa je v tem primeru preverjati pravilnost tako zgrajene baze znanja. (Nekaj več o tem procesu lahko preberete v poglavju Izbrana poglavja področij umetne inteligence v podpoglavjih Odkrivanje znanja v podatkih in Podatkovno rudarjenje in Strojno učenje.)

Če nam uspe napraviti ustrezen simulacijski model izbranega izseka realnega sveta, nam ta model lahko pomaga z generiranjem učnih primerov.

### 1.1.6. Gradnja odločitvenih modelov

*Cilj tega dela učnega procesa je, da dijaki samostojno izdelajo odločitveni model ter ob tem ozavešajo faze odločitvenega procesa in utrdijo teorijo, ki so jo do sedaj spoznavali.*

#### **Didaktično metodična navodila**

Glavnino vsebin tehnologij znanja predstavljajo odločitveni procesi, podprti s tehnologijo ekspertnih sistemov. Opredelitev, uporabo in lastnosti te metode odločanja predstavi učitelj ob pripravljenem odločitvenem modelu, aktualnem za dijake (na primer izbira maturantske ekskurzije). Variante predlagajo in opišejo dijaki skupaj z učiteljem. Po vrednotenju variant učitelj interpretira rezultate. V prejšnjem poglavju je šlo za demonstracijo odločitvenih metod, tu pa je poudarek na gradnji odločitvenega modela. Možno pa je tudi, da se poglavji ne obravnavata ločeno, ampak se prepletata.

Faze odločitvenega procesa spoznajo dijaki ob gradnji odločitvenega modela.

Poudarek je na prednostih, ki jih nudi večparametrsko odločanje, možnosti določanja funkcije koristnosti glede na vrednost kriterija ter uporabi mehkih in nepopolnih podatkov. Tak model lahko gradimo s pomočjo lupine ekspertnega sistema. V našem primeru bomo uporabili računalniški program DEXi. Pri gradnji vzorčnih primerov odločitvenih modelov je pomembno, da učitelj posveti veliko pozornosti študiju primera odločitvenega problema, ki se prične *z jasno izraženimi cilji*. Pri tem opozori na pomen (skupaj s časovnimi in ostalimi omejitvami) temeljitega poznavanja problema. Poudari logična pravila, ki izhajajo iz razumevanja problema, po katerih zgradi drevo kriterijev. Pomembno je tudi, da dijakom razloži pomen odločitvene skupine, saj je pri kvalitativnih merskih lestvicah opis variant subjektiven, prav tako tudi izbira kriterijev in določitev funkcije koristnosti. Pri vrednotenju in analizi variant je nujno, da učitelj dijakom prikaže pomen transparentnosti rezultata vrednotenja. To stori tako, da vrednotenje vsake variante posebej razloži in ugotavlja z **analizo kaj-če** spremembe pri razvrščanju variant. Na koncu skupaj z dijaki naredi povzetek faz odločitvenega procesa.

Pred samostojnimi vajami učitelj razloži delovanje programa DEXi tako, da skupaj z dijaki, vsak na svojem računalniku, zgradijo odločitveni model prej izdelanega vzorčnega primera in izvedejo vrednotenje, interpretacijo rezultatov in analizo variant. Dijake opozori na uporabo navodil za uporabo programa.

V nadaljevanju dijaki gradijo svoje odločitvene modele za primere, ki jih predlaga učitelj ali pa jih poiščejo sami. Stopnjevanje zahtevnosti odločitvenih problemov učitelj določi z najmanjšim številom kriterijev in najmanjšo razvejanostjo drevesa kriterijev. Predvideli smo, da dijaki izdelajo v šoli tri odločitvene modele. Zahtevnost odločitvenega modela narašča s številom osnovnih parametrov in s številom ravni drevesa kriterijev. Ob koncu vsake faze odločitvenega procesa se dijak posvetuje z učiteljem in jo po potrebi izboljša. O modelu naj se pogovori s sošolci, kar lahko prav tako privede do izboljšave modela.

Ob koncu učnega sklopa tehnologije znanja pripravi vsak dijak poročilo o svojem odločitvenem modelu skupaj z vrednotenjem in interpretacijo vsaj dveh variant in ga predstavi sošolcem in učitelju. Učitelju odda pisno poročilo, v katerem je opisan celotni proces odločanja, skupaj z računalniškim izpisom programa DEXi. Sošolcem pa nalogo predstavi z elektronskimi prosojnicami.

Na zaključni uri tega poglavja o tehnologijah znanja dijaki iščejo možnosti in razloge za uporabo znanja, ki so ga pridobili pri pouku.

### **Vsebina**

**Organiziran odločitveni proces poteka po določenih fazah**, ki jih lahko struktuiramo takole:

1. opredelitev problema,
2. določitev kriterijev,
3. strukturiranje kriterijev,
4. določitev zaloge vrednosti za kriterije,
5. določitev funkcije koristnosti: odločitvena pravila,
6. opis variant z vrednostmi po kriterijih,
7. vrednotenje
8. analiza variant in
9. odločitev.

#### **1 . Opredelitev problema:**

Najprej moramo določiti, kaj je sploh odločitveni problem: kaj je predmet odločanja. Natančno moramo opredeliti, kakšne **cilje** želimo z odločitvijo doseči.

Problem moramo temeljito preučiti, da ga čim bolj spoznamo, saj bomo tako lažje zgradili ustrezen odločitveni model. Pri tem si pomagamo z različnimi viri.

Pomembno je določiti, kdo je lastnik odločitvenega problema, kdo za odločitev odgovarja in koga odločitev neposredno zadeva. Od vrste, obsega in zapletenosti odločitvenega problema je odvisno, ali je smiselno vključiti v odločitveno skupino eksperte, tehnologa znanja ali predstavnike tiste skupine ljudi, na katere odločitev vpliva.

#### **2. Določitev kriterijev**

Variante ocenjujemo na osnovi kriterijev (parametrov, atributov), ki jih določimo glede na zastavljeni cilj. Bolj natančno ko poznamo problem, lažje določimo kriterije.

V tej fazi odločanja sestavimo *spisek* kriterijev, po katerih bomo ocenjevali variante.

Smiselno je, da so kriteriji **merljivi**, tako si olajšamo delo in omogočimo **operativnost**.

Upoštevati je treba **načelo polnosti**: pomembno je, da se prepričamo, da nismo spregledali kriterijev, ki pomembno vplivajo na odločitev.

Ugodno je doseči **ortogonalnost** in **neredundatnost** kriterijev (kriteriji naj se po možnosti ne prekrivajo, ker bi v tem primeru isti kriterij imel na odločitev večkratni vpliv ali bi se vsebinsko ponavljal).

Včasih je smiselno, da vključimo v določanje kriterijev celotno odločitveno skupino.

### 3. Struktuiranje kriterijev

Iz spiska kriterijev zgradimo drevesno strukturo vsebinsko združenih kriterijev, ki predstavlja ustrezni miselni vzorec. Zaradi človekovih sposobnosti hkratnega razmišljanja o kombinacijah različnih kriterijev ni smiselno združevati več kot tri kriterije.

Kriterije struktuiramo iz več razlogov:

- zaradi preglednosti nad odločitvenim modelom in s tem tudi nad odločitvenim znanjem,
- zato da združimo kriterije, ki so vsebinsko povezani, in s tem dosežemo, da smiselno vplivajo na odločitve,
- zato da lažje določamo odločitvena pravila, s tem pa dosežemo tudi razumljivo razlago končne odločitve.

### 4. Določitev zalog vrednosti kriterijev

Vsakemu od kriterijev določimo vrednosti, ki jih lahko zavzame. Če je le mogoče, uporabimo naravne vrednosti kriterijev. Torej take kot jih običajno uporabljamo na področju, kamor spada kriterij. Pri gradnji odločitvenega modela upoštevamo, da pri listih določimo le toliko različnih vrednosti posameznega parametra, da lahko razlikujemo bistvene razlike med variantami. Ko gremo višje po drevesu, naj število vrednosti za posamezni (združeni) kriterij postopoma raste, kar je pomembno zavoljo občutljivosti modela. Tako na primer pogosto uporabimo na listih tri možne vrednosti, višje pa štiri ali pet.

### 5. Določitev funkcije koristnosti: odločitvena pravila

Za posamezne liste – osnovne parametre – določimo vrednost pri opisu variant. Funkcija koristnosti pa določa vpliv podrednih kriterijev na vrednost nadrednega kriterija.

Ko določamo funkcijo koristnosti za nadredne kriterije, je pomembno ugotoviti, kateri osnovni kriteriji so pomembnejši od drugih. Ugotoviti pa je treba tudi, ali v modelu morda ne nastopajo izločilni kriteriji.

Funkcijo koristnosti lahko v splošnem izrazimo:

- analitično, kot na primer z uteženo vsoto,
- točkovno (z odločitvenimi pravili za posamezne vrednosti) v obliki tabel za vsak izpeljan kriterij po točkah po principu *če-potem*.

Pri gradnji odločitvenega modela s pomočjo elektronske preglednice določamo funkcijo koristnosti z uporabo uteži, pri gradnji odločitvenega modela s pomočjo programa DEXi pa z utežimi ali pa funkcijo koristnosti podamo po točkah, ko oblikujemo pravila v ustreznih tabelah.

Pri določanju funkcije koristnosti uporabljamo preferenčno znanje odločevalcev.

To pa je odvisno ne le od znanj, ki ga ima odločevalec o določeni domeni znanja, ampak tudi od njegovih vrednot in njegovega statusa.

## 6. Opis variant

Variante opišemo z vrednostmi po parametrih. Do vrednosti pridemo po natančni preučitvi posamezne variante.

Pri tem moramo biti pozorni:

- na zanesljivost virov informacij o posamezni varianti,
- na čim večjo popolnost podatkov.

## 7. Vrednotenje variant

Končno oceno variant dobimo po vrednotenju variant na osnovi njihovega opisa po parametrih na listih odločitvenega drevesa.

Program vrednoti od listov proti korenu drevesa kriterijev v skladu:

- s strukturo drevesa
- z definirano funkcijo koristnosti.

Vrednost, ki jo na ta način dobimo v korenu drevesa, predstavlja končno oceno variante.

Varianta z najvišjo oceno je praviloma najboljša. Vrednotenje lahko uporabimo tudi za razvrščanje variant glede na rezultat, ki ga da funkcija koristnosti.

## 8. Analiza variant

Z analizo variant ugotavljamo razloge za rezultate vrednotenja.

Najboljšo varianto primerjamo z nekaj najbolj ocenjenimi preostalimi variantami.

Pri analizi si poskušamo odgovoriti na vprašanja:

- Zakaj je končna ocena takšna, kot je?
  - Kateri kriteriji so najbolj prispevali k takšni oceni?
  - Je v skladu s pričakovanji ali odstopa in zakaj?
- Katere so bistvene prednosti in pomanjkljivosti posameznih variant?
- Ali so vrednosti kriterijev in uporabljene funkcije koristnosti ustrezni?
- Kakšna je občutljivost odločitve: kako spremembe vrednosti kriterijev vplivajo na končno oceno?
- Ali je mogoče in kako variante izboljšati?
- Katere spremembe povzročijo bistveno poslabšanje ocen variant?
- V čem se variante bistveno razlikujejo med seboj?

Če ugotovimo, da se da posamezne parametre neke variante izboljšati, je smiselno pri ponovnem vrednotenju upoštevati izboljšane vrednosti in ponovno primerjati variante med seboj. Z *analizo kaj-če* lahko tako ugotovimo optimalno varianto v danih možnostih.

Razlago lahko podpremo tudi z različnimi grafičnimi ponazoritvami.

## **9. Odločitev**

Ob končni izbiri je zanimivo ugotoviti, ali so bili cilji odločitvenega procesa doseženi in katere lastnosti izbrane variante bi bile pri realizaciji lahko kritične.

Samo vrednotenje variant sicer opravi računalniški program na osnovi modela odločanja, analizo variant in končno odločitev pa opravi človek. Odgovornost za odločitev namreč nosi človek, IKT pa mu je lahko v procesu odločanja v bistveno pomoč.



## 2. Učni načrt in predlog časovne razporeditve ur

V okviru tega dela učnega načrta predmeta informatika dijaki pridobijo dodatno znanje za:

- uporabo IKT za podporo njihovih miselnih procesov,
- uporabo IKT za boljše razumevanje problemov – lahko učne snovi tudi pri drugih predmetih in v življenju.

Delo ob gradnji odločitvenih modelov razvija kreativnost in pozitivno vpliva na osebnostno rast.

### Podrobni operativni cilji in vsebine

Vsebina	Operativni cilji
Ravni uporabe IKT	Dijak zna opisati ravni uporabe informacijsko komunikacijske tehnologije. Zna razložiti razlike med njimi. Zna analizirati konkretne primere posamezne uporabe in utemeljiti, na katerih ravneh sam uporablja IKT.
Model človeškega procesiranja informacije	Dijak zna razložiti koncepta pomnjenja in miselnih procesov. Zna razložiti pomen učenja za nadaljnje učenje in ustvarjalnost. Poveže šibke točke človekovega procesiranja informacije z možnostmi, ki jih nudi IKT, da te šibke točke odpravi.
Pregled različnih tehnologij znanja	Dijak zna razložiti pojem »umetna inteligenca«. Razlikuje med različnimi vrstami tehnologij znanja. Zna argumentirati pomen transparentnosti in pomen razlage dobljenih rešitev in opredeliti, pri katerih primerih tak pristop ni potreben.
Proces odločanja in različni prijemi pri odločanju	Dijak zna utemeljiti, zakaj je pomemben sistematičen pristop k odločanju. Zna analizirati prednosti in slabosti obravnavanih metod. Zna razložiti pomen vsake faze odločitvenega procesa. Zna utemeljiti, kakšen pomen imajo naravne merske lestvice.
Uporaba računalniških programov kot pomoč pri odločanju	Dijak obvladuje delo z elektronsko preglednico in programom za večparametrsko odločanje, da lahko z njuno pomočjo modificira že obstoječ model za odločanje in zgradi novega.
Gradnja odločitvenih modelov z razlago primerov odločitev	Dijak zna rešiti dovolj preproste odločitvene probleme z ustrezno odločitveno metodo. Predlagane končne rešitve zna utemeljiti.

## **Standardi znanj:**

### **Minimalna raven**

Dijak oziroma dijakinja

- razloži pomen umetne inteligence in našteje nekaj primerov uporabe,
- poišče primere uporabe IKT za posamezne ravni uporabe IKT,
- opiše faze odločitvenega procesa,
- zgradi preprost (sedem listov v odločitvenem drevesu, ena raven) odločitveni model s programom za podporo večparameterskemu odločanju,
- opiše in vrednoti variante in utemelji, zakaj se je odločil(a) za eno od njih.

### **Temeljna raven**

Dijak oziroma dijakinja

- razloži pomen in vlogo IKT kot podporo človekovim umskim procesom,
- klasificira različne primere uporabe IKT v štiri ravni uporabe IKT,
- razloži prednosti in pomanjkljivosti obravnavanih odločitvenih metod,
- z analizo kaj–če utemelji in razloži končno izbiro lastnega odločitvenega modela.

### **Zahtevnejša raven**

Dijak oziroma dijakinja

- utemelji pomen in vlogo IKT kot podporo človekovim umskim procesom,
- predlaga in utemelji različne metode uporabe tehnologij znanja za reševanje določenih problemov,
- zgradi (več kot sedem listov v odločitvenem drevesu, več ravni) odločitveni model za kompleksnejši odločitveni problem s programom za podporo večparameterskemu odločanju.

## **Didaktična priporočila**

Teoretični del pouka izvedemo z razlago, z razgovorom med dijaki in učiteljem, s pomočjo video predstavitev uporabe sistemov umetne inteligence, ki pri snovi predstavlja izziv za obravnavo.

Učno snov predstavimo problemsko, začetni problem pa naj bo iz vsakdanjega življenja. Čimveč primerov naj poiščejo dijaki sami, skupaj z učiteljem pa jih opredelijo.

Pri vajah dijaki samostojno rešujejo odločitvene probleme. Po vsaki obravnavani odločitveni metodi naj dijaki za domačo nalogo izberejo odločitveni problem in ga rešijo s pomočjo te metode. Odločitvene probleme si lahko dijaki izberejo sami, tako je verjetnost, da jih bo delo pritegnilo večje, učitelj pa naj pomaga s predlogi.

Dijaki preučujejo odločitveni problem pri pouku in kot domačo nalogo. O njem zbirajo podatke iz najrazličnejših virov. Ob vsaki fazi odločitvenega procesa se dijak in učitelj pogovorita, ali je bila ustrezno izpeljana. Če ni bila, jo dijak ponovi.

Ob zaključku dijak odda poročilo, predstavi odločitveni problem, variante in končno odločitev sošolcem s pomočjo elektronske predstavitve. Sošolcem in učitelju interpretira, zakaj je končna odločitev prav izbrana varianta. Po vsaki predstavitvi se dijaki in učitelj o odločitvenem modelu kritično pogovorijo in ga analizirajo.

### Medpredmetne povezave

Teme se povezujejo s tistimi predmeti, s katerih področij si dijaki izberejo odločitvene probleme. Problemska področja so običajno interdisciplinarna in povezujejo več predmetov.

Močna je povezava s psihologijo, ko gre za razumevanje človekovih miselnih procesov, in sociologijo, ko gre za vpliv IKT ne le na posameznika, ampak na družbo kot celoto. Pa tudi z maternim jezikom, angleščino, pri iskanju podatkov na internetu, matematiko, logiko ter s knjižnično informacijskimi znanji pri iskanju podatkov po najrazličnejših virih.

### Načini preverjanja in ocenjevanja znanja

Preverjanje in ocenjevanje znanja poteka pisno, ustno, oceni se domača naloga in izdelek.

Dijaki dobijo eno oceno iz predstavitve odločitvenega modela in eno ustno oceno. Ustna ocena zajema kratko poročilo o razvoju ali uporabi metod in tehnik umetne inteligence po svetu, dijaki ga pripravijo kot domačo nalogo. Priporočamo, da dijaki dobijo eno oceno, ki ocenjuje raven osvojenih deklarativnih znanj.

Dijak, ki zadosti osnovnim zahtevam za izdelavo in zagovor naloge in uspešno predstavi tudi svoje poročilo o razvoju ali uporabi metod UI, ne more biti ocenjen negativno.

### PREDLOG ČASOVNE RAZPOREDITVE UR

TEMA	PODTEME	METODE DELA	ure	Σur
Uvod	Opredelitev vsebine sklopa snovi in cilji	Razgovor – dijaki iščejo primere.	1	1
Ravni uporabe IT	<ul style="list-style-type: none"> <li>Računalniška pismenost</li> <li>Razbremenitev pri delu</li> <li>Delamo stvari, ki jih do sedaj nismo</li> <li>Sistemi za intenzivno uporabo znanja</li> </ul>	<i>Domača naloga:</i> za svoje domače ugotovijo, na katerih ravneh uporabljajo IKT.	1	2
Kako človek procesira informacije	Kratkotrajni, dolgotrajni spomin, miselni procesi, podpora miselnim procesom	Razgovor, model - gradnja slike	1	3
Umetna inteligenca	<ul style="list-style-type: none"> <li>Opredelitev</li> <li>Namen in cilji</li> <li>Teme (vrste) umetne inteligence</li> </ul>	Razgovor ob ogledu videa s primeri uporabe različnih oblik IT  <i>Domača naloga:</i> Dijak poišče aktualne primere uporabe UI.	2	5

TEMA	PODTEME	METODE DELA	ure	Σur
Odločanje	<ul style="list-style-type: none"> <li>• Odločanje kot proces</li> <li>• Način odločanja</li> <li>• Pasti za dobro odločanje</li> </ul>	Razgovor – dijaki iščejo primere, razlaga ob primerih Povzetek (prosojnica)	1	6
Pripomočki pri odločanju	<ul style="list-style-type: none"> <li>• Ročna metoda</li> <li>• Elektronska preglednica</li> <li>• Program za večparametrsko odločanje</li> <li>• Faze odločitvenega procesa</li> </ul>	Razlaga vsake metode ob gradnji odločitvenega modela za konkreten odločitveni problem.  Dijaki v skupinah ugotavljajo prednosti in slabosti posameznih metod.  Analiza variant, pregled rezultatov vrednotenja, interpretacija  <i>Domače naloge:</i> po vsaki metodi dijaki za lasten problem izdelajo svoj odločitveni model.	6	12
Ekspertni sistem	<ul style="list-style-type: none"> <li>• Opredelitev</li> <li>• Zgradba</li> <li>• Uporaba</li> <li>• Lastnosti</li> </ul>	Ogled videa, razgovor in predavanje	1	13
VAJE	<ul style="list-style-type: none"> <li>• Gradnja odločitvenega modela za primer iz domače naloge.</li> <li>• Vrednotenje variant.</li> <li>• Priprava analize kaj če.</li> <li>• Priprava predstavitve lastnega modela.</li> </ul>	Individualno delo  <i>Domače naloge:</i> Priprava zahtevnejšega odločitvenega problema, zbiranje podatkov o variantah. Izdelava poročila.	6	19
Predstavitve	Predstavitev in interpretacija	Javne predstavitve s komentarji	4	23
Uporaba pridobljenega znanja	Različni odločitveni problemi poslovni, osebni, vrednotenje kakovosti, ...	Priprava primerov v skupinah. Predstavitev zaključkov skupin.  Povzetek zaključkov.	2	25

### 3. Gradiva kot pripomočki pri pouku

Za pouk je pripravljeno naslednje gradivo:

- program in navodila za program DEXi,
- primer popolnega poročila odločitvenega modela in navodila za pripravo poročila,
- priporočila za izbiro odločitvenega problema in izdelavo odločitvenega modela,
- na svetovnem spletu na naslovu <http://www.s-gimvic.lj.edus.si/gradiva/> so elektronske prosojnice za predstavitev snovi,
- elektronske prosojnice kot učni primeri za gradnjo odločitvenih modelov,
- učitelju in učencu pa so lahko v pomoč tudi kriteriji za ocenjevanje.

#### 3.1. Program za večparametrsko odločanje DEXi – priporočila za uporabo

Program sam in navodila za uporabo so na voljo na spletnem naslovu <http://lopes1.fov.uni-mb.si/DEXi>.

Ko gradimo nov model s pomočjo programa za večparametrsko odločanje DEXi, najprej oblikujemo odločitveno drevo. Imena parametrov naj bodo kratka. Pri vnosu vsakega od parametrov vnesemo pojasnilo tega parametra. Skrbna dokumentacija je potrebna za kasnejšo interpretacijo rezultatov in popravljanje modela.

Zaradi večje preglednosti predvsem funkcije koristnosti je smiselno, da v isti vozeli ne združujemo več kot štiri kriterije.

Pri zalogah vrednosti parametrov upoštevajmo pravilo, da je število pri listih omejeno na razlikovanje pomembnih lastnosti - ko gremo proti korenu število možnih vrednosti večamo, vendar ne pretiravajmo. Priporočamo, da imajo kriteriji v listih dve ali tri možne vrednosti, višje proti korenu pa tri, štiri, končna ocena lahko tudi več.

Pri določanju funkcije koristnosti si lahko delo s tabelami in pravili s pomočjo programa DEXi olajšamo z uporabo uteži. Pri tem se moramo zavedati, da za funkcijo koristnosti privzamemo model utežene vsote. V praksi lahko pričnemo z utežmi in dvema osnovnima praviloma, to je točkama, kamor vpnemo v splošnem hiper ravnino, ki predstavlja funkcijo koristnosti. Tabele osnovnih pravil, ki jih nato izdela računalnik, podajajo funkcijo koristnosti po točkah. Vsaka točka je predstavljena s pravilom. Pravila preverimo, in če nam vsebinsko ne ustrezajo, jih primerno spremenimo. S tem spremenimo tudi funkcijo koristnosti, ki praviloma ni več hiper ravnina, ampak bolj ali manj razgibana funkcija. Ob koncu od programa zahtevamo, da ponovno izračuna uteži, kjer gre za aproksimacijo funkcije koristnosti z ravnino. Razlike med temi in začetnimi utežmi so nam v razmislek o vplivu kasnejših sprememb pravil na celovito podobo funkcije koristnosti. To je pomemben proces določanja in interpretacije funkcije koristnosti, ki nam pomaga na poti do vsebinsko ustreznega povezovanja kriterijev v končno oceno. Gre za računalniško pomoč pri upravljanju s preferenčnim znanjem človeka.

### 3.2. Učni primer: Poročilo za izbiro maturitetnega predmeta

#### OPREDELITEV PROBLEMA

Prvič na koncu drugega letnika, dokončno pa se mora konec tretjega letnika gimnazijec odločiti za tri predmete, ki jih bo poleg slovenskega jezika in matematike opravljal na maturi. Tretji maturitetni predmet, ki mora biti tuji jezik, ni težko izbrati, ker je to običajno kar prvi tuji jezik, na izbiro četrtega in petega – izbirnega maturitetnega predmeta pa vpliva več kriterijev. Odločitvi, ki jo dijak sprejme konec tretjega letnika gimnazije, sledi priprava na te predmete v četrtem letniku. Slabi odločitvi marsikdaj sledi menjava maturitetnega predmeta med letom, dijak se mora zato na maturo več pripravljati sam, običajno pa to pomeni tudi slabšo pripravljenost in s tem slabši maturitetni uspeh.

Cilj je izbrati tak predmet, da bo ustrezal nadaljnjemu študiju, da bo uspeh na maturi čim boljši, delo pri pouku pa prijetno.

#### ODLOČITVENA SKUPINA

Odločitveni problem je v prvi vrsti problem dijaka, vendar pa se v odločanje vpletejo navadno tudi starši. Ožja odločitvena skupina so torej dijak in njegovi starši, čeprav na odločitev vpliva tudi šola.

Pri odločanju o izbiri maturitetnega predmeta je za vrednotenje variant in za iskanje ustreznih podatkov smiselno vključiti:

- svetovalnega delavca šole, ki lahko posreduje podatke vpisne službe fakultet o pogojih za vpis,
- učitelje, ki poučujejo izbirne maturitetne predmete, da čimbolj izčrpno predstavijo maturitetni katalog in s tem maturitetne učne vsebine ter maturitetne pole,
- tajnico(ka) ŠMK, ki lahko posreduje podatke o statistiki rezultatov mature pri posameznih predmetih in primerjavo z uspehom v zadnjih dveh letnikih,
- upoštevati je treba tehnične omejitve, ki jih dijakom razloži vodstvo šole.

Pomembno je, da vse podatke, ki jih dijaki izvedo od znancev in prijateljev, preverijo pri pristojnih osebah.

#### DOLOČITEV SPISKA KRITERIJEV

Določitev kriterijev je lahko zelo osebna, zagotovo pa obstajajo taki, ki bi jih lahko več ali manj upoštevali vsi.

Kriteriji za ta primer so določeni glede na pravilnik o maturi ter vpisni postopek na univerzi in glede na pogovore z dijaki, ki so že opravljali maturo ali se pripravljajo nanjo. Neurejen spisek kriterijev je lahko naslednji: *zahteve študija, zahtevnost predmeta, predznanje, ocena v 3.letniku (ali 2.letniku), razpoložljivost predmeta, kombinacija z drugimi maturitetnimi predmeti (glede na že izbrani predmet), zanimivost predmeta, (osebni odnos do predmeta), družba (sošolci), povprečni šolski uspeh pri maturi v primerjavi z oceno predmeta v šoli, razpoložljive ure v urniku, ali ima predmet predpisano*

*maturitetno raziskovalno nalogo ali laboratorijske vaje in učitelj - skladnost učiteljevega osebnega sloga z dijakom.*

## STRUKTUIRANJE KRITERIJEV

Zaradi preglednosti, medsebojne odvisnosti in povezav je kriterije smiselno strukturirati. Iz spiska kriterijev napravimo drevesno strukturo vsebinsko združenih kriterijev, ki predstavlja ustrezni miselni vzorec.

Tako je npr. **Osebni odnos do predmeta** izvedeni kriterij, v katerem so združeni kriteriji, ki opisujejo, kako je dijaku predmet všeč, ali se za ta predmet odločajo tudi njegovi prijatelji in kako sprejema učitelja.

V kriterij **osebna ocena** je združen kriterij **osebni odnos do predmeta**, poleg tega pa še kriterija **predznanje** in **zahtevnost predmeta**. Vse vrednosti kriterijev, ki sestavljajo vrednost kriterija osebna ocena, določi dijak sam in predstavljajo izrazito subjektivno oceno.

**Potencialni uspeh** je kriterij, sestavljen iz odstopanja ocen pri maturi, ocen v tretjem in četrtem letniku in ocene dijaka v tretjem letniku (v času, ko se odloča) in dejstva ali predmet zahteva tudi seminarsko nalogo ali laboratorijske vaje. Vrednost tega parametra je objektivna. Pomemben je kriterij, ali ima predmet maturitetno raziskovalno nalogo ali laboratorijske vaje, saj si lahko dijak še pred začetkom mature z uspešno izdelano nalogo ali poročili o uspešno izvedenih vajah zagotovi do 30% celotne maturitetne ocene.

Potencialni uspeh in osebna ocena sta združena v nov parameter **nagnjenje**.

**Tehnične možnosti** predstavljajo parameter, ki opisuje, kako je priprava na predmet dosegljiva dijaku in kako ga bo fizično – s številom ur – obremenjevala.

### Drevo kriterijev

Kriterij	Opis
<b>mat_pred</b>	izbira maturitetnega predmeta
zaht_štu	nekateri fakultete predpisujejo predmete, potrebne za vpis
<b>nagnjenje</b>	upošteva potencialni uspeh na maturi in počutje dijaka pri predmetu
<b>ocena_os</b>	združeni kriterij subjektivnih ocen
<b>odnos</b>	osebni odnos do predmeta
učitelj-osebno	skladnost učenčevega osebnega sloga z učiteljevim
zanimivost	kako zanimiv je predmet
družba-sosolci	ali se bodo na ta predmet vpisali tudi prijatelji
predznanje	osebna ocena predznanja za predmet
zahtevnost	osebna ocena o zahtevnosti predmeta
<b>pot_uspeh</b>	združeni kriterij, ki napoveduje oceno na maturi
odstopanje	odstopanje med povprečno oceno na maturi v prejšnjih letih in v razredu
ocena_3	dijakova ocena predmeta v 3. letniku
interna	pri predmetu je predpisana interna maturitetna naloga - do 20% ocene na maturi
<b>teh_mož</b>	tehnične možnosti za izpeljavo predmeta
ure	število ur izbirnega predmeta glede na celotno število ur na teden
kombinacije	možnost kombinacij predmeta z že izbranimi mat. predmeti
razpoložljivost	na šoli ali drugače

**Slika 12: Celotno drevo kriterijev za izbiro maturitetnega predmeta**

## ZALOGE VREDNOSTI

Orodje DEXi omogoča, da so zaloge vrednosti določene z naravnimi opisi ocene kriterija. Vrednosti so lahko urejene od najmanj zaželene do najbolj zaželene, to sicer ni nujno, a omogoča uporabo uteži pri določanju funkcij koristnosti. Priporočljivo je, da opišemo posamezno vrednost iz zaloge vrednosti tako, da je uporabniku razumljivo, kdaj je ocena nekega parametra na primer za parameter *razpoložljive ure* »ustrezno«. Opis dodamo, ko določamo zaloge vrednosti. V tem primeru je opis: »Število ur tega predmeta ravno dopolnjuje obvezno skupno število učnih ur«. Slika 13 prikazuje zaloge vrednosti posameznih kriterijev.

Kriterij	Zaloga vrednosti
<b>mat_pred</b>	<b>nesprejemljiv</b> ; preračunaj; še sprejemljiv; primeren; <b>zelo primeren</b> ; <b>obvezen</b>
-zaht_štu	ni; samo področje; <b>točno ta</b>
<b>nagnjenje</b>	ni; slabo; srednje; <b>dobro</b>
-ocena_os	slaba; srednja; <b>dobra</b>
-odnos	neustrezen; slabši; srednje; <b>dober</b>
-učitelj-osebnost	slab; primeren; <b>zelo dober</b>
-zanimivost	ni; srednje; <b>zanimiv</b>
-družba-sosolci	ni; srednje; <b>ustrezna</b>
-predznanje	ga ni; srednje; <b>odlično</b>
-zahtevnost	težak; srednje; <b>lahak</b>
<b>pot_uspeh</b>	slab; srednji; <b>dober</b>
-odstopanje	navzdol; navzgor; <b>enake</b>
-ocena_3	2; 3; 4; 5
-interna	ni; <b>je</b>
<b>teh_mož</b>	neustrezne; slabe; <b>primerne</b> ; <b>odlične</b>
-ure	jih ni; manjka; <b>ustrezno</b>
-kombinacije	ni možna; <b>možna</b>
-razpoložljivost	ni na šoli; občasno; <b>šola nudi ta predmet</b>

Slika 13: Zaloge vrednosti kriterijev

## FUNKCIJE KORISTNOSTI

Funkcije koristnosti določajo medsebojni vpliv kriterijev na vrednost nadrednega kriterija. Določene so v obliki tabel za vsak izpeljani kriterij po točkah po principu *če-potem*. Program DEXi ob določitvi vsaj dveh odločitvenih pravil ob upoštevanju uteži sam izračuna vrednost agregirane funkcije.

V tem primeru so uteži konstantne. Vendar je v večini primerov smiselno upoštevati, da je teža posameznega kriterija odvisna od njegove vrednosti.

Najpomembnejši objektivni kriterij, ki ob zadostni oceni ostalih kriterijev prevlada, je kriterij *zahteve študija*, če seveda ta zahteva obstaja. Le če je verjetnost, da bi dijak izdelal izpit iz tega predmeta na maturi, zelo majhna, je smiselno razmisliti, ali ni morda bolje, da izbere drug predmet in se odpove vpisnim točkam iz določenega predmeta.

Zelo pomemben objektivni kriterij je tudi *statistično odstopanje ocen v razredu in pri maturi*. V odločitvenem modelu nastopa v kombinaciji z oceno dijak.



Tabela 5 prikazuje funkcijo koristnosti za oceno primernosti maturitetnega predmeta, ki predstavlja koren drevesa kriterijev in združuje podredne kriterije: zahteve študija, nagnjenje in tehnične možnosti za izpeljavo predmeta. Vsako pravilo podaja kombinacijo oz. kombinacije vrednosti teh treh kriterijev, ki vodijo v določeno končno oceno maturitetnega predmeta. V 15. vrstici najdemo pravilo, ki določa zelo primeren predmet. V to oceno vodijo kombinacije, kjer nadaljnji študij zahteva le predmetno področje ali pa še tega ne, nagnjenje dijaka je ocenjeno z dobro in so tehnične možnosti vsaj primerne.

V našem drevesu kriterijev imamo šest tabel odločitvenih pravil. Funkcije koristnosti moramo določiti za vsako vozlišče drevesa, ki ni list.

**Tabele odločitvenih pravil**

	<b>zaht štu</b>	<b>nagnjenje</b>	<b>teh mož</b>	<b>mat pred</b>
	43%	39%	19%	
1	<b>ni</b>	<b>ni</b>	*	<b>nesprejemljiv</b>
2	<b>ni</b>	<=srednje	<=slabe	<b>nesprejemljiv</b>
3	<=samo področje	<b>ni</b>	<=slabe	<b>nesprejemljiv</b>
4	<=samo področje	<=srednje	<b>neustrezne</b>	<b>nesprejemljiv</b>
5	>=samo področje	<b>ni</b>	>= <b>primerne</b>	preračunaj
6	samo področje	slabo:srednje	slabe	preračunaj
7	<b>točno ta</b>	<b>ni</b>	*	preračunaj
8	<b>točno ta</b>	<=slabo	<b>neustrezne</b>	preračunaj
9	<=samo področje	slabo	>= <b>primerne</b>	še sprejemljiv
10	<=samo področje	slabo:srednje	<b>primerne</b>	še sprejemljiv
11	<b>ni</b>	<b>dobro</b>	<b>neustrezne</b>	še sprejemljiv
12	<=samo področje	srednje	<b>odlične</b>	primeren
13	<=samo področje	<b>dobro</b>	slabe	primeren
14	samo področje	<b>dobro</b>	<=slabe	primeren
15	<=samo področje	<b>dobro</b>	>= <b>primerne</b>	<b>zelo primeren</b>
16	<b>točno ta</b>	>=slabo	>=slabe	<b>obvezen</b>
17	<b>točno ta</b>	>=srednje	*	<b>obvezen</b>

**Tabela 5: Funkcija koristnosti, podana z odločitvenimi pravili za oceno primernosti maturitetnega predmeta**

	odstopanje ocen	ocena v 3. letniku	interna naloga	potencialni uspeh
1	navzdol	2	ni	slab
2	navzdol	2	je	slab
3	navzdol	3	ni	slab
4	navzdol	3	je	slab
5	navzdol	4, 5	ni	srednji
6	navzdol	4, 5	je	srednji
7	navzgor	2	ni	slab
8	navzgor	2	je	srednji
9	navzgor	3	ni	srednji
10	navzgor	3	je	srednji
11	navzgor	4, 5	ni	dober
12	navzgor	4, 5	je	dober
13	enake	2	ni	slab
14	enake	2	je	slab
15	enake	3	ni	srednji
16	enake	3	je	srednji
17	enake	4, 5	ni	dober
18	enake	4, 5	je	dober

**Tabela 6: Funkcija koristnosti za izvedeni kriterij *potencialni uspeh***

## OPIS VARIANT

Variante so predmeti srednje dobrega (bivšega) dijaka. Predmeti, med katerimi je izbiral, so francoski jezik, kemija in biologija. Tabela 7 prikazuje vnesene vrednosti opisa posameznega predmeta.

Varianta	frj	kem	bie
zaht_štu	ni	ni	ni
ucitelj-osebnost	slab	primeren	zelo dober
zanimivost	ni	zanimiv	zanimiv
družba-sosolci	ustrezna	ustrezna	ustrezna
predznanje	srednje	odlično	odlično
zahtevnost	težak	lahak	težak
odstopanje	navzgor	navzdol	navzgor
ocena_3	3	4, 5	4, 5
interna	ni	je	je
ure	ustrezno	ustrezno	ustrezno
kombinacije	možna	možna	možna
razpoložljivost	šola nudi ta predmet	občasno	šola nudi ta predmet

**Tabela 7: Opis variant**

## VREDNOTENJE IN ANALIZA VARIANT

DEXi rezultate vrednotenja variant izpiše v poročilu, ki ga prikazuje tabela 8.

Najslabše ocenjena varianta je bila francoščina. Ocene objektivnih kriterijev so bile sicer dobre, vendar so bili subjektivni kriteriji ocenjeni zelo slabo. Izrazita slabost variante **frj** je slab osebni odnos učitelja in nezanimivost predmeta. Potencialni uspeh je srednji kljub slabši oceni v razredu, zaradi statističnega odstopanja navzgor pri oceni na maturi. Izrazita prednost pa so tehnične možnosti.

Biologija in kemija sta bili obe enako dobro ocenjeni kot zelo primerna predmeta za pripravo na maturo. Potrebna je nadaljnja analiza, ker dijak izbira samo en predmet.

Izrazita prednost variante **kem** je dobra osebna ocena, ki izvira iz zanimivosti predmeta, dobrega predznanja in subjektivne ocene, da je predmet lahek. Izrazita slabost je statistično odstopanje maturitetne ocene navzdol glede na oceno v razredu.

Izrazita prednost variante **bie** so vse subjektivne ocene, razen ocene, da je predmet težak, kar bi glede na oceno v razredu težko ocenili kot slabost. Poleg tega pa je tudi osebna ocena učitelja kot osebnosti pri kemiji slabša kot pri biologiji, čeprav to na končno oceno ni vplivalo.


Pri analizi nam lahko pomaga tudi ustrezno izbrana grafična predstavitev variant.

### Rezultati vrednotenja

Kriterij	frj	kem	bie
<b>mat_pred</b>	še sprejemljiv	<i>zelo primeren</i>	<i>zelo primeren</i>
zaht_štu	ni	ni	ni
<b>nagnjenje</b>	slabo	<i>dobro</i>	<i>dobro</i>
<b>ocena_os</b>	<i>slaba</i>	<i>dobra</i>	<i>dobra</i>
<b>odnos</b>	slabši	<i>dober</i>	<i>dober</i>
učitelj-osebnost	<i>slab</i>	primeren	<i>zelo dober</i>
zanimivost	ni	<i>zanimiv</i>	<i>zanimiv</i>
družba-sosolci	<i>ustrezna</i>	<i>ustrezna</i>	<i>ustrezna</i>
predznanje	srednje	<i>odlično</i>	<i>odlično</i>
zahtevnost	težak	<i>lahek</i>	težak
<b>pot_uspeh</b>	srednji	srednji	<i>dober</i>
odstopanje	nav zgor	<i>navzdol</i>	nav zgor
ocena_3	3	4, 5	4, 5
interna	ni	<i>je</i>	<i>je</i>
<b>teh_mož</b>	<i>odlične</i>	<i>primerne</i>	<i>odlične</i>
ure	<i>ustrezno</i>	<i>ustrezno</i>	<i>ustrezno</i>
kombinacije	<i>možna</i>	<i>možna</i>	<i>možna</i>
razpoložljivost	<i>šola nudi ta predmet</i>	občasno	<i>šola nudi ta predmet</i>

Tabela 8: Rezultat vrednotenja

## Grafikon



**Slika 14: Večdimenzionalni grafični prikazi vrednotenja**

Na grafikonih so prikazane vse tri variante po parametrih *zanimivost*, *družba-sošolci*, *učitelj-osebnost* in *potencialni uspeh*. Vidimo, da ima največjo površino grafikon, ki predstavlja varianto biologija.

Zato se kaže kot najboljša izbira med obravnavanimi variantami biologija. Ta izbira je najprimernejša zato, ker sta tako osebna ocena kot potencialni uspeh najboljše ocenjena. Prav tako so tehnične možnosti za izvedbo priprav dobre.

### **3.3. Priporočila za izbor odločitvenega problema in kriteriji za odločitveni model**

Pri poskusnem izvajanju so si dijaki sami izbrali odločitveni problem. To se je izkazalo kot dobra motivacija za izdelavo odločitvenih modelov. Področja so bila zelo različna. Zajemajo njihove konjičke in aktualne osebne ali družinske odločitvene probleme. Problemi, ki so jih obdelali, so bili na primer:

- izbira različnih domače živali,
- izbira najprimernejše športne panoge,
- izbira najprimernejšega športnega rekvizita,
- izbira kraja za letovanje ali izlet,

- izbira tehničnih naprav,
- izbira programske opreme,
- izbira instrumenta,
- izbira čevljev za planinarjenje in prosti čas/poletne obutve,
- nakup stanovanja / hiše,
- izbira prireditve,
- izbira najboljšega športnega kluba, ...

Končni odločitveni model pa naj zadošča naslednjim merilom:

- v drevesu kriterijev naj bo vsaj devet listov,
- parametri se ne smejo ponavljati ali delno prekrivati, naj čimbolj opišejo problem (polnost kriterijev), paziti je treba, da se jih da vrednotiti,
- parametri naj bodo strukturirani na vsaj tri ravni,
- pri struktuiranju naj se upošteva, da so v nadrednem kriteriju združeni največ trije (le izjemoma več) podredni,
- uporabi naj se parametrom naravne merske lestvice s primerno zalogo vrednosti,
- vsi parametri in zaloge vrednosti naj bodo komentirane,
- z modelom naj bodo ovrednotene najmanj pet variant,
- rezultati vrednotenja morajo biti analizirani in razloženi,
- v poročilu naj bo opisana vsaj ena smiselna analiza kaj-če.

### **3.4. Navodilo za pripravo poročila o odločitvenem procesu**

Poročilo mora vsebovati opis odločitvenega problema, odločitvene skupine, kriterijev, zaloge vrednosti, funkcij koristnosti, razlago vrednotenja variant in opis vsaj ene analize kaj-če.

1) V **opisu odločitvenega problema** morajo biti odgovori na naslednja vprašanja:

- Kaj je predmet odločanja, razvrščanja ali vrednotenja?
- Kakšne cilje želimo doseči?
- katerim zahtevam mora ustrezati izbrana varianta?
- Ali je problem težak in zakaj?

2) Ko poročamo **o odločitveni skupini**, moramo zapisati:

- Čigav je odločitveni problem? Kdo se mora odločiti?
- Kdo je odgovoren za odločitev?
- Kdo nosi neposredne posledice odločitve?
- Kdo še sodeluje v odločitveni skupini?

- Ali smo (bi) v odločitveno skupino vključili eksperte, tehnologa znanja oziroma predstavnike tistih segmentov, na katere vpliva odločitev?

- 3) **Kriterije** naštejemo in vsakega posebej opišemo. Utemeljimo, zakaj smo uporabili ta nabor kriterijev in zakaj menimo, da nismo spregledali kriterijev, ki pomembno vplivajo na vrednotenje variant. V ta del vstavimo sliko drevesa kriterijev iz programa in razložimo, kako in zakaj smo jih združevali!
- 4) Ob opisu vsakega kriterija predstavimo tudi vrednosti, ki jih lahko kriteriji zavzamejo (**zalogo vrednosti**) in zakaj smo si izbrali prav tako!
- 5) Ob opisu združevanja kriterijev – strukturiranja kriterijev razložimo **funkcije koristnosti**: kako smo jih določili in zakaj smo jih tako določili. Opišemo:
  - Kateri kriteriji so pomembnejši in zakaj?
  - Ali morda v modelu nastopajo izločitveni kriteriji, to so tisti, ki ob določeni vrednosti ne glede na vrednosti drugih kriterijev kaki varianti določijo vrednost. Kateri kriteriji so to?
  - Ali se kateremu od kriterijev vpliv na končno oceno spreminja glede na njegovo vrednost? Razloži kako?

S tem je opisan odločitveni model.

V nadaljevanju **opišemo variante**. To dokumentiramo s izpisom (sliko) iz programa (DEXi). Tudi pri opisu rezultatov vrednotenja izbranih variant dodamo sliko. V poročilo zapišemo:

- Kako so bile ocenjene variante?
- Kje smo dobili podatke za ocene posameznih parametrov?
- Katera je najbolje ocenjena in razložimo zakaj.
- Najbolje ocenjeno varianto primerjamo z drugimi in utemeljimo razliko v končni oceni.

V poročilu predstavimo vsaj eno analizo kaj-če! Za to izberemo tiste kriterije, katerih vrednosti bi se dalo resnično spremeniti (izboljšati). Analizo dokumentiramo z izpisi iz programa!

Poročilu dodamo izpise DEXi-ja

- drevo kriterijev,
- merske lestvice,
- tabele odločitvenih pravil,
- opis variant,
- rezultat vrednotenja
- vsaj dve grafični ponazoritvi s komentarjem!

Zaključimo ga z utemeljitvijo naše končne odločitve.

### **3.5. Priporočila za ocenjevanje in preverjanje znanja**

Učitelj naj sproti preverja razumevanje snovi.

Pri pouku tehnologij znanja pridobimo več ocen.

Eno oceno dobi dijak iz predstavitve primera uporabe ali kake metode umetne inteligence. Pri tem ocenjujemo:

- izvirnost teme, ki jo dijak predstavlja,
- strokovnost predstavitve in
- kako poveže znanje pridobljeno pri pouku z znanjem, ki ga je s pomočjo drugih virov odkril sam.

Ocenjujemo pisni izdelek in sam nastop – zagovor ob elektronskih prosojnicah.

Pri poglavju o odločanju po predstavitvi vsake odločitvene metode dijaki z njeno pomočjo zgradijo vsak svoj odločitveni model za lasten odločitveni problem. Vsako fazo gradnje opišejo v poročilo. Učitelj sproti preverja in si beleži dijakov napredek, dijak pa hrani vse svoje izdelke.

V oceni končnega modela narejenega s pomočjo programa za večparametrsko odločanje upoštevamo:

- potek izdelave odločitvenega modela
- kakovost izvedene naloge,
- samo predstavitev.

Pri kakovosti naloge upoštevamo:

- zahtevnost odločitvenega problema,
- polnost izbranih parametrov,
- smiselnost strukture odločitvenega drevesa,
- primernost merskih lestvic,
- razlago vrednotenja,
- postopek analize kaj-če (smiselnost izbire parametrov, ki jim popravlja vrednosti, razlaga)
- utemeljitev končne razvrstitve, uvrstitve ali izbire.

Pri predstavitvi ocenjujemo:

- prepričljivost in samostojnost dijaka, ko opredeli problem, razloži postopke reševanja, opiše variante, razloži vrednotenje, predlaga končno odločitev in
- tudi tehnično podporo predstavitvi.
- Upoštevamo tudi, kako suvereno odgovarja na vprašanja po predstavitvi.

Dijak, ki zadosti vsem merilom, opisanim v priporočilu za izbor odločitvenega problema in kriteriji za odločitveni model, naj bi dobil najmanj oceno dobro.

Priporočamo, da eno oceno dijak dobi s pisnim preverjanjem znanja.

### 3.6. Primeri dreves kriterijev

Kot primer navajamo nekaj primerov dreves kriterijev odločitvenih modelov, ki so jih zgradili dijaki med poskusnim izvajanjem teh vsebin.

#### 1.primera: izbira mobitela

##### Drevo kriterijev

Kriterij	Opis
<b>Mobilniki</b>	Izbira za mobilnike v cenovnem razredu med 10 do 30 tisoč tolarjev
<b>Karakteristike</b>	Tehnične lastnosti
<b>baterija</b>	Lastnosti baterije
čas pogovora	Čas pogovora v urah
čas pripravljenosti	Stanje pripravljenosti v urah
teža	Teža baterije
<b>oblika</b>	Osnovne oblikovne značilnosti
dimenzije	Velikosti mobija
zaslon	Karakteristike zaslona
<b>kommunikacije</b>	Možnosti za izmenjavo podatkov
wap	Wap 1.1 oz. običajni html brskljalnik
podatki	Prenos podatkov (npr. vgrajen modem)
omrežje	Deluje na dveh ali več frekvenčnih območjih
<b>dodatki</b>	Luksuzni dodatki
<b>čas</b>	Vgrajena ura in datum
ura	Točen čas
datum	Koledarček
alarm	Budilka, ki nas kaj opominja
<b>zanimivo</b>	Dodatne zanimive funkcije
als	Uporaba dveh števil na eni kartici
glas_izbiranje	Glasovno izbiranje
igre	Igrice na mobilniku
<b>vibra</b>	
<b>cena</b>	Cena mobilnika



## 2.primerek: izbira ekskurzije:

### Drevo kriterijev

Kriterij	Opis
<b>Ekskurzija</b>	
<b>Cena</b>	Cena ekskurzije je odvisna od tega, kaj imamo vključeno.
Standard življenja	Kaj bom tam nujno potreboval in koliko to stane.
Višina	Koliko stane
Način plačevanja	Obroki, popusti
<b>Ponudba</b>	Dodatne ponudbe, ki mi jih določen kraj ponuja
<b>Ugodje</b>	Zahteve, ki jih imam za splošno počutje
Spanje	Kakovost namestitve
Klima	Odvisno od letnega časa - je pre vroče, premrzlo, ...
Dodatne ugodnosti	Npr. samopostrežni zajtrk, večerja, ...
<b>Aktivnosti</b>	
<b>Znamenitosti</b>	
Naravne znamenitosti	
Zgodovinske znamenitosti	
<b>Prosti čas</b>	
Zabava	Disko, plesi, koncerti, druge prireditve...
Športne aktivnosti	Tenis, fitness, ...
Vodenje	Kakovost vodnika in animatorja
<b>Zavarovanje</b>	
Odpoved	Zavarovanje ob odpovedi
Nesreča	Zavarovanje ob nesreči
<b>Prevoz</b>	Kakovost prevoza
Obl_prev	S kakšnimi sredstvi se peljemo
Kakov_prev	Kakovost prevoznih sredstev, servis ob okvari

## 3.primerek: izbira računalniške igrice:

### Drevo kriterijev

Kriterij	Opis
<b>Računalniška igrice</b>	Izbira najboljših računalniških igrice
<b>značilnosti igre</b>	Vse v zvezi kakovostjo in vsebino igre.
<b>karakteristika</b>	Sem spadajo igralnost, možnost igranja preko mreže in težavnost.
<b>igralnost</b>	Splošne značilnosti igranja igre.
igralnost	Vsebina igre, kako se igra.
težavnost	Ljudem, ki imajo radi izzive, bodo bolj všeč težavne igre.
mrežna_j	Človek se kmalu naveliča single player igranja in se hoče preizkusiti v igranju po mreži.
<b>audio&amp;video</b>	Audio&video lastnosti: grafika in zvok.
Grafika	Grafika igre. Boljša kot je, boljše je igranje.
Zvok	Boljši zvok je bolj zaželen.
Zvrst	Odvisno od tega, kaj ti je bolj všeč
<b>finance</b>	Ali zmorem finančno...
strojne_zhteve	Ali jo sploh lahko igram na svojem računalniku.
cena	Dražja kot je igra, manjše so možnosti, da si jo bom kupil.
<b>odmevi</b>	Vplivi mnenj ni ostale stvari
<b>ostale stvari</b>	Sem spada oblika domače strani, ugled igre in število jezikov, ki jih igra ima.
domača stran	Bolj ko je zanimiva domača stran igre, bolj me igra zanima
število jezikov	Če jih ima veliko, je to dobro, manj kot jih ima, slabše je....
starost	Stare igrice dostikrat zaostajajo za novimi.
<b>mnenje drugih</b>	Tukaj so mnenja, želje in ocene drugih.
mnenje prijateljev	Nasvet prijatelja je lahko zelo pomemben.
želje_družine	Kadar kupuješ igro, moraš paziti, da z igro prineseš v hišo veselje, ne prepri.
ocena v reviji	Kako oceni igro revija - boljša ocena je, boljše je igranje.

## 4. Poročila učiteljev

Pri projektu *Uvajanje tehnologij znanja v predmet informatika* smo razvili model poučevanja, ga preizkusili in ovrednotili v sodelovanju z enajstimi učitelji informatike z devetih slovenskih srednjih šol. Pri projektu so sodelovali učitelji in učiteljice z Gimnazije Jurija Vege iz Idrije Danica Bogataj, z Gimnazije Vič Alenka Krapež in Marina Galjot, s Srednje ekonomske šole, ekonomske gimnazije Ljubljana Boštjan Resinovič, s Srednje šole Srečka Kosovela Sežana, gimnazije Stanislav Jablanšček, z Gimnazije Kranj Fani Mavrič in Zdenka Verbinc, z Gimnazije Franca Miklošiča Ljutomer Zvonko Kustec, z Gimnazije Šiška Edi Kuklec, iz Srednješolskega centra Velenje Simon Muha in z Gimnazije Šentvid Nastja Lasič.

V poročilih ob koncu projekta so učitelji zapisali:

### **Danica Bogataj, Gimnazija Jurija Vege, Idrija**

Projekt sem izvajala v šolskem letu 2000/2001 v tretjem letniku gimnazije pri izbirnem predmetu informatika in v četrtem letniku gimnazije pri izbirnem predmetu računalništvo in informatika.

Ker je predmet izbiren, smo imeli v urniku 4 ure skupaj (blok ure). Taka organizacija je pri izvajanju teorije predstavljala majhno težavo, saj je zelo težko pri dijakih obdržati vse 4 ure teorije zanimanje za vsebine, čeprav je bilo to le trikrat (po učnem načrtu je za teoretične vsebine predvidenih 12 ur). Poleg tega smo gostovali v učilnicah druge stavbe, ker je računalniška učilnica premajhna za cel razred. Tam pa nisem imela na razpolago predstavitvenega računalnika. Pri vajah pa so se blok ure izkazale kot velika prednost. Razmišljala sem, kako motivirati dijake, da bi jim tudi teoretične ure "prehitro" minile. Odločila sem se, da bom v naslednjem šolskem letu vključila v pouk še video, ki ga imamo, predstavitev na predstavitvenem računalniku, predvsem pa jih bom že prve ure spodbudila, da bodo o temah še sami poiskali gradiva na internetu in jih nato predstavili sošolcem ter razmislili, kateri so taki problemi, da bi jih lahko rešili s pomočjo tehnologij, ki jih bomo spoznavali.

Zdaj pa še nekaj besed o poteku pouka. V uvodni uri sem jim predstavila delo v tem šolskem letu. Zanimivo, pod pojmom tehnologije znanja in ekspertni sistem si večina ni predstavljala nič, tudi niso kazali silnega navdušenja nad temo, so pa malo oživel pri pojmu umetna inteligenca. Imela sem občutek, da se jim je vse zdelo pretežko. Pozneje (pri vajah) so mi povedali, da se jim je na začetku vse zdelo "totalno neuporabno" in "ful težko", če uporabim njihove izraze. A ko smo začeli s konkretnimi temami, se je izkazalo, da jih stvar vedno bolj zanima. Presenetili so me pri temi "Kako človek procesira informacijo?" - o spominih so se razgovorili prav vsi. Mislim, da je prav ta tema (dobro predznanje iz psihologije?) pri njih dokončno ovrgla pomisleke o smislu učenja te snovi. Bolj ko smo šli proti DEXi-ju, bolj so sodelovali.

Pri vajah se je izkazalo, da sem pri teoriji prehitro šla skozi identifikacijo problema, identifikacijo kriterijev in definicijo odločitvenih pravil, ali bolje: preslabo sem preverila razumevanje pojmov pri vseh. Letos teorije nisem posebej preverjala (preverjala sem samo pri nekaterih dijakih) in ocenjevala (pri nobenem), drugo leto bom pri vseh teorijo preverila in ocenila. Tako bom dosegla, da se bodo dijaki za razumevanje pojmov bolj potrudili.

Z dijaki smo se že na začetku dogovorili, da si vsi namestijo DEXi na domače računalnike. To so tudi storili, razen treh, ki nimajo svojega računalnika. S temi smo se dogovorili, da bodo pač vse naredili v šoli.

Vaje so potekale zelo dobro. Med vajami sem ocenila prvi preprost odločitveni model. Na koncu je moral vsak izdelati še svoj odločitveni model - mi oddati poročilo o projektu, ki sem ga tudi ocenila. Pri nalogi bom morala več pozornosti nameniti predstavitvi in interpretaciji.

Mislim, da mi bo drugo leto lažje, ker bom znala bolje organizirati delo. Pomanjkljivosti letošnjih oddanih nalog so mi pri tem eden od kažipotov. Do naslednjega šolskega leta bom morala še izpopolniti in utrditi tudi svoje znanje o tehnologijah znanja.

Danes so dijaki mnenja, da je bilo poglavje Tehnologije znanja mnogo bolj zanimivo, pestro in uporabno kot so si predstavljali na začetku. Povedali so, da so jim bile vaje bistveno bolj všeč kot teorija. Kdaj jim pa niso? Pa vendar - saj so v šoli zato, da vidijo (spoznajo?) tudi kaj več, kot tisti, ki gredo na tečaj uporabe kakega programskega orodja, mar ne? Samo prikazati jim bom morala teorijo skozi ta očala, pa bo.

### **Marija Galjot, Gimnazija Vič Ljubljana**

V šolskem letu 2000/01 sem v skupini šestnajstih dijakov drugega letnika izvajala projekt Uvajanje tehnologij znanj v predmet informatika. Začeli smo z različnimi stopnjami uporabe informacijske tehnologije. Dijaki so iskali, na kateri stopnji se nahajajo, in ugotavljali, kako bi prišli čim lažje na naslednjo stopnjo uporabe informacijske tehnologije. Naslednjih deset ur smo se ukvarjali s področji umetne inteligence. Ogledali smo si dva videoposnetka, ki govorita o možnostih in težavah pri razvoju umetne inteligence. Preostanek ur smo prepustili odločanju. Začeli smo s preprostejšimi primeri, kmalu pa smo prišli do večparameterskega odločanja.

Vsak od dijakov si je izbral svoj odločitveni primer. Poiskal je vsaj petnajst kriterijev, narisal odločitveno drevo in ga po ustrezni obdelavi vstavil v program Dexi. Potem je poiskal štiri variante in jih ocenil. Seveda je vnesel tudi variante in na koncu je ostal še najpomembnejši del – analiza rezultata. S pomočjo programa Dexi je analiziral rezultat, ki mu ga je podal program. S to analizo so dobili povezavo med teorijo in prakso. Videli so resnični pomen funkcije koristnosti, pomen večparametrskega odločanja in prednosti ekspertnih sistemov pred sistemom Abacon in odločitvijo s pomočjo Exela.

Dijaki so si izbrali različne odločitvene probleme, npr.: nakup mobitela, smuči, računalniške igrice, motocikla, gorskega kolesa, radia, izbira najboljšega športnega kluba in izbira najboljšega igralca v klubu Manchester.

Na koncu so natisnili poročilo iz programa Dexi in dodali uvod in analizo odločitve ter svoj odločitveni model predstavili pred drugimi dijaki. Dijaki so bili s svojimi izdelki zadovoljni.

Opazila sem, da jim začetna snov, ki je predvsem teoretične narave, dela malo preglavic, zato bi bilo dobro, da med te ure dodamo kakšne praktične vaje, da se snov utrdi. Pri izdelavi odločitvenih modelov pa bi bilo dobro, da dijaki pred predstavitvijo svojih modelov izdelke izmenjajo in preizkusijo model svojega sošolca

na svojih variantah. Seveda zapišejo komentarje, kaj jim je bilo pri modelih všeč in kaj ne, če so pogrešali kakšen kriterij ali so mogoče našli celo kakšne napake.

Moje mnenje je, da so dijaki v tem projektu spoznali, na kakšnih področjih nam računalnik lahko pomaga, kje pa smo ljudje še v prednosti. Z izdelavo odločitvenih modelov pa so se naučili razmišljanja o reševanju problema z računalnikom, kako odločitveni problem oblikovati, da ga razume tudi ekspertni sistem, in kako analizirati rezultat, ki nam ga da računalnik in da sploh spoznamo, ali je rešitev smiselna ali ne.

### **mag. Boštjan Resinovič, Srednja ekonomska šola Ljubljana**

Projekt sem izvajal v šolskem letu 2000/2001 v četrtem letniku ekonomske gimnazije pri izbirnem predmetu poslovna informatika.

Pouk je potekal v računalniški učilnici, opremljeni s projekcijsko opremo. Organiziran je bil v bloku po dve uri, po učnem načrtu predmet obsega 35 ur, dejansko pa jih je bilo realiziranih 32. Prvih 10 ur sem poučeval teorijo tehnologij znanj, naslednjih 10 ur so bile na programu vaje in izdelava seminarske naloge s programom Dexi, nato 2 uri osnov računalniških predstavitev, 6 ur izdelave predstavitev in 4 ure nastopov. Ko so v šoli dokončali seminarsko nalogo (odločitveni problem po lastni izbiri), so dijaki doma napisali poročilo, ki sem ga ocenil. Predstavitev, ki so jo izdelali, se je morala nanašati na odločitveni problem, ki so ga obdelali pri seminarski nalogi. Predstavitev in nastop sem ocenil.

Blok ure so se pri izvajanju teorije pokazale kot zelo naporne, dijakom sta pogosto padli koncentracija in zanimanje, morda malo bolj tudi zato, ker sem jim že v uvodni uri razložil, kako bodo pridobili oceni in da znanja teorije ne bomo preverjali in ocenjevali s testom. Ne glede na to pa pri vajah in ocenjevanju seminarskih nalog nisem dobil občutka, da bi bilo njihovo teoretično znanje pomanjkljivo. Nekaj težav so nekateri dijaki imeli le z ločevanjem kriterijev od zalog vrednosti kriterijev (to, kar bi morale biti zaloge vrednosti, so poskušali pretvoriti v kriterije), zato bom temu naslednje leto posvetil več pozornosti.

Monotonost in napornost teoretičnih ur je razbilo predvajanje video posnetkov, ki smo jih imeli na razpolago, čeprav so ti malo starejšega datuma, dva od njih nista prevedena v slovenščino, kvaliteta posnetkov pa bi tudi lahko bila boljša. Zato bi bilo dobro poiskati kak sodobnejši dokumentarec in ga, po potrebi, prevesti v slovenščino. Pri vajah pa so se, po pričakovanju, blok ure pokazale kot zelo dobra oblika.

Dijaki niso prej o temah, s katerimi smo se ukvarjali, imeli skoraj nikakršnega znanja. Ker se je večini snov zdela zanimiva, so veliko spraševali in sodelovali, še posebej po so jim bile všeč vaje. Zato se jih je velika večina pri seminarski nalogi in njeni predstavitvi zelo potrudila, tako da smo bili na koncu zadovoljni vsi.

### **Stanislav Jablanšček Srednja šola Srečka Kosovele Sežana, gimnazija**

V šolskem letu 2000/01 sem v tretjem letniku gimnazije predaval novo učno snov tehnologije znanja. Pri projektu je sodelovalo 33 dijakov iz a in b oddelka. Ker se je ta

projekt prvič izvedel v okviru predmeta informatika (pri nas kot izbirni predmet), sem tej snovi in elektronskim prosojnicam posvetil vse učne ure.

Dijaki so postopoma prihajali od lažjega uvodnega odločitvenega problema preko zahtevnega do najzahtevnejšega.

Najzahtevnejši problem so dijaki morali predstaviti z nastopom in ga zagovarjati pred skupino. Drugače so pa za vsak problem napisali tudi seminarsko nalogo (ponovitev snovi in utrjevanje iz prvega letnika).

Najboljše seminarske naloge so bile tudi razstavljene na naši in sosednji Osnovni šoli ob dnevu projekta "Optična povezava med zavodi v Sežani".

Zanimivo, je da so se dijaki uvodnega projekta lotili lahko z mislijo, da bodo nalogo opravili z eno roko. »Saj to ni nobena umetnost.« Posledica je bila katastrofalen projekt. Projekte smo prediskutirali. Iz razgovorov sem razbral, da se naši dijaki zelo malo odločajo. Za kar je tudi več vzrokov:

- Starši odločajo o vsem (kaj bom jedel, kam gremo skupaj, kje bomo počitnikovali itd.)
- V šoli učitelji odločajo (postavljajo nam vprašanja, lokalizirajo kaj bomo pisali, kako morajo biti napisni odgovori, važno je, da je napisano po učbeniku, matura itd.)
- Kadar moramo sami kaj odločiti, nam je najlažje odločitev in s tem odgovornost zanj prenesti na druge.

Drugega projekta so zato dijaki lotili že bolj celovito, saj so spoznavali že obsežno drevesno strukturo kriterijev pri odločanju. Zato so nekateri menili, da bi bilo morda le dobro uporabljati tudi računalniška sredstva, saj morda kaj spregledaš. Ugotovili so, da je relativno težko dobiti ustrezne kriterije za dober opis problema ali vsaj za zadostitev minimalnih učiteljevih zahtev.

V tretjem projektu so dijaki uporabili tudi uteži (ponderje), kjer so prišli do spoznanja, kako malo je treba spremeniti, da se jim podre navidez najboljši model. Največji problem pa je v tem, da so večinoma odločitveni proces izpeljali sami. S timskim delom bi prišli gotovo do drugačnih, morda boljših rezultatov. Zanimivo je bilo gledati njihove nastope in poslušati diskusijo, če je bil predmet odločanja vsem domač (nakup mobija, motorji, računalniki), oziroma je nastopila tišina pri problemih, o katerih večina še razmišljala ni (najem stanovanja, nakup hiše, izbira kuhinje, nakup psa).

Prišli smo do zaključka, da se v življenju stalno odločamo, največkrat na izkušnjah in mnenjih pisnih virov, zelo malo pa si vzamemo časa za premislek in za strojno podprto odločanje.

Podpiram uvajanje novih tehnologij znanja v gimnazijski program, saj smo prešli iz klasičnega učenja, predstavitve pripomočka, primera, vaje in testa na osnovi vaje v konkretizacijo, kjer se dijaki srečujejo s problemi in samostojno odločajo o vsebini in njihovem videzu in to odločitev predstavijo ter jo pred skupino utemeljijo.

V naslednjem šolskem letu se bo nova generacija srečala s to temo.

### **Fani Mavrič in Zdenka Verbinc, Gimnazija Kranj**

Gimnazija Kranj sodeluje pri uvajanju predmeta informatika že od vsega začetka. Ker smo bili nad rezultati uvajanja predmeta informatike navdušeni, smo se odločili za nadaljevanje projekta. Tako je v šolskem letu 2000/01 potekal projekt poskusno izvajanje vsebin informatike za tretji letnik tehnologije znanja. Z načinom dela v projektu smo zadovoljni, tako dijaki kot učiteljici, saj nam omogoča kreativnost, motiviranost, sodelovalno učenje.

V drugem letniku smo zbrali prijave za izbirni predmet informatika v tretjem letniku. Prijavilo se jih je zelo veliko, vendar jih je mnogo odstopilo zaradi časovne neusklajenosti izbirne vsebine z njihovimi urniki. Tako usklajevanje je zelo težko, saj so se prijavili dijaki iz vseh osmih oddelkov.

Prvi del pouka je bil namenjen spoznavanju in razumevanju novih pojmov. Pri temi Odločanje in Ravni uporabe IT sva uporabili razlago in pogovor. Pri razlagi sva navajali primere, ki jih dijaki dobro poznajo. V tretjem sklopu Kako človek procesira informacije pa so imeli dijaki težave z razumevanjem pojmov. Sledil je ogled filma na temo umetna inteligenca. Po ogledu smo se pogovorili o njihovem pogledu in razumevanju umetne inteligence. S takim pristopom so bili dijaki zelo zadovoljni.

Naslednja tema so bili Ekspertni sistemi. Tudi tu smo si ogledali film in se o njem pogovorili. Ker se je izkazalo, da so imeli pri strokovne terminologiji težave, smo ji posvetili nekaj več časa.

Temo Faze odločitvenega procesa smo obravnavali ob razlagi konkretnega primera. Najprej sva poskusili samo s teoretično razlago, pa se je izkazalo, da tak pristop za dijake ni primeren. Priporočava, da učitelj skupaj z dijaki obdela več primerov, ki so jim blizu. Dijaki morajo dobiti domačo nalogo. Poglobiti se morajo v primer in ga razčleniti: nalogo potem v razredu prediskutirajo in model po potrebi popravijo, dopolnijo in razložijo, zakaj tako. Spremenijo naj vrednost vsaj enega od kriterijev in ugotavljajo, kako to vpliva na rezultat. Delo se spremeni v eksperimentiranje in dijake spodbuja k razmišljanju.

Zadnji del je izdelava odločitvenega modela v večparameterskem programu DEXi. Tu smo porabili največ časa. Dijaki so delo s programom DEXi dobro sprejeli.

Zaključek dela je bila projektna naloga, ki so jo dijaki izdelali delno v šoli delno pa doma. Oddali so pisno poročilo in elektronsko verzijo odločitvenega modela z vrednotenjem variant. Nalogo so predstavili v razredu z elektronskimi prosojnicami.

Dijaki so za projektno nalogo dobili tri ocene: za sam model, za pisno poročilo in za predstavitev. Pisnega preverjanja letos nisva izvajali.

### **Zvonko Kustec, Gimnazija Franca Miklošiča, Ljutomer**

V projekt Uvajanje tehnologij znanja v predmet informatika se je prijavilo 26 dijakov, ki so v drugem letniku obiskovali predmet informatika. Po začetnih urah, ki so potekale izven pouka 8. in 9. šolsko uro, se je oblikovala skupina 15 dijakov, s katerimi smo preizkusili cel model.

Teme so jih pritegnile, gradivo so dijaki iskali po internetu in ga predstavili v obliki referata, nakar je sledila diskusija.

Težave smo imeli pri temi »Kako človek procesira podatke«, kar bi morali spoznati že pri psihologiji, ki jo poslušajo v drugem letniku, a nam tema nekako »ni ležala«.

Pripombe so imeli tudi v zvezi s programom za večparametrsko odločanje, saj bi želeli izdelati masko za vnos podatkov v odločitveni model, pa program tega zaenkrat ne omogoča.

Zaradi narave načina izvajanja projekta dijakov nisem ocenil, če pa bi jih, bi osem ocenil odlično, druge pa prav dobro.

### **Edi Kuklec, Gimnazija Ljubljana Šiška**

Ker nismo imeli oddelka za izvajanje pouka, smo delali malo drugače. Tako kot pri projektu Timko smo preizkušali fakultativni pristop. Dijaki so se prostovoljno prijavljali k fakultativnemu predmetu informatika. Sodelovanje pri tem projektu smo ponudili predvsem dijakom tretjega letnika, lahko pa so se pridružili tudi posamezniki iz drugih letnikov. Tako se je nabralo devet dijakov iz različnih oddelkov, ki so sodelovali pri projektu celo leto.

Na začetku smo imeli štiri popoldanska večurna srečanja, na katerih sem dijakom predstavil idejo tehnologij znanja in orodja za njihovo implementacijo. Sprehodili smo se skozi uvod v tehnologije znanja, umetno inteligenco in modele miselnih procesov, ekspertne sisteme ter faze odločanja. Na koncu so spoznali še orodje Dexi.

Potem so dijaki samostojno razvijali svoj odločitveni model, k meni pa so hodili le na posvet. Sodelovali so dijaki z različno usposobljenostjo za tako delo, zato so bili tudi modeli in kasnejše rešitve različne. Izkazalo se je, da ni pomembno, iz katerega letnika je dijak, ampak ali ima smisel za tak pristop k odločanju. Tako velja razmisliti, ali ne bi v bodoče ponudili del teh vsebin tudi v drugem letniku.

Na koncu so dijaki izdelali vsak svoj odločitveni model z lupino Dexi. Dijake sem usmerjal k uporabnosti rešitev, tako da so lahko rešitve preverili tudi v življenjskih okoliščinah. Najbolj napredne pa sem usmerjal k bolj kompleksnim rešitvam in »mehki« logiki. Ukvarjanje z »mehko« logiko je bila za večino pretrd oreh, hitro pa so obvladali samo manipulacijo in izdelali »trde« rešitve.

Na koncu so dijaki predstavili svoje izdelke svojim sošolcem. Prisotni so bili tudi drugi dijaki in ne samo tisti iz skupine. Tako je bilo treba predstaviti rešitev tako, da so jo razumeli tudi laiki in ne samo »eksperti« za tehnologije znanja.

### **mag. Simon Muha, Šolski center Velenje, Poklicna in tehniška elektro in računalniška šola**

V šolskem letu 2000/2001 se je v izdelavo projektov vključilo 12 dijakov (1., 2. in 3. letnika) Šolskega centra Velenje, Poklicne in tehnične elektro in računalniške šole. Izvajanje projekta je obsegalo 16 ur, ki so se dijakom lahko šttele tudi k obveznim izbirnim vsebinam.

Dijakom so bila predstavljena znanja:

- iz tehnologij znanja,
- iz faz odločitvenega procesa,
- iz izdelave odločitvenega modela in
- iz izdelave večkriterijskega odločitvenega modela s pomočjo računalniškega programa DEXi.

Dijaki so izdelali projektne naloge z naslednjimi naslovi: Izbira GSM telefona (2x), Izbira avtomobila, Izbira poletnih počitnic, Izbira zaključnega izleta (2x) in Izbira učitelja.

Dijaki pri izdelavi pokazali veliko zavzetost, saj so manjkali največ enkrat. Veliko dela in pogovorov so opravili tudi doma oz. izven predvidenih ur.

### **Nastja Lasič, Gimnazija Šentvid, Ljubljana**

Projekta sem se lotila z dijaki četrtega letnika, ki so izbrali informatiko kot izbirni predmet. Na začetku smo ponovili snov prvega letnika, predvsem uporabo Worda in Exela, nato pa smo se lotili sklopa uporabe novih tehnologij predvsem z vidika pomoči pri odločanju.

Na začetku smo se pogovarjali o tem, kako sami uporabljajo računalnik, kako in zakaj uporabljajo informacijsko tehnologijo. Izkazalo se je, da uporabljajo računalnik večinoma za pisanje različnih poročil in referatov, za obdelavo slik ter za brskanje po internetu in pošiljanje elektronske pošte. Nato smo si ogledali video, kjer sem dijake opozorila, da sledijo možnostim uporabe informacijske tehnologije v različne namene. Celoten film je za predvajanje pri uri nekoliko predolg, posamezni izseki filma pa so zelo zanimivi.

V nadaljevanju sem poskušala predstaviti primer uporabe računalnika na višjih ravneh, zato smo se kar hitro spoznali z metodami odločanja in uporabe računalnika pri odločanju.

Želela sem, da dijaki sami postavijo enostaven problem ob katerem bomo spoznali metode za pomoč pri odločanju. Tako smo začeli z nakupom kruha. Dijaki so kmalu začeli spoznavati težave, ki nastopijo pri odločanju. Skupina je bila velika in kmalu so se pokazala različna mnenja o parametrih in vrednosti parametrov, ki smo jih upoštevali pri nakupu kruha. S tem primerom sem predvsem hotela pokazati, da odločanje nikakor ni enostaven proces.

Naslednji primer, ki smo si ga skupaj ogledali, je bil nakup računalnika. Primer smo si pogledali najprej z modelom Abacon, nato smo ga reševali s pomočjo preglednic in nazadnje z uporabo programa Dexi.

Dijaki so samostojno izdelali enostaven primer po svoji želji z uporabo vseh treh metod. Primeri so bili zelo enostavni z uporabo 5-8 kriterijev, opisati pa so morali 3 variante.

Najpogostejši komentarji o uporabi teh metod so bili:

- Porabili so več časa, kot bi ga, če bi se kar na pamet odločali za neko rešitev.
- Izbira izmed treh variant je lažja brez uporabe metod.
- Veliko je težav pri določanju kriterijev.
- Dijaki so imeli težave pri objektivnem določanju vrednosti kriterijev.
- Na začetku so se morali seznaniti s programom Dexi.

O vseh teh dilemah smo se z dijaki pogovorili. Pred izdelavo končnega projekta smo sistematično razdelili proces reševanja takih problemov od načinov določanja kriterijev, združevanja kriterijev v drevesno strukturo do določanja merskih lestvic in drugo.



Kot končni izdelek so morali dijaki izdelati model za zapletenjši problem z izbiro med najmanj 10 variantami. Za določanje kriterijev so porabili kar nekaj časa, z različnimi idejami o kriterijih za posamezne naloge so sodelovali tudi med seboj. Ko je bil projekt zaključen so izdelali poročilo. Na koncu so dejali, da šele sedaj dejansko vidijo smiselnost uporabe računalnika in različnih metod pomoči pri odločanju. Dijaki so bili nad končnimi izdelki zelo navdušeni.

Problemi, ki so jih reševali, pa so bili: nakup avtomobila, izbira stanovanja, izbira prostora za gradnjo hiše, izbira počitnic, nakup mobilnega telefona, glasbenih stolpov in drugih izdelkov. Zelo zanimiva je bila naloga izbire najboljšega dekleta.

Mislim, da so bili na koncu dijaki z delom zelo zadovoljni.

**Analiza preizkusa** učnega modela, ki smo jo izpeljali tudi s pomočjo vprašalnika z enajstimi učitelji in 206 dijaki iz sodelujočih šol, je pokazala vsaj dvoje:

1. Vsebina je za dijake zanimiva, z razumevanjem pripravljene snovi niso imeli težav. Področje umetne inteligence je sicer že samo po sebi privlačno, večinoma pa so svoje predstave o tem, kaj umetna inteligenca je, in področjih uporabe UI temeljito spremenili.
2. Do tega dela pouka so IKT uporabljali le na prvih treh ravneh uporabe, na možnost četrte niso pomislili.

Praktični del pouka, gradnja odločitvenih modelov, je dijakom pripomogla k več spoznanjem:

- ⇒ Vsak problem, ki ga želimo reševati s pomočjo računalnika, je potrebno najprej temeljito razumeti, da lahko naredimo model, ki bo čimbolj ustrezal realnosti.
- ⇒ Modeli so lahko kvalitativni, ki delujejo tudi ob nepopolnih, mehkih podatkih.
- ⇒ Rešitev, ki jo predlaga računalnik, je samo tako dobra, kot je dober model. Rešitve je potrebno preveriti in pretehtati šibke točke modela in tudi možnosti, da se posamezni pogoji lahko spreminjajo. Za to imajo na voljo dovolj preprosta računalniška orodja.
- ⇒ Ob upoštevanju metod UI lahko ljudje svoje kompleksne miselne procese s pomočjo IKT podprejo do takšne mere, da minimizirajo možnosti napake.
- ⇒ Kljub čedalje večjim strojnim sposobnostim IKT in kljub čedalje večjim bazam znanja in tudi vgrajenimi najrazličnejšimi algoritmi umetne inteligence pa so vse to le pripomočki, ki jih lahko uporablja samo tisti, ki ima dovolj znanja o področju, na katerem deluje, in znanja o sodobni metodologiji in tehnologiji. V končni fazi so za dejanja odgovorni ljudje, ki tudi nosijo posledice, in ne naprave.

Glede na poročila so bile predlagane oblike dela pri učiteljih in dijakih dobro sprejete. Delo z večjim poudarkom na učnem procesu in odgovornosti dijakov se je tudi pri rezultatih preverjanja in ocenjevanja izkazalo kot učinkovito.

**V nadaljevanju** je treba dopolniti učno gradivo s sodobnimi videoposnetki, zbirko primerov obogatiti tako, da bo vključevala konkretne primere iz drugih predmetnih področij. Tako bi lahko neposredno pokazali na uporabnost vključevanja gradnje baze znanja oziroma odločitvenih modelov kot metodo poučevanja tudi pri drugih

predmetih, širili kulturo odločanja in pospeševali uporabo IKT za boljšo izkoriščenost človekovih miselnih procesov.

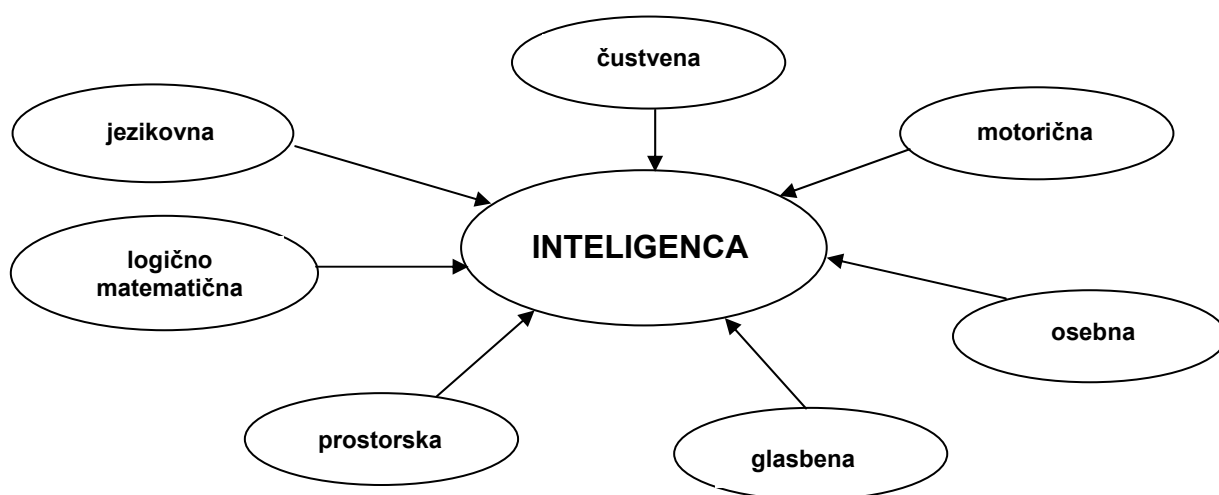
Smiselno bi bilo tudi nadaljevati razvoj programa za večparametersko odločanje DEXi. Zlasti v smislu možnosti za izdelavo maske, ki bi se uporabljala za bolj pregleden vnos vrednosti parametrov posamezne variante. Dobrodošla pa bi bila uporaba DEXi-jevih modelov na dlančniku in v omrežju.

Izvajanje pouka po tem modelu je treba slediti tudi v naslednjih letih, dopolnjevati učno gradivo in iskati še učinkovitejše oblike dela z dijaki.

## 5. Izbrana poglavja področij umetne inteligence

Umetna inteligenca (UI) proučuje inteligentno vedenje umetnih sistemov, ki vključuje zaznavanje, mišljenje, učenje, komunikacijo in odzivanje v kompleksnem okolju. Dolgoročni cilj UI, ki ga ima mnogo znanstvenikov za nedosegljivega, je, da bi razvila umetni sistem, ki bi z učenjem dosegel ali celo presegel naravno inteligenco. Drugi cilj je razumevanje inteligentnega obnašanja tako pri ljudeh, kot pri živalih in strojih. (Nilsson, 1998)

Kaj je inteligentno obnašanje, je še vedno tema znanstvenih razprav. Danes govorimo o različnih vrstah inteligence. Gardner (1993) je opredelil jezikovno inteligenco, glasbeno inteligenco, logično matematično inteligenco, prostorsko inteligenco, motorično inteligenco in osebno inteligenco. Omeniti pa velja še čustveno inteligenco.



**Slika 15: Vrste inteligence**

Malo verjetno je, da bi imel vsak človek enako dobro razvite vse vrste inteligence. Seveda pa bo lažje razvil razumevanje s področja, kjer ima bolj razvito inteligenco.

Tudi zaradi različnega razumevanja pojma inteligenca so cilji in pričakovanja do umetne inteligence v javnosti marsikdaj nerealni.

Pri razvoju umetne inteligence lahko govorimo o **dveh pristopih**:

Prvi temelji na prepričanju, da je **manipulacija s simboli** osnova miselnih procesov. Simboli so abstraktne entitete; njihov pomen predstavlja določen zunanji pojav. Simbole lahko shranjujemo in prikličemo v računalniku. Prav tako lahko oblikujemo pravila, kako ravnati s simboli. Na tem prepričanju temeljijo sistemi, ki temeljijo na znanju, prav tako pa tudi celotno klasično računalništvo. Računalnik je tako formalni sistem za manipulacijo s simboli. Idejo, da inteligenca vključuje logično manipulacijo s simboli, sta v svojih delih razvila že Descartes in Leibniz.

Alternativno mnenje (razvili so ga v sredini 20. stoletja) pa zagovarja tako imenovani **mrežni pristop**. Zagovarja prepričanje, da inteligenca ne temelji na manipulaciji s simboli, temveč namesto tega poskuša modelirati procese, ki se odvijajo v človeških možganih.

## 5.1. O razvoju umetne inteligence

Na UI vplivajo dognanja različnih ved: filozofije, matematike, jezikoslovja, biologije, psihologije in računalništva. Sam izraz »umetna inteligenca« so prvič uporabili na računalniški konferenci 1956 v Dartmouthu.

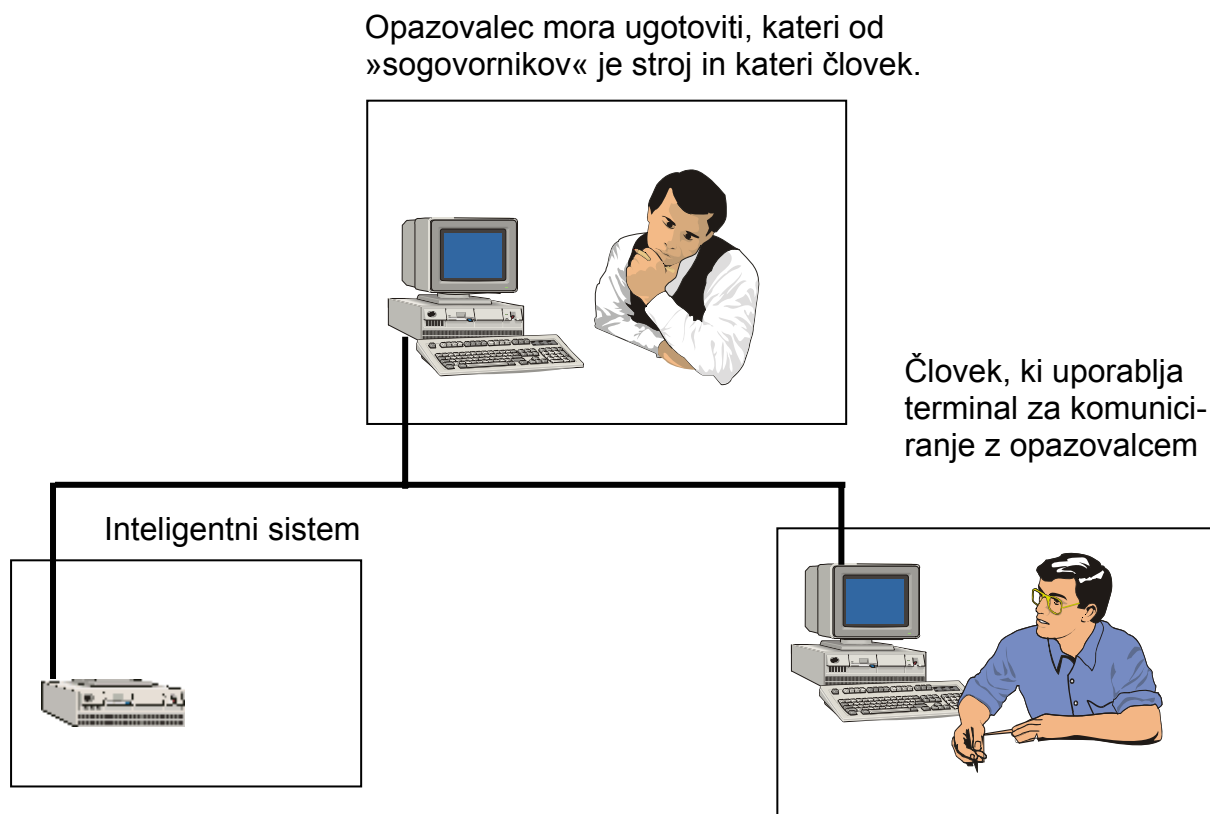
**Razmerje med človekovim umom in stroji** je vznemirjalo filozofe vse od Platona in Sokrata dalje. Razvili sta se **dve teoriji mišljenja**:

Prva (mind-as-machine) verjame, da je **človeški razum kot stroj** in je kot vsak fizični stroj podvržen vsem zakonitostim narave. Zato je načeloma možno izdelati napravo s podobnimi sposobnostmi, kot jih imajo človeški možgani.

Druga teorija (mind-beyond-machine), ki prvi nasprotuje, trdi, da **ni mogoče narediti racionalnega modela človeških možganov** in zato tudi stroja ne, ki bi imel podobne sposobnosti, saj nekaterih vidikov človeškega uma, kot so občutki in čustva, ni mogoče logično predstaviti.

Prva teorija verjame, da so tudi občutki in čustva logični miselni procesi, ki jih vodijo kompleksni algoritmi in cilji, ki pa si jih zaenkrat še ne znamo razložiti.

Alan Turing je 1950 postavil tako imenovani Turingov test inteligentnosti stroja. Če opazovalec ne ugotovi, kateri od sogovornikov je stroj, potem lahko rečemo, da je računalniški sistem inteligenen.




**Slika 16: Turingov test: ali lahko računalnik na levi prevara opazovalca?**

Preizkušanje različnih teorij je omogočila ustrezno razvita tehnologija. Leta 1946 je bil zgrajen prvi elektronski računalnik ENIAC. Šele razvoj in uporaba polprevodniških tehnologij pa je omogočila gradnjo dovolj zmogljivih računalnikov za sisteme UI. Prvi programi, ki so lahko reševali preproste miselne probleme, so bili napisani v

petdesetih letih, med njimi programi, ki lahko igrajo šah (Shannon, 1950, Newell, Shaw & Simon, 1958), damo (Samuel, 1957) in programi, ki dokazujejo matematične izreke (Newell, Shaw & Simon, 1957, Gelernter, 1959). John McCarthy je leta 1959 napisal LISP, programski jezik, ki ga z mnogo izboljšavami še danes uporabljajo za pisanje sistemov UI. Osnovni poudarek v tem pionirskem obdobju UI je bil na reševanju **splošnih problemov**. Veliko naporov so vložili v pisanje programov za igranje iger, kot sta šah in dama. Začetni uspehi so bili veliki, pričakovanja o uspešnosti UI pa preveč optimistična. Vseeno je to področje UI doživel leta 1997 izjemen uspeh: program Deep Blue je premagal takratnega svetovnega šahovskega prvaka Garija Kasparova. Vendar ni pomembna zmaga stroja nad človekom. Pomembno je proučevanje principov inteligentnega obnašanja, ki jih lahko dovolj kakovostno izvaja tudi računalnik.

V poznih 60-ih in začetku 70-ih let 20.stoletja je prišlo na področju UI do pomembnega premika. Prišli so do spoznanja, da človeška sposobnost in spretnost izhajata bolj kot iz **uporabe algoritmov** za reševanja splošnih problemov, iz **velikanske količine** tako splošnega kot specialističnega **znanja**. Zato so napore razvoja sistemov UI usmerili v iskanje metod za kodiranje in uporabo specialističnega znanja. Pokazalo se je, da je zelo težko predstaviti velikanske količine znanja kakega področja tako, da bo lahko hitro in preprosto določiti, katera znanja so pomembna za rešitev problema in jih nato uporabiti. Drugi pereči problem v zvezi s predstavitvijo znanja je »vedeti, kaj že veš«. Kot rezultat te usmeritve so nastali tudi ekspertni sistemi.



**Slika 17: Razvoj umetne inteligence (Dutta, 1993)**

Sistemi umetne inteligence niso ostali dolgo samo v akademskih krogih.

Začetnim sistemom UI namenjenim reševanju splošnih problemov in sistemov za igre, kot so šah in dama ali zlaganje kock, kot to počno otroci, so v 70-ih sledili **sistemi, temelječi na ozko specializiranem znanju - ekspertni sistemi**. Sistemi, ki temeljijo na bazah znanja, uspešno pomagajo pri reševanju zapletenih problemov. Eni prvih so bili *ekspertni sistemi* (ES) DENDRAL (ES za napovedovanje strukture

organskih molekul), MYCIN (ES za ugotavljanje vrste bakterij pri bolniku in pripravo predloga za predpisovanje antibiotikov) in INTERNIST (ES za diagnozo na področju interne medicine), Authorizer's Assistant (American Express) – sistem za dodeljevanje kreditov, AL/X (British petroleum) sistem za sprotno diagnosticiranje napak na naftnih ploščadih, PROSPECTOR (ES za rudne in naftno geološke raziskave) sledili so mnogi drugi sistemi, temelječi na znanju, med njimi tudi XCON (1980, sistem za konfiguracijo računalniških sistemov za podjetje DIGTAL), ki pomeni prelomnico na področju sistemov umetne inteligence, saj se je pokazala tudi visoka ekonomska vrednost uporabe tega sistema. Razvili so orodja za razvoj ekspertnih sistemov, tako imenovane lupine ekspertnih sistemov.

V nadaljevanju so na kratko pojasnjeni nekateri pojmi, ki so povezani s pojmom umetna inteligenca in smo jih v vodniku že omenili: več načinov predstavitev znanja, odkrivanje znanja v podatkih, strojno učenje, nevronske mreže, mehki sistemi, evolucijsko računanje in genetski algoritmi, računalniško zaznavanje in robotika.

## **5.2. Predstavitve znanja**

Znanje, ki ga želimo uporabljati v različnih sistemih umetne inteligence, mora biti primerno predstavljeno. Za računalnik, da ga lahko ustrezno obdeluje, in za človeka, da lahko razume rešitve in pot, po kateri je sistem prišel do njih.

Različne predstavitve znanj običajno primerjamo med sabo po naslednjih kriterijih:

- razumljivost,
- modularnost,
- bogastvo možnosti predstavitve,
- možnost različnih načinov sklepanja,
- dopolnjevanje in spreminjanje,
- možnost ponovne uporabe dela baze znanja za drugo področje znanja.

**Za predstavitve znanja obstaja več različnih pristopov. Najpogosteje srečamo:**

- predstavitev znanja s pravili,
- predstavitev znanja z uporabo mrež: semantične mreže,
- predstavitev znanja z uporabo okvirov,
- predstavitev znanja s pomočjo scenarija.

### **PREDSTAVITEV ZNANJA S PRAVILI**

Eden od najstarejših in še vedno pogosto uporabljenih načinov predstavitve znanja je uporaba pravil. Baza znanja je v takem primeru sestavljena iz opisa dejstev oz. podatkov in pravil, ki opisujejo razmerja in razlagajo relacije med temi podatki.

Primer preproste oblike pravil:

*ČE element\_1 IN element\_2 IN element\_3 IN ... IN element\_n*

### POTEM zaključek

Pravila so lahko podana v kompleksnejši obliki:


#### ČE element POTEM zaključek\_1 SICER zaključek\_2

Lahko pa upoštevajo tudi verjetnostni faktor:


#### ČE element POTEM zaključek (z verjetnostjo 0,9)

Z verjetnostjo lahko podajamo tudi vrednost elementov. Zaključki so tako ob upoštevanju verjetnosti bolj realni.

Proces sklepanja v sistemih, ki imajo predstavljeno znanje s pravili, lahko poteka po dveh osnovnih poteh. Glede na niz podatkov in pravil, ki povezujejo te podatke, ugotovljamo cilj. Temu načinu sklepanja pravimo **veriženje naprej**. Drug način imenujemo **veriženje nazaj**. Pri tem načinu določimo cilj, ki naj bo izpolnjen, potem pa poskusimo glede na pravila poiskati podatke v bazi, ki potrjujejo vrednost cilja.



Slika 18: Veriženje naprej



Slika 19: Veriženje nazaj

Vsako pravilo predstavlja majhen, relativno neodvisen del znanja. Pravila je enostavno dodajati. V pravila je možno vgraditi hevrstiko<sup>2</sup>, ki je pomemben element implicitnega znanja, in kombinacijo *stanje* - *akcija*. Tak sistem omogoča razlago, kako je prišel do rešitve in zakaj so določeni podatki potrebni. Razlagi je preprosto slediti, saj ustreza človekovemu načinu razmišljanja in sklepanja.

---

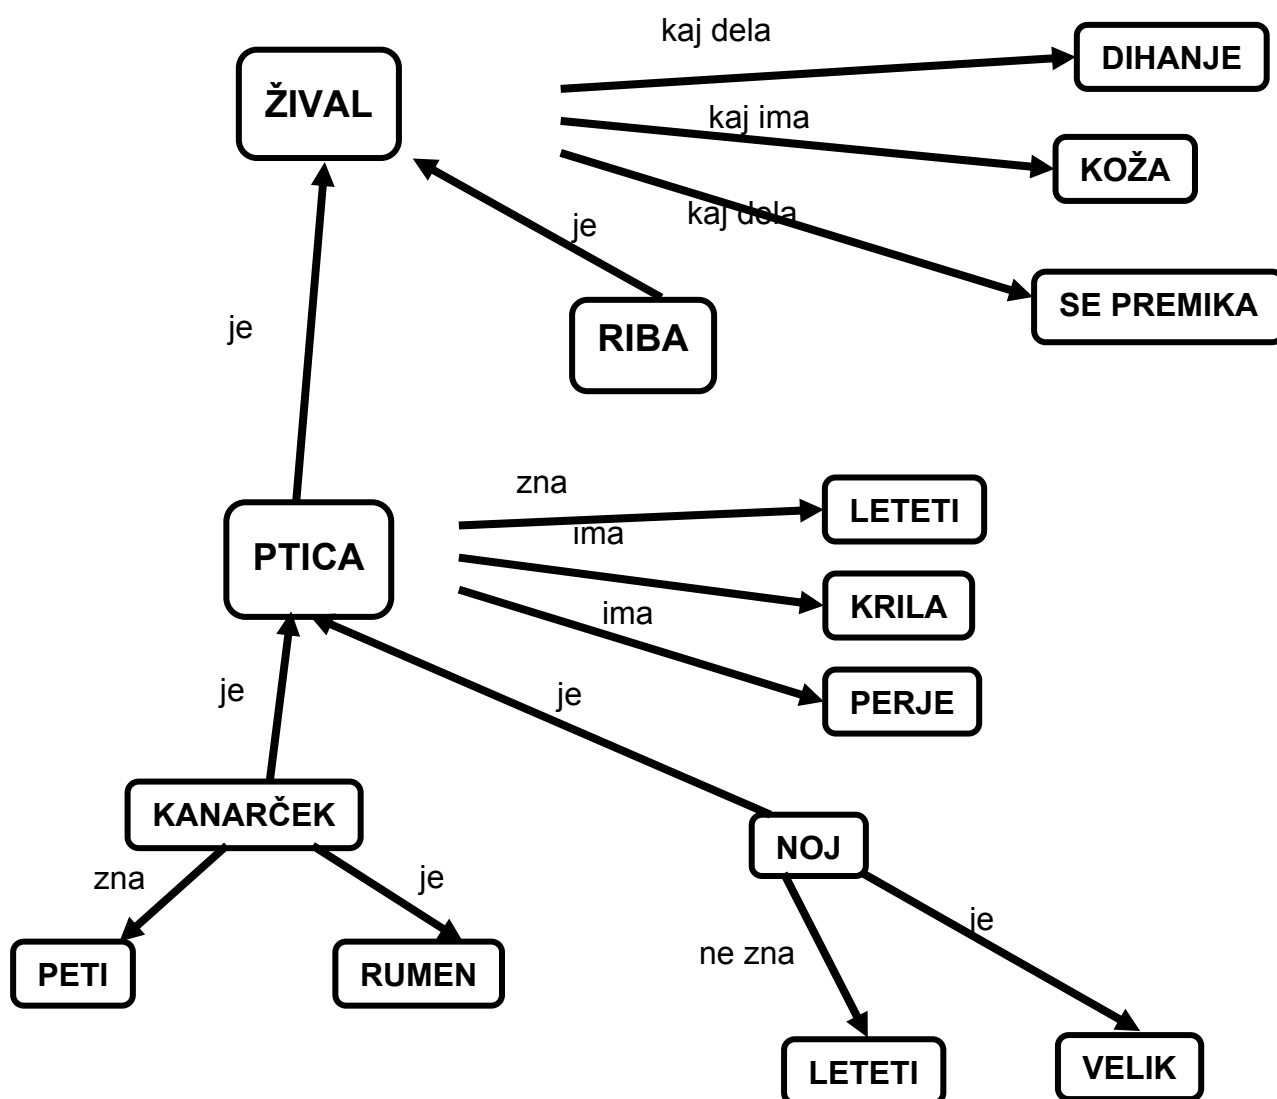
<sup>2</sup> Hevrstika je princip reševanja problema, ki nas po bližnjici pripelje do dobre ali celo optimalne rešitve. Pri tem upošteva specifična znanja kakega področja. Tako se izognemo neperspektivnim poskusom iskanja rešitve.

Vendar s pravili težko opisujemo zapletene odnose med večjo množico elementov. Pri veliki bazi znanja postane tak sistem nepregleden, samo procesiranje pa počasno.

Primer programskega jezika, ki je namenjen gradnji sistemov, ki imajo znanje predstavljeno s pravili, je Prolog (Bratko,1982).

### PREDSTAVITEV ZNANJA Z MREŽAMI: SEMANTIČNE MREŽE

Človekov dolgotrajni spomin je organiziran v mreže asociativno povezanih pomenskih enot. Govorimo o miselnih vzorcih in njihovih povezavah. Semantične mreže so poseben primer množice mrežnih shem za predstavitev znanja. Vsem so skupna vozlišča in povezave med njimi, ki so označena. Vozli običajno predstavljajo objekte, koncepte, dogodke in njihove lastnosti, povezave pa relacije med njimi.



Slika 20: Primer semantične mreže



Preprost proces sklepanja v sistemu z znanjem predstavljenim s semantično mrežo je sprehajanje po povezavah med vozli in iskanje posameznih delov mreže, ki ustrezajo določenim zahtevam.

Privlačna lastnost semantičnih mrež je, da jih je preprosto brati in razumeti, vendar pri obsežnejši mreži izgubimo preglednost. Za povečanje preglednosti je smiselno vozle in povezave strukturirati. Tak princip predstavitve znanja uporablja predstavitev z okviri.

## **PREDSTAVITEV ZNANJA Z OKVIRI**

Okvir predstavlja objekt, ki je lahko opisan s svojo zgradbo in vedenjem. Zgradba je nabor lastnosti (v angleščini uporabljajo izraz slot) in pripadajočih vrednosti, ki razlagajo objekt oz. entiteto s področja znanja, ki ga opisujejo. Okviri so med seboj hierarhično povezani. Povezava vsebuje tako dedovanje kot specializacijo (inheritance-specialisation hierarchy). Predstavitev z okviri pozna pojma razred in podrazred. Podrazred in primerki dedujejo lastnosti in vrednosti od nadrejenih razredov (staršev). Specializacija pa se nanaša na določitev specifičnih lastnosti podrazredov in primerkov, ki jih predniki nimajo. To omogoča razločevanje med specifičnimi primerki in podrazredi. Komponenta, ki opisuje vedenje, (metoda) določa reakcijo objekta v različnih situacijah. Vsaka lastnost je lahko še dodatno strukturirana. Posamezni objekti lahko med seboj komunicirajo s sporočili in tako sprožijo določeno vedenje (metodo) pri objektu, ki je sporočilo prejel.

Predstavitev s pomočjo okvirov omogoča grafično predstavitev znanja, modularnost in zaradi dedovanja zgoščen zapis, četudi opisuje kompleksno področje znanja. Omogoča zelo pestre načine predstavitev tako lastnosti kot vedenja, zaradi hierarhije omogoča predstavitev tako imenovanega »globokega« znanja kateregakoli področja znanja. Ker je omogočeno komuniciranje med objekti, je tudi mehanizem sklepanja bolj raznolik kot pri pravilih. Dopolnjevanje in spreminjanje modularnih sistemov je bolj preprosto kot pri sistemih, ki temeljijo na pravilih. Dele znanja, predstavljenega z okviri, je lahko prenesti v drug sistem.

Slabosti predstavitev z okviri, in tudi predstavitve znanja s pravili, so slaba sposobnost prepoznavanja vzorcev, nezmožnost učiti se in občutljivost sistema.

Primer programskega orodja za predstavitev znanja z okviri je Kappa (Dutta, 1993).

## **PREDSTAVITEV ZNANJA S POMOČJO SCENARIJA**

Za predstavitev znanja pri prepoznavanju in razumevanju naravnega jezika za ozko omejena specializirana področja se uporablja predstavitev znanja s pomočjo scenarija (scripts). Način zapisa je podoben okvirom. Z njim opisujemo stereotipne situacije, kot na primer dvigovanje denarja na bankomatu. Scenarij določa vloge, nastopajoče elemente, povezane vhodne in izhodne pogoje, ki določajo začetna in končna stanja.

**In kako je znanje predstavljeno pri DEXi-ju?** Govorimo lahko o kombinaciji posebne semantične mreže, to je drevesa kriterijev, in pravil, s katerimi so po točkah podane funkcije koristnosti v vozlih drevesa. Pravila podajajo medsebojno odvisnost kriterijev in njihov vpliv na neposredno nadredne vozle v drevesu.

### 5.3. Odkrivanje znanja v podatkih in podatkovno rudarjenje

Tehnološki napredek na področju IKT je omogočil shranjevanje čedalje večje količine podatkov o poslovnem svetu in o različnih raziskavah na vseh področjih človeškega delovanja, pa tudi njihovo dostopnost. Z analizo podatkov poskušajo v njih najti vzorce oziroma še neznane zakonitosti: novo znanje.

Odkrivanje znanja iz podatkov (Knowledge Discovery from Data) je proces odkrivanja doslej neznanega in potencialno uporabnega znanja iz podatkov. Del tega procesa je tako imenovano podatkovno rudarjenje (Data Mining), ko dejansko pride do odkrivanja znanja (Groth, 2000).

Faze odkrivanja znanja iz podatkov so:

- priprava podatkov,
- podatkovno rudarjenje,
- interpretacija, vrednotenje in predstavitev pridobljenega znanja.

Podatke za podatkovno rudarjenje največkrat zajemamo iz podatkovnih baz ali iz **podatkovnih skladišč**. Podatkovna skladišča tvorita programska in strojna oprema, ki shranjuje časovne serije transakcijskih podatkovnih baz (gospodarskih podjetij, zdravstvenih ustanov, ...) za nadaljnje analize in arhiviranje (Alter, 1999).

Za odkrivanje znanja iz podatkov se uporablja raznovrstne metode umetne inteligence: simbolično induktivno učenje odločitvenih dreves ali odločitvenih pravil, genetske algoritme, nevronske mreže itd, pa tudi različne statistične metode. Nekatere od teh so opisane v nadaljevanju. Katero metodo reševanja problemov izberejo, je odvisno od vrste problema in oblike, v kateri želijo predstavljeno rešitev. Pomembna je tudi točnost, s katero tako zgrajen model rešuje probleme. Točnost izboljšujejo s ponovnim pregledom in pripravo podatkov ali/in z izbiro druge metode podatkovnega rudarjenja.

Odkrivanje znanja v podatkih uporabljajo na najrazličnejših področjih: pri trženju in odnosih z javnostjo, pri analizi poslovnih partnerjev in strank, pri analizi poslovanja in proizvodnje, pri odkrivanju in predvidevanju zlorab, pri znanstvenih raziskavah na različnih področjih, pri obdelavi anket in javnomnenjskih raziskav, ...

### 5.4. Strojno učenje

Zmožnost učenja je ena od osnovnih lastnosti inteligentnih sistemov. Na področju umetne inteligence predstavlja *avtomatsko* ali *strojno učenje* pomembno vejo raziskav. Njen namen je omogočiti reševanje problemov, ki zahtevajo specifično znanje in tudi razumevanje naravnega učenja ter inteligence. S strojnim učenjem se lahko sistemi učijo in izpopolnjujejo na različnih področjih.


Znanje, ki ga generirajo sistemi za strojno učenje, lahko uporabimo pri računalniškem prepoznavanju slik in zvoka, za razumevanje naravnega jezika, pri avtomatskem sklepanju in dokazovanju izrekov, pri hevrističnem reševanju problemov, uveljavlja pa se tudi na drugih področjih umetne inteligence.

Tak primer so tudi sistemi, ki temeljijo na znanju. Bazo znanja lahko namreč zgradimo ročno, kar je v splošnem zamudno in dostikrat tudi nekonsistentno, kot smo omenili na koncu poglavja Uporaba različnih pripomočkov pri odločanju, ali pa s

pomočjo algoritmov za strojno učenje, če je le na voljo dovolj podatkov o rešenih primerih.

Pri sistemih za strojno učenje razlikujemo med *učnimi algoritmi*, s pomočjo katerih se sistem uči, kar pomeni, da iz množice primerov tvori novo oziroma popravlja staro znanje, in *izvajalnimi algoritmi*, ki to znanje uporabljajo za reševanje problemov. Avtomatsko naučeno znanje predstavlja *model*.

*Predznanje* je množica možnih rešitev (modelov) in kriterij optimalnosti, ki ga bo sistem med učenjem skušal izpolniti.



**Slika 21: Shema sistema za strojno učenje**

Metode strojnega učenja lahko razdelimo na:

- simbolično induktivno učenje (učenje odločitvenih dreves, odločitvenih pravil, indukcija logičnih programov, učenje konceptov ...),
- statistične metode in
- umetne nevronske mreže.

#### 5.4.1. Simbolično induktivno učenje

Pri simboličnem induktivnem učenju gre za to, da iz množice podatkov z rešitvami nekega problema, določimo splošno pravilo, s katerim lahko rešujemo nove primere (na primer dodeljevanje kreditov). V simbolično induktivno učenje sodijo: gradnja odločitvenih dreves in odločitvenih pravil ter induktivno logično programiranje.

Za vsako od teh aktivnosti je razvitih več algoritmov.

Razred C	C	A <sub>1</sub>	A <sub>2</sub>	...	A <sub>N</sub>	}	Atributi
	C <sub>1</sub>	V <sub>1,1</sub>	V <sub>1,2</sub>	...	V <sub>1,N</sub>		
	C <sub>2</sub>	V <sub>2,1</sub>	V <sub>2,2</sub>	...	V <sub>2,N</sub>	}	Vrednosti atributov
	...						
	C <sub>M</sub>	V <sub>M,1</sub>	V <sub>M,2</sub>	...	V <sub>M,N</sub>		

**Slika 22: Tabela rešenih primerov z atributi od A<sub>1</sub> do A<sub>N</sub>**

Naloga je iz podatkov poiskati pravilo za razred C.

Kot učni primeri za **odločitveno drevo** so podatki, podani v obliki tabele, in sicer tako, da vsaka vrstica vsebuje attribute enega učnega primera. Primer prikazuje tabela 9. Program gradi iz teh podatkov odločitveno drevo. Razlikujemo med regresijskimi odločitvenimi drevesi, kjer je v listih drevesa zvezni atribut, in klasifikacijskimi odločitvenimi drevesi, kjer je v listih drevesa diskretni atribut. Atributu, ki je v listih, pravimo razred. (Kononenko, 1997, Nilsson, 1998). V notranjih vozliščih so atributi (isti se lahko pojavi večkrat tudi na isti poti od korena do vozlišča), veje predstavljajo vrednosti atributov (na vsakem vozlišču se testira vrednost atributa).

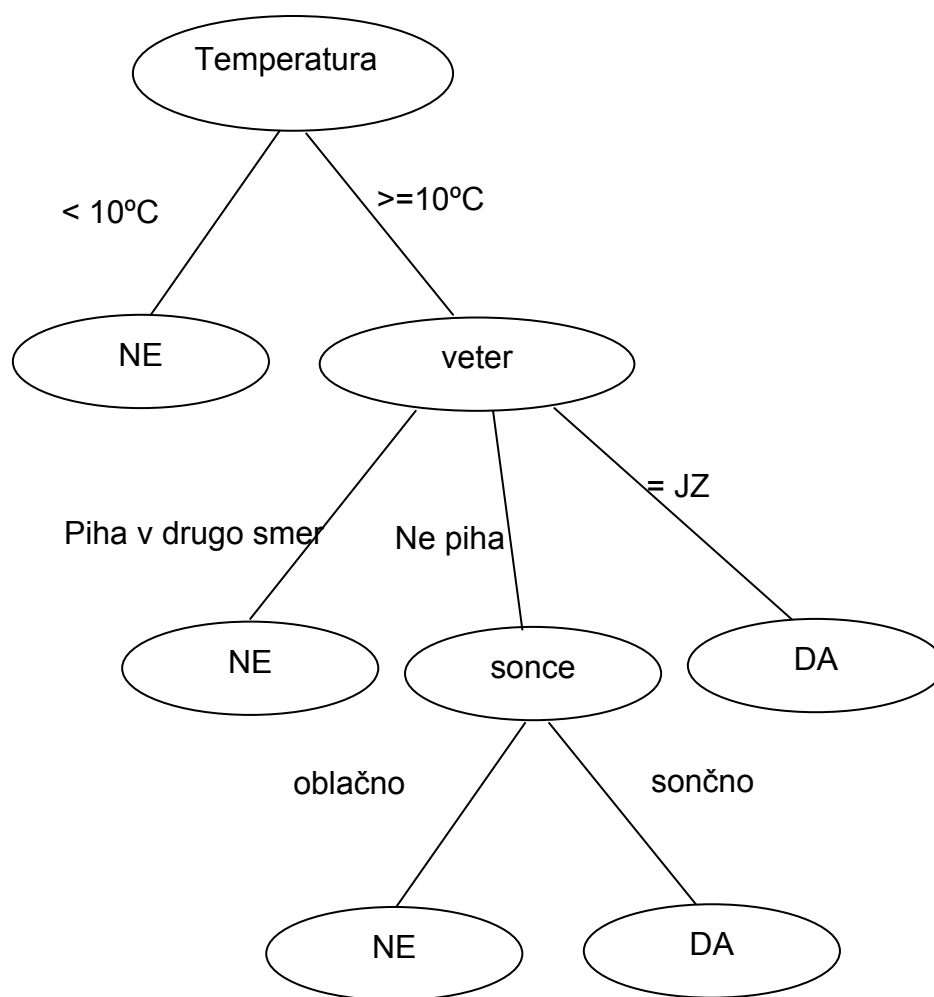
Razred					Atributi
	Gremo jadrat	Temperatura °C	Veter (smer)	Sončno	
	ne	15	ni	ne	
	da	20	JZ	da	
	da	31	ni	da	
	ne	12	S	da	Vrednosti atributov
	ne	5	JV	ne	
	ne	0	S	da	
	ne	-1	ni	da	
	da	10	JZ	ne	
	ne	16	SV	da	
	ne	9	JV	da	
	da	21	ni	da	
	ne	18	S	ne	
	da	19	ni	da	

**Tabela 5: Tabela rešenih primerov za odločitev Gremo jadrat?**

Ko je odločitveno drevo zgrajeno, ga lahko uporabimo za klasifikacijo novih primerov. Začnemo pri korenu in potujemo po ustreznih vejah do lista. Odgovor je razred ciljnega lista.

Pri gradnji odločitvenih dreves igra pomembno vlogo ocenjevanje kakovosti vsakega koraka. Ocene kakovosti temeljijo na različnih funkcijah, ki so namenjene usmerjanju iskanja pri klasifikacijskih in relacijskih problemih (Kononenko, 1997).

Vsako odločitveno drevo lahko spremenimo v množico **odločitvenih pravil**. Vsaka pot od korena do lista ustreza enemu odločitvenemu pravilu. Ni pa možno vsake množice odločitvenih pravil združiti v drevo, zato je predstavitev znanja s pravili bolj prožna kot z odločitvenimi drevesi. Algoritmi za generiranje odločitvenih pravil iterativno gradijo odločitvena pravila in izločujejo učne primere, ki jih zgrajeno odločitveno pravilo pravilno klasificira, dokler ne klasificirajo vseh učnih primerov.



**Slika 23: Primer klasifikacijskega odločitvenega drevesa (Gremo jadrat?)**

Pri **induktivnem logičnem programiranju** izpelje učni algoritem program npr. v prologu na osnovi dveh množic učnih primerov (v bistvu je to zaporedje stavkov, ki opisuje ciljno relacijo in ne program v pravem pomenu besede). Prva množica vsebuje pozitivne učne primere, druga pa negativne. Poleg tega uporablja učni algoritem tudi predznanje, ki je podano v obliki množice dejstev ali pa programskih stavkov. Predznanje je sestavljeno iz množice relacij, ki jih sme algoritem uporabiti za izpeljavo ciljne relacije (Kononenko, 1997). Cilj učnega algoritma je izpeljati čim preprostejšo ciljno relacijo, ki pokriva vse pozitivne učne primere in ne pokriva nobenega negativnega učnega primera.

#### **5.4.2. Statistične metode**

Statistične metode so bile kot matematične osnove razvite že pred uporabo elektronskih računalnikov. Med metodami, ki se uporabljajo pri strojnem učenju, naj

omenimo: Bayesov klasifikator, naivni Bayesov klasifikator,  $k$ -najbližjih sosedov in diskriminantno analizo.

Za **Bayesov klasifikator** velja, da je verjetnost napačne klasifikacije minimalna. Teoretično je to najboljši klasifikator, ki bi ga lahko dosegel katerikoli učni algoritem. Najboljši je tisti učni algoritem, ki najbolje aproksimira Bayesov klasifikator. (Več o tem lahko preberete v Kononenko, 1997)

**K-najbližjih sosedov** je metoda strojnega učenja, ki kot znanje shrani kar same učne primere. Za dani novi primer poišče algoritem v dani množici učnih primerov  $k$  najbližjih, najbolj podobnih primerov in oceni verjetnostno porazdelitev iz relativne porazdelitve teh  $k$  primerov po razredih. V najpreprostejši varianti te metode priredi algoritem novemu primeru kar razred, ki mu pripada večina od najbližjih sosedov. Izpopolnjena metoda upošteva uteževanje vpliva učnih primerov na razvrstitev novega primera glede na razdaljo.

Pri **diskriminantni analizi** iščemo diskriminantne funkcije za reševanje danega klasifikacijskega razreda. Diskriminantne funkcije implicitno opisujejo mejne ploskve med posameznimi razredi v  $n$  dimenzionalnem prostoru,  $n$  je število atributov. Uporabljamo več vrst diskriminantnih funkcij. Poleg analitične rešitve lahko uporabljamo za iskanje diskriminantne funkcije tudi nevronske mreže.

## 5.5. Nevronske mreže

Nevronske mreže sodijo med sisteme umetne inteligence, ki imajo sposobnost strojnega učenja.

Umetna nevronska mreža skuša posnemati zgradbo možganov. Sestavljena je iz medsebojno povezanih preprostih procesnih enot – nevronov. Ko nevron sprejme dražljaj – vhodni problem, ga ojači in pošlje sosednjemu nevronu ali pa ga ustavi. Mreža doseže stabilno stanje, ko se širjenje dražljaja po mreži ustavi. To pomeni, da je na izhodu nevronske mreže rešitev. Ključna lastnost nevronske mreže je, da množica enot deluje neodvisno in vzporedno (Dobnikar, 1990).

Pri uporabi nevronske mreže govorimo o treh fazah:

- učenju mreže,
- testiranju,
- uporabi in vzdrževanju.

Pri učenju nevronske mreže se določajo uteži (pragovi) na povezavah med nevroni. Uteži določajo celotno karakteristiko nevronske mreže, spremembe uteži spremenijo naravo odziva sistema. Nevronsko mrežo učimo s pomočjo rešenih primerov.

Če se pogoji uporabe nevronske mreže spremenijo, se lahko ponovno požene algoritem za učenje in z novim naborom rešenih primerov prilagodi delovanje.

Poznamo več vrst nevronskih mrež, ki so lahko realizirane v strojni obliki ali v obliki računalniškega programa. Pri klasificiranju je osnovni kriterij, ali je vhod digitalen ali zvezen. Naslednja delitev mrež je po načinu učenja. Če pri učenju mreže sodelujeta vhodni vzorec in pravilni izhodni vzorec, govorimo o nadzorovanih nevronskih mrežah. Pri nenadzorovanih mrežah pri učenju sodeluje le vhodni podatek, mreža pa

sama generira ustrezen izhod. Vsaka od teh skupin ima več konkretnih možnih rešitev.

Z nevronskimi mrežami rešujemo različne vrste problemov:

- klasifikacije,
- generalizacije in
- razvrščanje.


Pri **klasifikacijskih problemih** se mreža uči iz parov primerov vhodni podatki - rešitev, od nje pričakujemo, da bo med delovanjem naučene vhodne podatke prepoznala, čeprav bodo vsebovali šum.

Pri **generalizaciji** pričakujemo od naučene nevronske mreže, da bo napovedala rezultat za vhodne podatke, ki so drugačni od tistih v času učenja.

Pri **razvrščanju** (clustering) pričakujemo od naučene nevronske mreže, da bo mreža niz vhodnih podatkov razvrstila v ustrezno skupino.

Nevronske mreže so v svoji osnovni arhitekturi lahko eno-, dvo- ali več-nivojske. Kompleksnost problemov, ki so jih zmožne rešiti, se večja s številom nivojev. Vrsta nevronske mreže, število nivojev, število vhodnih, izhodnih in vmesnih nevronov je odvisna od vrste problema, ki ga želimo reševati z nevronske mreže.

Prikažimo tri-nivojski perceptron.



**Slika 24: preprosti tri-nivojski perceptron**

Prvi nivo nevronov, v našem primeru je sestavljen iz štirih nevronov, je vhodni nivo. Nanj so pripeljani štirje analogni vhodi. Izhodi vsakega vhodnega nevrone so hkrati tudi vhodi nevronov v drugem nivoju mreže. To pomeni, da ima vsak od treh nevronov drugega nivoja štiri vhode. Izhodi nevronov drugega nivoja so vhodi tretjega, izhodnega nivoja. Na izhodu imamo dva analogna izhoda. V tem primeru so

vsi nevroni povezani z nevroni iz sosednjih nivojev. Vsaka povezava med nevroni ima svojo utež. Med učenjem se te uteži spreminjajo.

Ko pridejo izhodi predhodnih nevronov na vhod nevrona, se najprej izračuna utežena vsota vseh vhodov s pripadajočimi utežmi. Izhod nevrona se izračuna glede na to uteženo vsoto in glede na prenosno funkcijo nevrona. Obstaja več vrst prenosnih funkcij glede na probleme, ki naj bi jih nevronska mreža reševala. Med pogosto uporabljene prenosne funkcije sodita skočna funkcija in sigmoidna pragovna funkcija (Kononenko, 1997).

Pomanjkljivost nevronske mreže je v tem, da nimajo mehanizma, s pomočjo katerega bi lahko dobljene rešitve razložili. Zaradi tega so manj primerne za uporabo pri odločanju, uspešna pa je njihova uporaba pri prepoznavanju vzorcev.

## **5.6. Mehki sistemi**

V mehke sisteme sodijo mehka logika (fuzzy logic) in mehke množice (fuzzy sets). Pri klasični teoriji množic je neki element član neke množice ali pa ni. Če pripada množici, mu pripišemo vrednost 1 oziroma pravilno, če ne, mu pripišemo vrednosti 0 oziroma napačno. Za mehke množice pa velja, da nek element pripada neki množici s tako imenovano stopnjo pripadnosti, ki je realno število med 0 in 1. Elementi neke množice so tako opisani z imenom in stopnjo pripadnosti tej množici. Posamezni element lahko pripada različnim množicam z različno stopnjo pripadnosti. Vsota stopenj pripadnosti elementa različnim množicam je lahko večja ali manjša od 1. Stopnja pripadnosti je določena s funkcijo pripadnosti, ki je lahko podana tabelarično ali pa zvezno v obliki enačbe oz. grafikona.

Tak pristop je uspešnejši kot klasičen pri reševanju kompleksnih problemov, za katere se ne da zgraditi klasičnih matematičnih modelov, kjer so vhodne vrednosti nenatančne ali nepopolne ali pa po svoji naravi mehko določene (upravljanje fizikalnih in kemijskih sistemov, ekspertni sistemi, ...). Omogoča opise vrednosti, kot na primer velik (fant), blizu (Ljubljane), primerna (cena), zmerno hiter (odziv), ... in obravnavo takih vrednosti (Negnevitsky, 2002).

## **5.7. Evolucijsko računanje in genetski algoritmi**

Na začetku poglavja smo omenili dva pristopa v razvoju umetne inteligence: simbolični in mrežni pristop.

Na *simboličnem* temeljijo klasično računalništvo in ekspertni sistemi. Značilno zanj je zaporedno procesiranje, možnost razlage odločitve, eksplicitno shranjena pravila, ... Podobnosti z biološkimi sistemi ni.

Iz *mrežnega* pristopa izhaja koncept nevronske mreže. *Tu gre za posnemanje primerov iz žive narave.* (Za razliko od pristopov, ki temeljijo na primerih iz nežive narave npr. ohlajanju snovi.) Značilnosti mrežnega pristopa so vzporedno procesiranje, lokalnost, nehierarhična struktura, pravila se kreirajo dinamično.

Ena od oblik prilagajanja živih sistemov okolju je *učenje iz primerov*, druga oblika pa je *evolucija*. Vzor iz narave, ko na podlagi mutacije, križanja in selekcije preživijo le primerki, ki so najuspešnejši, posnema področje umetne inteligence, imenovano **evolucijsko računanje**. Osnovo evolucijskega računanja predstavljajo *genetski*



*algoritmi* (za optimizacijo), *genetsko programiranje* (pri razvoju programov) in *evolucijske strategije*.

Pri genetskih algoritmih je osnovni element (objekt) gen, ki podaja možno rešitev problema za en parameter. Vsi geni skupaj tvorijo kromosom, ki ustreza eni rešitvi problema. Geni so lahko: binarni vektorji, cela števila ali realna števila. Vsaka nova ponovitev evolucijskega ciklusa da boljšo rešitev problema. Pri genetskem programiranju je evoluciji podvržena populacija računalniških programov. Cilj je izbrati tisti računalniški program, ki najbolje rešuje dani problem (Filipič, 1996).

Evolucijski cikel sestavljajo koraki:

- generacija začetne populacije,
- ocenjevanje osebkov zadnje populacije (selekcija),
- formiranje nove generacije na osnovi genetskih operacij (križanje, mutacija).

Pričakuje se, da vsaka nova ponovitev zadnjih dveh korakov evolucijskega ciklusa da boljšo rešitev problema.

Problem, ki ga rešujemo s pomočjo genetskih algoritmov, določa obliko populacije in cenitveno funkcijo, ki izbira najboljše primerke. Ta metoda se uporablja za reševanje optimizacijskih problemov, kot je na primer razporejanje proizvodnih kapacitet.

## **5.8. Računalniško zaznavanje**

### **RAČUNALNIŠKI VID**

Za razliko od logičnega reševanja problemov, ki se ga naučimo, se zdi, da je prepoznavanje vzorcev prirejena lastnost ljudi. Ker je naloga prepoznavanja vzorcev drugačne narave kot logično reševanje problemov, je uporaba sistemov temelječih na znanju neučinkovita. Za prepoznavanje vzorcev je bilo razvitih več praktičnih tehničnih rešitev, kot sta sistema za zaznavanje v industriji DIP (Document Image Processing) in OCR (Optical Character Recognition System).

Računalniški vid je opredeljen kot znanstvena disciplina, ki se ukvarja s razvijanjem modelov, pomenom in kontrolo podatkov iz vizualnih podatkov.

Na področju računalniškega vida govorimo o dveh pristopih. Prvi pristop temelji na modelih biološkega procesiranja vida in se ukvarja z razvojem teorije vidnega zaznavanja, drugi pa se ukvarja s praktičnimi industrijskimi rešitvami, poimenovali so ga strojni vid.

Za procesiranje vizualnih podatkov na podoben način, kot jih procesira človek, bi potrebovali izjemno zmogljiv računalnik. Oko zaznava okolico z okoli 100 milijoni pikslov. Čeprav je hitrost prenosa podatkov v računalniku večja, kot v človeških možganih, pa je obdelava slike zaradi paralelnega procesiranja milijonov nevronov tista, ki omogoča izjemno visoko kakovost v realnem času.

Moderni strojni vid ima dosti nižjo resolucijo kot človeško oko, vendar so zahteve po zmogljivosti strojne opreme še vedno zelo velike, če želimo zagotoviti procesiranje slike v realnem času. Rešitve iščejo v paralelnem procesiranju.

Pri gradnji praktičnih sistemov za strojni vid je poleg težav z zmogljivostjo strojne opreme veliko komplikacij pri prepoznavanju oz. razumevanju slik. Med njimi: različni

pogledi na isti objekt (različna razdalja, drugi kot pogleda), dvoumnost, nepopolni podatki, različna osvetljenost objekta. Težave postanejo še večje, če je na sliki več objektov hkrati. Ker imajo zunanji pogoji močan vpliv na naravo slike, je industrijski strojni vid zato, da je prepoznavanje olajšano, omejen na vnaprej določeno okolje.

Pri procesiranju slike je vhodni podatek slika, ki jo zajame kamera. Velik delež napora procesiranja slike je namenjen pretvarjanju dvodimenzionalno zajete slike v tri dimenzije. Celoten proces lahko razdelimo v tri faze:

- obdelava signalov, ki obsega filtriranje šuma in zaznavanje mej objektov,
- samo procesiranje slike, ki obsega razlikovanje notranjih delov objektov na sliki in
- razumevanje slike.

Prvo in del druge faze usmerjajo algoritmi za računalniški vid, del druge in tretja faza pa je izvedena na osnovi baze znanja določenega področja.

Čeprav je omejitev za procesiranje slik vrhunske kakovosti z zmogljivostjo strojne opreme velika, se je strojni vid uveljavil na različnih področjih: v proizvodnji za nadzor delov pri montaži, avtomatskemu razvrščanju in pakiranju, robotiki, slikanju dokumentov, kot pripomoček pri načrtovanju; v medicini za analizo ultrazvočnih, rentgenskih, tomografskih in drugih slik ...

## PROCESIRANJE NARAVNEGA JEZIKA

Naravni jezik pomeni najpomembnejšo obliko komuniciranja med ljudmi. Razumevanje naravnega jezika, ko je besedilo z vneseno v računalnik, zadeva dve področji:

- samo razumevanje naravnega jezika in
- prevajanje (iz enega v drug naravni jezik).

Področje umetne inteligence – razumevanje naravnega jezika poskuša za to razviti učinkovite računalniške algoritme.

Prvo področje – razumevanje naravnega jezika zadeva razumevanje ukazov, ki jih uporabnik daje računalniku v naravnem jeziku, tako da se računalnik pravilno odzove.

Najstarejši in najpreprostejši sistem za prepoznavanje naravnega jezika je **ujemanje besed**. Bistvo je prepoznavanje specifičnih ključnih besed v vhodnem besedilu. Ključne besede se spreminjajo od besed do fraz in celih stavkov. Tak način ne izvede analize, s katero bi lahko ugotovili, kako določene besede ali fraze vplivajo druga na drugo in tako dajo besedilu spremenjen pomen.

Sistem za prepoznavanje naravnega jezika **na osnovi sintakse in semantike** za prepoznavanje uporablja kombinacijo obeh. Sintaktična analiza vhodnega stavka določa relacijo med besedami in stavki glede na slovnico jezika. Semantična analiza pa skuša besedilu dati pomen glede na pomen posameznih besed.

Sistemi, ki temeljijo **na bazi znanja**, poskušajo besedilu dati pomen na osnovi specifične baze znanja in na osnovi baze splošnega znanja. Pri teh sistemih se običajno uporabljajo pristop, ki temelji na konceptualni odvisnosti ali na scenariju.

**Strojno prevajanje** ima v osnovi iste tri pristope kot razumevanje naravnega jezika.

Najpreprostejše je prevajanje na osnovi vzorcev, kjer sistem poišče vhodnemu vzorcu primeren par vzorca iz slovarja. Vzorci so običajno besede ali fraze. Tak sistem besedila seveda ne razume in je zato omejen.

Pri uporabi sintakse in semantike za prevajanje temelji na razumevanju izvirnega in ciljnega jezika. Sistem torej prevaja pomen izvirnega jezika in ne besedo za besedo.

Visoko kakovostni sistemi za avtomatsko prevajanje temeljijo na bazi specifičnega znanja določenega področja in splošnega znanja.

## Procesiranje govora

Govorno komuniciranje z računalnikom lahko naredi uporabo računalnika bolj prijazno. Pri procesiranju govora govorimo o dveh komponentah: **prepoznavanju govora** in **razumevanju govora**. Pri prepoznavanju gre za povezovanje izgovorjene besede s pripadajočo iz slovarja. Pri razumevanju govora pa gre za prepoznavanje besed in stavkov govora in razumevanje naravnega jezika.

*Problemi pri prepoznavanju govora so podobni kot pri prepoznavanju slik. Gre za nejasnost izgovorjave in s tem možne dvoumnosti prepoznavanja kdaj se beseda začne in kdaj konča. Vzorci izgovorjave istih besed so različni ne le med ljudmi, ampak tudi pri isti osebi, poleg tega pa je običajno, da so v okolju, kjer se generira zvočni signal, tudi drugi, moteči zvoki.*

Za reševanje teh problemov je bilo razvitih več matematičnih in hevrističnih tehnik. Matematične tehnike so uporabne pri prepoznavanju zvoka, pri razumevanju pa so smiselne hevristične tehnike.

## 5.9. Robotika

Robotika je v prakso usmerjena dejavnost, ki se ukvarja z razvojem robotov, t.j. naprav, ki so zmožne nadomestiti človeka pri opravljanju določenih opravil, npr. pri sestavljanju neke naprave iz danih sestavnih delov. Fizična opravila robot opravlja na način, ki vsaj bežno spominja tudi na človeka. Zaradi praktičnih razlogov pa so roboti po obliki običajno zelo različni od človeka. Razširjen tip robota je umetna roka, ki se giblje v določenem prostoru, kjer opravlja koristno delo, npr. postavlja elemente v določene položaje. Značilni opravili pa sta tudi varjenje in barvanje, npr. v avtomobilski industriji.

Pri opravljanju operacij robota vodi računalnik. Ob vodenju robota se pojavlja cela vrsta zapletenih problemov, ki jih mora računalnik rešiti sproti. V osnovi gre za problem upravljanja robota v smislu doseganja želenega (ciljnega) stanja. Iz podatkov o stanju robota in elementov v prostoru, ki ga obvladuje, je potrebno ustrezno krmiliti robota, da le-ta doseže zastavljeni cilj, npr. izvede zahtevano operacijo. V kibernetski (upravljalški) zanki nastopajo problemi zaznave, npr. računalniškega vida, kompleksnega računanja, ki mora postreči z rezultati v realnem času. Če računalniku v procesu upravljanja robota naložimo tudi načrtovanje operacij, mora ta sam poiskati tako zaporedje operacij, da pride do (optimalne) rešitve zastavljenega problema.

Gre torej za probleme, katerih narava in zapletenost govori o smiselnosti uporabe metod umetne inteligence, kot so npr. razpoznavanje slik in vzorcev na sploh, simbolično programiranje in hevristično reševanje problemov. Glede na stopnjo

samostojnosti robota (kako se robot znajde v dani situaciji) običajno govorimo tudi o njegovi višji ali nižji stopnji »inteligentnosti«.

## Literatura

1. Alter, S.: Information Systems: A Management perspective. New York, Addison – Wesley, 1999.
2. Bohanec M. in V. Rajkovič: DEX: An expert system shell for decision support. *Sistemica*, 1(1):1450–157, 1990.
3. Bohanec M., Rajkovič V.: Večparameterski odločitveni sistemi. *Organizacija*, let. 28, št.7, Kranj, 427–438, 1995.
4. Bratko, I.: Inteligentni informacijski sistemi. Ljubljana: Fakulteta za elektrotehniko, 1982.
5. Dobnikar, A.: Nevronske mreže. Radovljica: Didakta, 1990.
6. Dutta, S.: Knowledge Processing & Applied Artificial Intelligence. Oxford, Butterworth-Heinmann Ltd., 1993.
7. Feigenbaum, E.A.: The Art of Artificial Intelligence: Themes and Case Studies of Knowledge Engineering. V: Michie, D. (editor) *Expert Systems in Microelectronic Age*. Edinburg University Press, 1979.
8. Filipčič, B.: Pregled metod evolucijskega računanja. Zbornik pete elektrotehniške in računalniške konference ERK '96, Portorož 1996, Zvezek B, str. 31–34.
9. GartnerGroup: Knowledge Management – Everything and Nothing, Gartner Group Symposium Documentation, Lake Buena Vista, Florida, 1999.
10. Gerritsen, R.: Assessing loan Risks: A Data Mining Case Study. *ITProfessional*, Nov./Dec. 1999, str. 16–21.
11. Groth, R.: Data Mining: Building Competitive Advantage. Prentice Hall, 2000.
12. Hammond S. J., Keeney L. R., Raiffa H.: Pametne odločitve: Praktični vodnik za sprejemanje boljših odločitev, Ljubljana, Gospodarski vestnik, 2000.
13. Han, J., M. Kamber: Data Mining: Concepts and Techniques. Morgan Kaufman, 2001.
14. Hayes. N., S. Orell: *Psychology An Itroduction*. Harlow, Longman, 1993.
15. Ilc Rutar, Z.: Gradivo za seminar in projekt Nova kultura preverjanje znanja. Ljubljana, Zavod RS za šolstvo, 2000.
16. Informatika, učni načrt. Nacionalni kurikularni svet, MŠZŠ, Ljubljana, 1998.
17. Jackson, P.: Expert Systems. Addison Wesley, 1999.
18. Key data on education in Europe. Eurydice, Eurostat, 2000.
19. Kokol, P. et al.: Inteligentni sistemi. Maribor, Univerza v Mariboru, Fakulteta za elektrotehniko, računalništvo in informatiko, 2000.
20. Kononenko, I.: Strojno učenje. Ljubljana, Založba Fe in FRI, 1997.
21. Luger, F. G.: Artificial Intelligence. Addison Wesley, 2002.
22. Marentič Požarnik, B.: Psihologija učenja in pouka. Ljubljana, DZS, 2000.

23. Marzano R. J. et al.: Dimensions of Thinking: a Framework for Curriculum and Instruction. Aleksandrija, ASCD, 1989.
24. Munakata, T.: Fundamentals of New Artificial Intelligence: Beyond Traditional Paradigms. New York, Springer, 1998.
25. Negnevitsky, M.: Artificial Intelligence: A Guide To Intelligent Systems. Harlow, Pearson Education, 2002.
26. Newton, D. P.: Teaching for Understanding. London and New York, RutledgeFlamer, 2000.
27. Nilsson, J.N.: Artificial Intelligence: A New Synthesis. San Francisco, Morgan Kaufmann Publishers, Inc., 1998.
28. Rajkovič, V., M. Bohanec: Ekspertni sistemi v izobraževanju: Kaj lahko storimo za boljše odločanje? Program Računalniško opismenjevanje. MŠŠ in ZRSŠ, 1999.
29. Rajkovič, V., M. Bohanec: O nekaterih problemih v procesu odločanja. Zbornik s konference Organizacija, informatika, kadri; danes-jutri. str.141-147. Portorož, 1991.
30. Rajkovič, V: Tim in sodobna informacijska tehnologija. V: Skrivnost ustvarjalnega tima. Ljubljana, Dedalus, 2001.
31. Ravenscroft, A., R. M. Pilkington: Investigation by design: developing dialog models to support reasoning and conceptual change. International Journal of Artificial Intelligence in Education, Vol.11, No. 3, str. 273–298, 2000.
32. Russell, P.: Knjiga o možganih: Spoznajte svoj razum in se ga naučite uporabljati. Ljubljana, Državna založba Slovenije, 1990.
33. Scot, P., C. Spencer: Psychology: A Contemporary Introduction. Oxford, Blackwell Publischer, 1989.
34. Teacher Resources: Supporting a Constructivist Curriculum with Technology <http://members.aol.com/Ulmer3/index4.html>.
35. Voolfolk, A.: Pedagoška psihologija. Ljubljana, Educy, 2002.
36. Zupan, B., M. Bohanec, J. Demsar and I. Bratko: Learning by discovering concept hierarchies, Artificial Intelligence, 109(1–2): str. 211–242, 1999.